Instituto Tecnológico de Buenos Aires

16.63 Procesamiento de Señales e Imágenes Biomédicas
2026 — Segundo cuatrimestre

Comisión BIO

Detección de lunares sospechosos mediante imágenes dermatoscópicas

Trabajo Práctico de Imágenes (TPI)

PSIB2026Q2-TPI-Grupo02-CassanoNieto DElia Ortega

Grupo 2

Integrante	Legajo
Cassano Nieto, Facundo Tomás	65555
D'Elía, Lucas Valentín	65414
Ortega, Facundo	65560

Docentes: Roberto Sebastián Tomás, Lucila Capurro,
Francisco Joaquín Tassara y Victoria Reppucci

5 de noviembre de 2026

Resumen

El melanoma se parece a un lunar común en sus comienzos, y la regla dermatoscópica ABCD ayuda a distinguirlos a partir de la asimetría, el borde, los colores y las estructuras de la lesión. En este trabajo se desarrolló un algoritmo que mide esos criterios en las 200 imágenes de la base PH2 con procesamiento clásico de imágenes, sin entrenar un clasificador. Las imágenes se separaron en 140 de entrenamiento y 60 de prueba, y todo parámetro se fijó con las primeras. La segmentación por crecimiento de regiones alcanzó un Dice medio de 0,916 en prueba. Quitar los pelos con un cierre morfológico no mejoró la segmentación, por lo que la primera hipótesis no se confirmó. El criterio D estimado a partir de la textura no separó las lesiones sospechosas de los lunares comunes en prueba (AUC 0,60), mientras que la diferencia de saturación entre la periferia y el centro de la lesión sí lo hizo (AUC 0,71; IC 95 %, 0,58 a 0,84). La asimetría y los colores medidos coincidieron con los del dermatólogo con un κ de 0,38 y 0,24. El TDS automático separó las lesiones sospechosas de los lunares comunes con un AUC de 0,78 (IC 95 %, 0,66 a 0,89), pero agregarle los términos de zonas no lo mejoró, así que la segunda hipótesis se confirmó sólo en parte.

Índice

1. Introducción **2**
1.1. Problemática . . . 2
1.2. Marco teórico . . . 2
1.3. Estado del arte . . . 2
1.4. Pregunta, objetivos e hipótesis . . . 3

2. Materiales y métodos **3**
2.1. Base de datos y alcance . . . 3
2.2. Esquema del algoritmo . . . 4
2.3. Pre-procesamiento . . . 4
2.4. Segmentación . . . 5
2.5. Criterios A, B y C . . . 5
2.6. Textura y criterio D adaptado . . . 6
2.7. Zonas de la lesión y mapas de características . . . 6
2.8. Clasificación . . . 6
2.9. Evaluación . . . 7
2.10. Interfaz gráfica y código . . . 7

3. Resultados **7**
3.1. Pre-procesamiento . . . 7
3.2. Segmentación . . . 8
3.3. Criterios y comparación con el dermatólogo . . . 9
3.4. Zonas y mapas de características . . . 9
3.5. Clasificación . . . 10

4. Conclusiones **11**

Referencias **12**

A. Anexo **13**

1. Introducción

1.1. Problemática

El melanoma es un cáncer de piel cuyo pronóstico depende de cuán temprano se lo detecte. Al comienzo se parece mucho a un lunar común, y el dermatólogo lo evalúa con el dermatoscopio, una lente de aumento con iluminación propia. Para hacerlo de forma sistemática usa la regla ABCD, que puntúa la asimetría (A, de 0 a 2 según en cuántos ejes es asimétrica la lesión), el borde (B, de 0 a 8 según en cuántos sectores el pigmento termina de forma abrupta), los colores (C, de 1 a 6) y las estructuras diferenciales, como la red de pigmento o los glóbulos (D, de 1 a 5), y los combina en el puntaje dermatoscópico total

$$\mathrm{TDS} = 1{,}3\,A + 0{,}1\,B + 0{,}5\,C + 0{,}5\,D. \tag{1}$$

Un TDS menor a 4,75 indica una lesión benigna; entre 4,75 y 5,45, una lesión sospechosa, y mayor a 5,45, una lesión probablemente maligna [1]. La evaluación es visual y su precisión depende de la experiencia de quien la hace.

1.2. Marco teórico

La imagen dermatoscópica es una imagen RGB en la que el color tiene valor diagnóstico, porque depende de la profundidad del pigmento. Los marrones y el negro indican melanina en la epidermis, el azul grisáceo indica melanina en la dermis y el blanco, zonas de regresión. Por eso conviene trabajar en el espacio HSV, que separa el matiz (H) y la saturación (S) del brillo (V). Antes de medir ese color hay que lidiar con los artefactos de la imagen. La lente circular deja esquinas oscuras (viñeteo), y los pelos que cruzan la lesión, que se ven como líneas oscuras y finas, desplazan el borde segmentado y agregan un color que no le pertenece. Estos pueden quitarse con un cierre morfológico con un elemento estructurante más ancho que un pelo y más chico que la lesión, idea en la que se basa DullRazor [2].

Además del color, la regla mira las estructuras diferenciales, que son patrones que se repiten dentro de la lesión y que pueden describirse como textura. Una forma clásica de medirla es la matriz de co-ocurrencia de niveles de gris (GLCM), que cuenta con qué frecuencia aparecen juntos dos niveles de gris a una distancia y dirección dadas, y de la que se obtienen atributos como la entropía, el contraste y la correlación [3]. Sin embargo, estas estructuras no se reparten al azar dentro de la lesión. Las estrías, por ejemplo, aparecen de forma focal y asimétrica en la periferia, y las áreas claras sin estructura en la periferia también se asocian al melanoma [4]. Un único número calculado sobre toda la lesión puede entonces promediar zonas que se comportan distinto. La interfase con la piel importa por otro motivo, ya que el criterio B puntúa justamente los sectores donde el pigmento termina de golpe [1], y comparar la lesión con la piel vecina permite medir ese cambio de forma continua.

Todo este detalle puede perderse al guardar o transmitir las imágenes. JPEG, el formato con pérdida más usado para fotografías [5], guarda el color a la mitad de resolución, divide la imagen en bloques de 8×8, les aplica la transformada discreta del coseno y cuantiza los coeficientes según un parámetro de calidad (de 1 a 100), descartando sobre todo las frecuencias altas. Lo que se pierde es justamente el detalle fino y parte del color que usa la regla ABCD.

1.3. Estado del arte

Los sistemas de diagnóstico asistido segmentan la lesión, miden descriptores de forma, color y textura y los entregan a un clasificador [6]. Las redes neuronales convolucionales ya alcanzan un desempeño comparable al de los dermatólogos [7], pero no muestran en qué se basa cada decisión, y la mayoría sólo informa el diagnóstico final, por lo que no permiten comprobar si cada criterio se mide bien.

Medir la regla ABCD de forma automática tampoco es una idea nueva. Un trabajo la implementó sobre 200 imágenes dermatoscópicas, 80 de melanomas y 120 de lesiones benignas, y obtuvo una sensibilidad de 91,25 % y una especificidad de 95,83 % [8]. Otro, sobre PH2, combinó color y textura con una máquina de vectores de soporte y separó melanomas de nevos con una sensibilidad de 99,25 % y una especificidad de 99,58 % [9]. Como referencia humana, el trabajo original de la regla informa 92,8 % y 90,3 % [1]. Estos valores no se pueden comparar directamente con los nuestros, porque ninguno de esos trabajos separa nevos comunes de nevos atípicos y melanomas, que es la pregunta de este trabajo.

Lo que buscamos aportar es una medición que se pueda revisar paso a paso. Cada criterio se compara con el dermatólogo, los mapas muestran en qué parte de la lesión está la información y el algoritmo final no entrena ningún clasificador, sino que usa la fórmula de la regla.

1.4. Pregunta, objetivos e hipótesis

Pregunta y objetivo general. ¿Pueden medirse automáticamente los criterios de la regla ABCD, complementarse con descriptores por zona de la lesión y distinguir lesiones sospechosas de lunares comunes? Para responderlo, buscamos desarrollar un algoritmo que haga esas mediciones y estime si la lesión es sospechosa, con una interfaz gráfica que muestre cada etapa.

Objetivos específicos. (1) Quitar los artefactos (viñeteo y pelos) y medir su efecto en la segmentación; (2) caracterizar la pérdida por compresión JPEG; (3) segmentar la lesión y validar contra la máscara manual (Dice); (4) medir A, B y C y comparar A y C con el dermatólogo (κ de Cohen); (5) estimar un criterio D adaptado a partir de la textura; (6) construir mapas de características y descriptores por zona y evaluar si mejoran la clasificación al agregarse al TDS; (7) clasificar con el TDS y medir sensibilidad, especificidad y AUC en un conjunto de prueba.

Hipótesis. (H1) Quitar los pelos con un cierre morfológico mejora la segmentación de las imágenes con pelos respecto de no quitarlos y de un filtro de mediana. (H2) El TDS automático separa las lesiones sospechosas de los nevos comunes, y agregarle términos de textura y de zonas mejora esa separación. Como objetivo de máxima, se evalúa además si el desempeño se mantiene sobre imágenes comprimidas con JPEG.

2. Materiales y métodos

2.1. Base de datos y alcance

Se usa la base PH2 [10], del Hospital Pedro Hispano (Portugal), con 200 imágenes dermatoscópicas RGB de 8 bits por canal adquiridas con el mismo equipo, que incluyen 80 nevos comunes, 80 nevos atípicos y 40 melanomas (figura 10 del anexo). Hay 24 tamaños de imagen distintos, así que ninguna etapa supone un tamaño fijo. La lesión ocupa entre el 3 % y el 98 % de la imagen (mediana 23 %) y en 50 imágenes toca el borde. Cada imagen trae la máscara de la lesión dibujada a mano y la evaluación de un dermatólogo (diagnóstico, asimetría, colores y estructuras), lo que permite validar cada etapa por separado.

Se considera *sospechosa* toda lesión con diagnóstico de nevo atípico o melanoma (120 imágenes) y *no sospechosa* a los nevos comunes (80), porque la pregunta es distinguir las lesiones que ameritan control de los lunares comunes.

Para el criterio D adaptado se cuenta la cantidad de estructuras presentes según el dermatólogo (0 a 5). La red de pigmento se cuenta sólo cuando es atípica. En la regla original se cuenta su presencia [1], pero en PH2 todas las lesiones tienen red, así que se usa la red atípica, que es la que se asocia al melanoma [11]. Con esta definición, el D medio es 0,65 en los nevos comunes, 1,79 en los atípicos y 3,12 en los melanomas.

Las imágenes se dividieron en entrenamiento (140, con 56 nevos comunes, 56 atípicos y 28 melanomas) y prueba (60, con 24, 24 y 12), de forma estratificada y con semilla fija. Todos los umbrales y parámetros se eligen únicamente con entrenamiento, y prueba se usa sólo para las métricas finales.

2.2. Esquema del algoritmo

La figura 1 muestra el recorrido de una imagen por el algoritmo. La compresión (M2) no forma parte de ese recorrido, y se estudia aparte para saber qué se pierde al guardar las imágenes en JPEG.

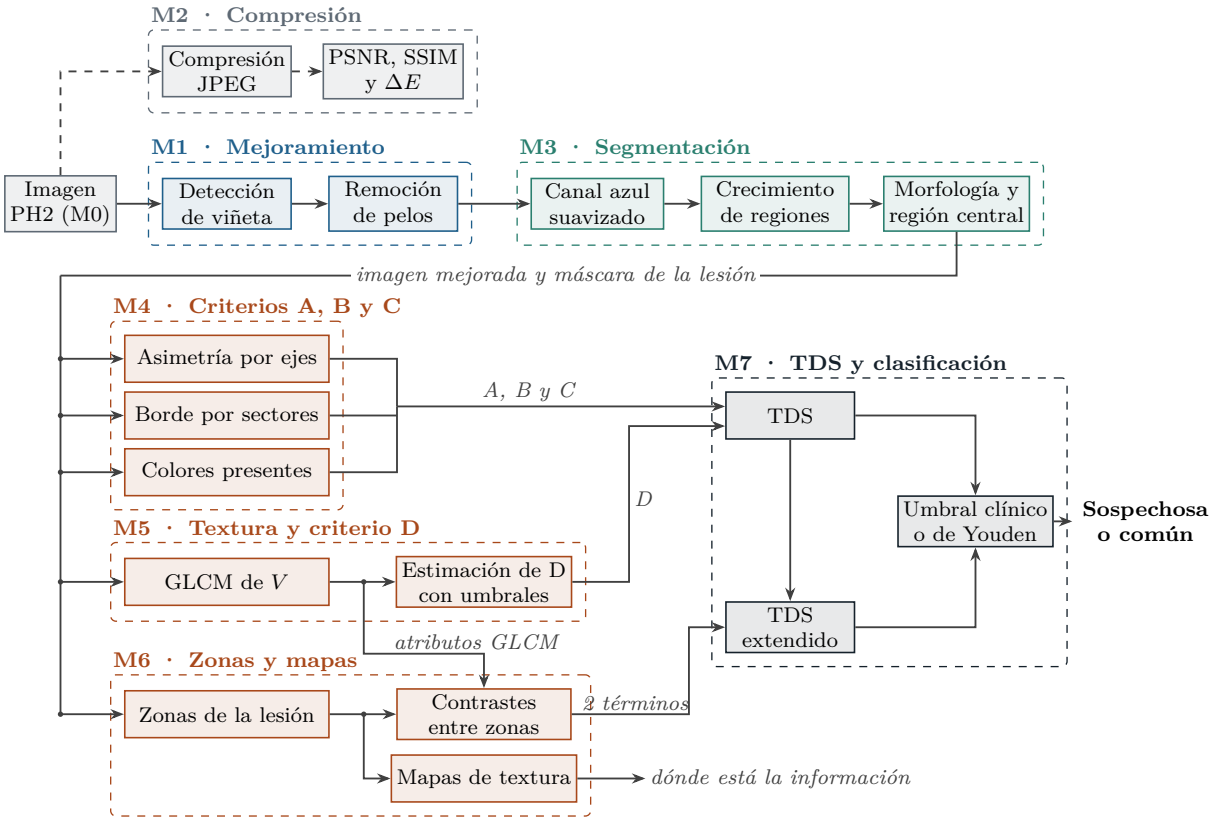


Figura 1: Diagrama de bloques del algoritmo. Los recuadros agrupan los bloques de cada módulo del repositorio, y la línea punteada marca el estudio de compresión, que queda fuera del recorrido principal.

2.3. Pre-procesamiento

Análisis exploratorio. Con las imágenes de entrenamiento se eligió el canal con más contraste entre lesión y piel. En cada imagen se tomaron 2000 píxeles de cada una y se calculó el área bajo la curva ROC (AUC) de separarlos con un umbral sobre cada canal (R, G, B, H, S, V, L de Lab y gris).

Viñeteo. Las esquinas oscuras se excluyen con una máscara de píxeles válidos. Un umbral fijo de brillo no sirve, porque el que captura todas las esquinas captura también zonas oscuras de 124 de las 140 lesiones de entrenamiento. En cambio se aprovecha que la viñeta es circular y centrada, y que la mediana de V en un anillo no se ve afectada por una lesión que ocupa sólo una parte de él. La viñeta empieza en el primer anillo cuya mediana cae por debajo del 60 % del anillo más brillante, y nunca antes del 80 % de la semidiagonal, para no cortar lesiones muy grandes (figura 11 del anexo).

Pelos. Se detectan con un cierre morfológico del gris con segmentos de 21 píxeles en 12 orientaciones. Son candidatos los píxeles donde la diferencia entre el cierre y la imagen (*black-hat*)

supera 0,10 [2]. Como la red de pigmento también es oscura y fina, sólo se conservan las regiones largas, finas y alargadas (tabla 6 del anexo). Esos píxeles se reconstruyen por *inpainting* [12] y el resto de la imagen no se modifica. Para la hipótesis 1 se compara con no quitar los pelos y con un filtro de mediana de 9×9 por canal.

Compresión. Cada imagen de entrenamiento se comprimió con JPEG a calidades 95, 75, 50, 25 y 10, y se midieron la tasa de compresión, el PSNR (en toda la imagen y dentro de la lesión), el SSIM [13] y la diferencia de color media dentro de la lesión en Lab (ΔE, CIE76), para la que 2,3 es el umbral aproximado de percepción. Cada calidad se resume con la mediana de las 140 imágenes.

2.4. Segmentación

Se segmenta sobre el canal azul, que es el que mejor separa la lesión de la piel, suavizado con un filtro gaussiano para que el pigmento y los puntos no dejen un borde dentado. El suavizado se hace en esta etapa y no en el mejoramiento porque la imagen mejorada también se usa para medir colores y textura, y suavizarla borraría la red de pigmento.

Se compararon cinco métodos. El umbral de Otsu [14] se calcula sólo con los píxeles válidos, para que la viñeta no corra el histograma. El crecimiento de regiones arranca del píxel más oscuro de un recuadro central, ya que en PH2 la foto apunta a la lesión, y agrega vecinos mientras no superen un límite de brillo a mitad de camino entre la lesión (percentil 5 del recuadro central) y la piel (percentil 90 de la zona válida), así que se adapta a lesiones oscuras y claras. En *watershed* se marca como lesión todo lo oscuro y como piel sólo lo claro conectado con el borde de la zona válida, porque si cualquier zona clara contaba como piel, las partes claras de las lesiones grandes quedaban afuera. k-means agrupa el color en Lab, ya que sobre un solo canal daría lo mismo que Otsu, y Chan-Vese [15] arranca desde el contorno de Otsu porque con el arranque por defecto se trababa en las lesiones chicas. A todas las salidas se les aplica una apertura para borrar islas, un cierre para rellenar mellas del borde, la selección de la región del centro de la imagen y el relleno de huecos.

Los parámetros de cada método se eligieron con una grilla sobre las 140 imágenes de entrenamiento, tomando la combinación de mayor Dice medio, y se amplió para *watershed*, el único que mejoraba más allá de los valores probados. Consideramos mal segmentada a una imagen con Dice menor a 0,7. El método elegido fue el crecimiento de regiones, con $\sigma = 4\,\text{px}$, tolerancia 0,5, apertura de 3 px y cierre de 10 px.

2.5. Criterios A, B y C

Los criterios se miden sobre la máscara automática, que es la que tendría el programa con una imagen nueva, y cada umbral se eligió en entrenamiento probando una lista de valores.

Asimetría. La máscara se refleja sobre sus dos ejes principales, calculados con los momentos de segundo orden, y se mide qué fracción de la lesión queda sin pareja. Un eje es asimétrico si esa fracción supera 0,11, el umbral con mayor κ con el dermatólogo, y A es la cantidad de ejes asimétricos.

Borde. El contorno se divide en 8 sectores de 45° contados desde el eje mayor, y en cada uno se promedia el gradiente de V (filtro de Sobel) sobre el contorno, sin contar los puntos pegados al marco de la foto, donde la lesión no termina sino que está cortada. Además del gradiente crudo se probó dividirlo por el salto de brillo entre lesión y piel, para medir qué tan rápido cambia el brillo y no cuánto. Como PH2 no anota B, el umbral de sector abrupto es el que mejor separa los nevos comunes de las lesiones sospechosas.

Color. Una referencia fija de cada color no sirve, porque en las zonas que pintaron los autores de PH2 el azul grisáceo es casi igual al negro, el blanco se ve rosado y todo cambia con la luz y el tono de piel. Comparados con la piel de la misma foto, en cambio, los colores se ordenan con sentido. El blanco es tan claro como la piel pero más azulado, los marrones son más rojizos

y el azul grisáceo y el negro son oscuros y grises. Por eso, y es la decisión más importante de este criterio, cada imagen se divide por el color de la piel de un anillo alrededor de la lesión. Las referencias son la mediana en HSV de las zonas de cada color en entrenamiento (tabla 5 del anexo). Como PH2 no trae zonas rojas, las marcamos a mano en las 7 imágenes con rojo anotado, aunque sólo una tenía rojo claro. Cada píxel se asigna al color más cercano, o a la piel si se parece más a ella, y un color está presente si ocupa más del 5 % de la lesión. Se calcula además la circularidad 4π área/perímetro^2, sin umbral.

2.6. Textura y criterio D adaptado

Se calcula la GLCM sobre V usando sólo pares de píxeles dentro de la lesión, promediada en las cuatro direcciones, y de ella se obtienen la energía, la entropía, el contraste, el IDM, la correlación, el *cluster shade* y el *cluster prominence* [3]. Se usan 32 niveles de gris y distancia 1, porque en entrenamiento la correlación de Spearman de la mejor medida con D apenas se mueve (de 0,37 a 0,40) entre 8 y 64 niveles y entre distancias 1, 2 y 4. La textura se mide en V, como se propuso en el anteproyecto, y no se comparó con otros canales.

Como PH2 no anota exactamente las cinco estructuras de la regla, se usa el D adaptado de la sección 2.1. Para estimarlo en una imagen nueva se toma el atributo que más crece con D en entrenamiento, que resultó ser la correlación ($\rho = 0{,}39$), y se cuenta cuántos umbrales supera. Los umbrales se ubican en los cuantiles que hacen que el D estimado se reparta como el del dermatólogo, y valen 0,879, 0,952, 0,970, 0,973 y 0,979. Se descartó ponerlos entre las medianas de cada valor de D porque, con validación cruzada en entrenamiento, estimaba $D = 5$ en unas 27 imágenes cuando en realidad hay 4.

2.7. Zonas de la lesión y mapas de características

Siguiendo la devolución del anteproyecto, se mira por separado el centro, la periferia y la interfase con la piel. Las zonas se definen con la transformada de distancia al borde de la máscara (figura 2). El centro es donde esa distancia supera la mitad de su máximo y la periferia es el resto de la lesión. Las interfases interna y externa son anillos de 15 px a cada lado del borde, y la externa no incluye las esquinas de la viñeta. Los 15 px salen del perfil de brillo alrededor del borde, que en entrenamiento alcanza el 90 % del brillo de la piel a 12 px en la mediana y a 19 px en el percentil 75.

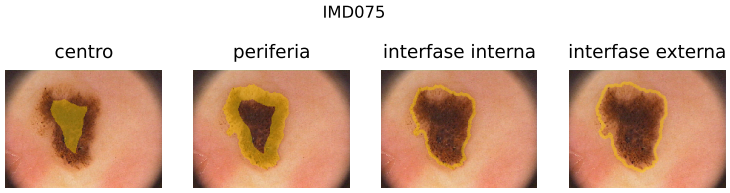


Figura 2: Las cuatro zonas sobre una lesión de tamaño típico de entrenamiento.

En cada zona se miden el color medio en HSV y los atributos GLCM de V. A partir de ellos se calculan 10 contrastes, restando periferia menos centro y piel menos lesión para H, S, V, contraste y entropía. El signo importa, porque el TDS extendido suma cada término y uno que baje en las sospechosas lo empeoraría. Además, para ver dónde está la información se calculan mapas de un atributo GLCM en ventanas de 31 px cada 8 px.

2.8. Clasificación

Una lesión se clasifica como sospechosa si su TDS automático (ec. 1) supera un umbral. Se comparan el umbral clínico (4,75) con el que maximiza la suma de sensibilidad y especificidad en entrenamiento (índice de Youden [16]). Para la hipótesis 2 se define un TDS extendido sumando

al TDS los términos de textura y de zonas elegidos en entrenamiento, estandarizados con la media y el desvío de entrenamiento, y se vuelve a elegir el umbral. Los dos términos se eligieron en entrenamiento, antes de mirar prueba, y son la saturación de periferia menos centro (AUC 0,76) y la de piel menos lesión (AUC 0,69). No se eligió el contraste de V entre piel y lesión, aunque su AUC es 0,74, porque se correlaciona con el primero ($\rho = 0{,}68$), mientras que los dos elegidos casi no se correlacionan entre sí ($\rho = 0{,}08$).

2.9. Evaluación

La segmentación se compara con la máscara de PH2 mediante el coeficiente de Dice, y A y C con el dermatólogo mediante el κ de Cohen [17], cuyos valores entre 0,41 y 0,60 indican un acuerdo moderado [18]. La clasificación se mide con la sensibilidad, la especificidad y el AUC.

Para H1 se usa la prueba de Wilcoxon de rangos con signo, porque el Dice se mide de a pares en las mismas imágenes. El intervalo de confianza del 95 % del AUC se calcula con un *bootstrap* de percentiles, sorteando 2000 veces con reposición dentro de cada grupo. Para comparar dos AUC se usa el mismo sorteo sobre las mismas imágenes, y la diferencia se considera significativa si su intervalo no incluye al cero.

2.10. Interfaz gráfica y código

La interfaz es una aplicación de escritorio en tkinter, que se abre con `python interfaz/app.py` (figura 13 del anexo). Permite elegir una imagen de prueba de PH2 o una propia, la procesa con los mismos métodos que el algoritmo final y muestra cada etapa, desde los pelos detectados y el contorno automático junto al de referencia hasta los ejes de simetría, el borde por sector, el mapa de colores, las zonas y los mapas de textura. En la pestaña de resultados presenta A, B, C, D, el TDS, el TDS extendido y la clasificación al lado de lo que anotó el dermatólogo. Sólo llama a las funciones de los módulos, de modo que lo que se ve es lo mismo que se evalúa.

El código está en `https://github.com/facortega/PSIB2026Q2-TPI-Grupo02-CassanoNieto-DElia-Ortega`. Cada módulo tiene un archivo `.py` con las funciones y un cuaderno `.ipynb` con las pruebas, las figuras y la discusión. La tabla 8 del anexo detalla el contenido de cada archivo.

3. Resultados

3.1. Pre-procesamiento

Canal de trabajo. El canal azul es el que mejor separa la lesión de la piel en entrenamiento (AUC medio 0,976, seguido por G con 0,965), lo que es coherente con que la melanina absorbe más la luz azul que la roja. El canal V, propuesto en el anteproyecto, queda entre los peores (0,902), porque $V = \max(R, G, B)$ y en la piel y la lesión domina el rojo. Por eso la segmentación se hace sobre B. El borde, en cambio, se mide sobre V, como estaba propuesto, porque ahí interesa el cambio de brillo en el contorno y no separar lesión de piel.

Viñeteo y pelos. Con el perfil radial, sólo 4 de las 200 imágenes pierden más del 2 % de la lesión por quedar fuera de la zona válida (máximo 5,9 %). En cuanto a los pelos, el cierre reconstruye sólo sus píxeles, mientras que la mediana suaviza toda la imagen, incluidas la red y el borde (figura 8 del anexo). El filtro de forma es lo que evita borrar la red. En IMD200, que no tiene pelos, el umbral solo marca como pelo el 28 % de la lesión, y el filtro completo, el 1 % (figura 9 del anexo).

Hipótesis 1. Se consideran con pelos las imágenes con más del 10 % de sus píxeles marcados, que son 30 de entrenamiento y 9 de prueba. La hipótesis no se confirmó (tabla 1). En entrenamiento,

el cierre empeora más imágenes de las que mejora, y la diferencia sólo es significativa frente a la mediana. En prueba no se detecta diferencia. El promedio de entrenamiento cae sobre todo por cuatro imágenes (IMD331, IMD418, IMD403 e IMD404) que pierden más de 0,1 de Dice, ya que las medianas de los tres métodos casi coinciden (0,906, 0,913 y 0,906). El algoritmo mantiene el cierre porque, a diferencia de la mediana, no suaviza la red de pigmento que mide M5, y porque cambiarlo después de mirar prueba invalidaría la evaluación.

	Dice medio			Cierre mejora / empeora (p)	
Conjunto (imágenes)	Sin quitar	Mediana	Cierre	Frente a sin quitar	Frente a mediana
Entrenamiento (30)	0,893	0,898	0,873	10 / 20 (0,10)	9 / 21 (0,025)
Prueba (9)	0,841	0,841	0,838	4 / 5 (0,65)	3 / 6 (0,36)

Tabla 1: Segmentación de las imágenes con pelos según cómo se quitan. El valor p es de la prueba de Wilcoxon.

Compresión. Incluso a calidad 95 el archivo ocupa unas 8 veces menos, con una pérdida imperceptible (tabla 7 del anexo). A esa calidad el PSNR dentro de la lesión es de 40,7 dB y el SSIM de 0,97, y a calidad 10 bajan a 28,7 dB y 0,70. El SSIM cae más que el PSNR al bajar la calidad, lo que indica que lo más afectado es la estructura local, es decir, la textura, y a calidad 10 la red de pigmento se reemplaza por bloques de 8×8 (figura 12 del anexo). Esperábamos entonces que la segmentación resistiera mejor que la textura y el borde, pero no lo comprobamos, porque no se llegó a repetir el algoritmo sobre imágenes comprimidas.

3.2. Segmentación

Los cinco métodos quedaron muy cerca en entrenamiento (tabla 2). Elegimos el crecimiento de regiones aunque *watershed* tiene un Dice medio 0,003 mayor, porque esa diferencia es despreciable, falla en una imagen menos y es casi diez veces más rápido. Otsu y Chan-Vese tienen la mediana más alta, pero fallan en 6 y 7 imágenes, y k-means quedó último, con 10 fallas. El crecimiento de regiones depende mucho de la tolerancia (de 0,69 a 0,91 de Dice medio), y en las lesiones chicas supera a Otsu por 0,04, porque ahí el histograma casi no tiene un pico de lesión y el umbral de Otsu se corre hacia la piel.

Método	Dice medio	Mediana	Peor	Dice $< 0{,}7$	Segundos por imagen
Watershed	0,911	0,936	0,504	3	0,151
Crecimiento de regiones	**0,908**	**0,931**	**0,501**	**2**	**0,016**
Otsu	0,906	0,940	0,262	6	0,013
Chan-Vese	0,900	0,938	0,262	7	0,351
k-means	0,880	0,925	0,259	10	0,207

Tabla 2: Métodos de segmentación con su mejor combinación de parámetros, sobre las 140 imágenes de entrenamiento.

En las 60 imágenes de prueba, el crecimiento de regiones da un Dice medio de 0,916 y una mediana de 0,946, muy parecidos a los de entrenamiento. Encuentra el 82,8 % de los píxeles de lesión y marca como lesión sólo el 1,1 % de los de piel, así que su error típico es quedarse corto, sobre todo en los melanomas. Falla en 2 de las 60 imágenes de prueba y en 2 de las 140 de entrenamiento, y las 4 son melanomas con azul grisáceo en los que dejó lesión afuera (figura 5 del anexo), porque ese color refleja bastante luz azul y en el canal B se ve casi como la piel. Aun así, 34 de las 38 imágenes con azul grisáceo salen bien, y ningún método, ni siquiera k-means, que mira el color completo, resolvió esos casos sin empeorar el resto, así que mantuvimos el canal azul.

3.3. Criterios y comparación con el dermatólogo

En prueba los criterios dan valores parecidos a los de entrenamiento, así que sus umbrales no quedaron ajustados sólo a esas imágenes.

Asimetría. El κ con el dermatólogo es 0,44 en entrenamiento y 0,38 en prueba, con coincidencia exacta en el 67 % de las imágenes de prueba. El acuerdo está en los extremos y el $A = 1$ es el más difícil. Muchos desacuerdos aparecen porque el dermatólogo también mira si el pigmento está repartido de forma pareja, y el programa sólo mira la forma del contorno (figura 6 del anexo).

Borde. Esperábamos que el gradiente normalizado separara mejor, y separó al revés (AUC entre 0,24 y 0,38 con cualquier umbral), porque en PH2 los nevos comunes suelen ser manchas parejas de borde nítido y los atípicos y melanomas tienen bordes que se desvanecen. Elegimos el gradiente crudo con umbral 0,0513, el único que suma en el sentido del TDS, aunque separa poco (AUC 0,60 en prueba).

Color. El κ de C es 0,17 en entrenamiento y 0,24 en prueba, aunque en el 80 % de las imágenes la diferencia es de un color como mucho. El marrón claro aparece casi siempre, incluso en 42 de las 44 lesiones de entrenamiento donde no fue anotado, porque es el color del borde, donde el pigmento se aclara. El blanco casi nunca se encuentra, porque el programa lo asigna a la piel, y el rojo sólo en la imagen de la que salió su referencia, mientras que el marrón oscuro, el azul grisáceo y el negro andan mejor (κ entre 0,49 y 0,57 en prueba) (figura 7 del anexo). Un mínimo propio para cada color mejora cada color por separado pero no el κ de C, así que mantuvimos uno solo.

Circularidad. Separa bien los grupos (AUC 0,72 en prueba), porque los melanomas son mucho menos circulares (mediana 0,34, contra 0,71 en los nevos comunes).

¿Error de segmentación o del criterio? Con la máscara de PH2 los criterios no mejoran. El κ de A baja de 0,44 a 0,29 y el AUC de la circularidad de 0,75 a 0,57, y B y C quedan parecidos, así que los desacuerdos vienen de los criterios y no de la segmentación. Una explicación posible es que nuestra máscara sigue el pigmento más oscuro y su forma refleja también cómo está repartido.

El criterio D estimado resultó débil como medida de D. En validación cruzada dentro de entrenamiento acierta el valor exacto en el 30 % de las imágenes, menos que decir siempre la mediana (37 %), y su acuerdo con el dermatólogo es casi nulo ($\kappa = 0{,}06$). En prueba acierta en el 40 %, también menos que la mediana de entrenamiento (50 %), con $\kappa = 0{,}17$. Tiene sentido, porque un solo número global de textura no puede contar cinco estructuras distintas.

3.4. Zonas y mapas de características

Los mapas sugieren que la información no está repartida de manera pareja (figura 3), aunque son dos ejemplos y no una prueba. Medido en las 140 imágenes de entrenamiento, en los nevos comunes la mediana de la entropía baja de adentro hacia afuera (4,40 en el centro, 4,31 en la periferia y 4,16 en la interfase interna), y en las sospechosas esa caída no aparece (4,31, 4,40 y 4,33). Un número global promedia esos comportamientos opuestos.

La tabla 3 muestra qué pasó al llevar estas medidas a prueba. D estimado cae a un AUC de 0,60 y su intervalo incluye al 0,5, de modo que no se puede afirmar que separe los grupos. La saturación de periferia menos centro es la única medida automática cuyo intervalo no incluye al 0,5, aunque hay que leerla con cuidado, porque sigue de cerca al brillo de la lesión ($\rho = -0{,}67$ en prueba) y ese brillo solo da un AUC parecido. Con estos datos no podemos separar los dos efectos. La saturación de piel menos lesión queda en 0,60, con un intervalo que incluye al 0,5, y

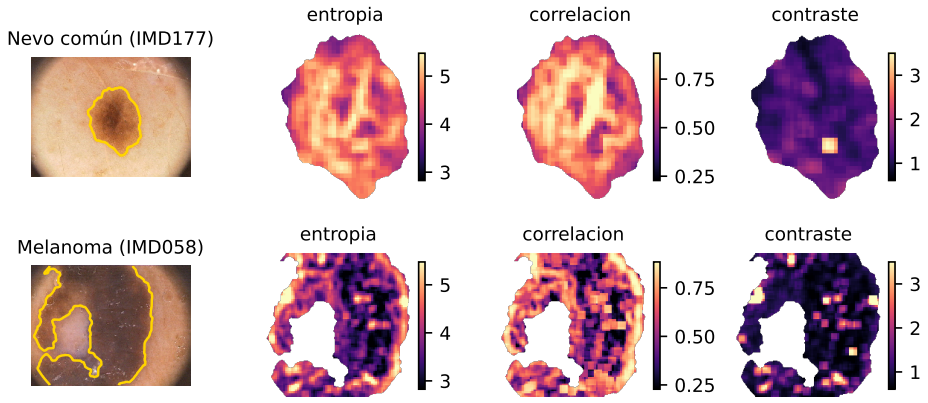


Figura 3: Mapas de entropía, correlación y contraste en un nevo común y un melanoma de entrenamiento. El hueco del mapa del melanoma es una zona central clara que la máscara automática dejó afuera.

además baja cuando M3 acierta más ($\rho = -0{,}42$ con el Dice), así que en parte mide errores de segmentación.

Medida	AUC entrenamiento	AUC prueba	IC 95 % en prueba
D del dermatólogo (techo)	0,92	0,88	0,81 a 0,94
D estimado	0,73	0,60	0,46 a 0,74
Periferia menos centro, S	0,76	0,71	0,58 a 0,84
Piel menos lesión, S	0,69	0,60	0,46 a 0,75
Oscuridad de la lesión ($-V$)	0,75	0,68	0,54 a 0,80
0,5 D más los dos términos de zonas	0,83	0,71	0,58 a 0,84

Tabla 3: Capacidad de cada medida para separar lesiones sospechosas de nevos comunes (140 imágenes de entrenamiento y 60 de prueba).

La última fila de la tabla es el TDS extendido sin A, B ni C, que no es el TDS y sirve sólo para ver si las zonas agregan algo a D. Sube el AUC en 0,11 respecto de D estimado, pero el intervalo de esa diferencia (de −0,01 a 0,23) incluye al cero, así que la mejora no es significativa. Con el umbral elegido en entrenamiento alcanza en prueba una sensibilidad de 0,81 y una especificidad de 0,54, frente a 0,56 y 0,63 de D estimado solo.

3.5. Clasificación

El TDS automático separa las lesiones sospechosas de los nevos comunes en prueba, con un AUC de 0,78 cuyo intervalo no incluye al 0,5 (tabla 4 y figura 4). Por separado, los criterios que más aportan son A y C (AUC de 0,73 y 0,69), mientras que B y D quedan en 0,60.

Clasificador	Umbral	Sensibilidad	Especificidad	AUC	IC 95 % del AUC
TDS, umbral clínico	4,75	0,25	0,96	0,78	0,66 a 0,89
TDS, umbral de Youden	2,25	0,78	0,58	0,78	0,66 a 0,89
TDS extendido, umbral de Youden	1,62	0,89	0,46	0,79	0,66 a 0,90

Tabla 4: Clasificación de las 60 imágenes de prueba. Los umbrales de Youden se eligieron en entrenamiento.

Con el umbral clínico la sensibilidad es de sólo 0,25 por los nevos atípicos. La regla se pensó para reconocer melanomas, y con ese umbral el programa detecta 8 de los 12 melanomas de prueba pero sólo 1 de los 24 nevos atípicos, cuyo TDS tiene una mediana de 3,05, más cerca de los nevos comunes (2,0) que de los melanomas (5,85). El TDS extendido sube el AUC en apenas

0,006, con un intervalo de la diferencia de −0,07 a 0,09, así que agregar las zonas no lo mejora, posiblemente porque lo que agregaban a D ya lo cubren A, B y C.

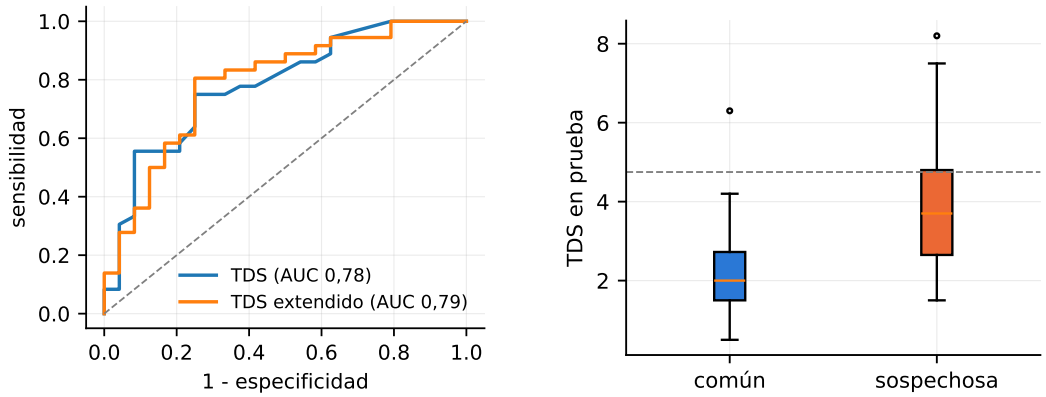


Figura 4: Curvas ROC del TDS y del TDS extendido (izquierda) y TDS de las imágenes de prueba según el grupo, con el umbral clínico punteado (derecha).

4. Conclusiones

La segmentación cumplió su objetivo, con un Dice medio de 0,916 en prueba y fallas en sólo 4 de las 200 imágenes. La compresión quedó caracterizada, aunque no se llegó al objetivo de máxima de repetir el algoritmo sobre imágenes comprimidas.

La hipótesis 1 no se confirmó. Quitar los pelos con un cierre no mejoró la segmentación y, en entrenamiento, resultó peor que el filtro de mediana. Una posible razón, que no comprobamos, es que el suavizado gaussiano previo a la segmentación ya atenúa buena parte de los pelos.

El criterio D estimado con un solo atributo de textura no reproduce al dermatólogo y, en prueba, tampoco separa los grupos con seguridad. El AUC cayó de 0,73 en entrenamiento a 0,60 en prueba, y eso muestra por qué convenía reservar ese conjunto. Mirar la lesión por zonas fue más prometedor, porque la saturación de periferia menos centro se mantuvo en un AUC de 0,71, pero con 60 imágenes el intervalo es ancho y no alcanza para distinguirla del brillo de la lesión ni para afirmar que mejore a D.

A, B y C se pudieron medir, aunque sólo en parte como el dermatólogo. A coincide con él de forma aceptable ($\kappa = 0{,}38$) y falla cuando la asimetría está en el color y no en la forma, C coincide poco ($\kappa = 0{,}24$) y B separa poco porque en PH2 los nevos comunes tienen el borde más nítido. La circularidad, que no es parte de la regla, separó casi igual que A, y es una buena candidata a término extra del TDS.

La hipótesis 2 se confirmó sólo en parte. El TDS automático separa las lesiones sospechosas de los nevos comunes (AUC 0,78), pero agregarle las zonas no lo mejora. Con el umbral de Youden su sensibilidad es 0,78 y su especificidad 0,58, lejos del 91 % y el 96 % de Kasmi y Mokrani [8], aunque ese trabajo separa melanomas de lesiones benignas, y acá los nevos atípicos cuentan como sospechosos y su TDS se parece más al de los nevos comunes. Con el umbral clínico, el programa reconoce 8 de los 12 melanomas de prueba.

Las limitaciones principales son la base, chica y de un solo equipo y un solo hospital, y el conjunto de prueba, que tiene sólo 60 imágenes y 9 con pelos. Además, D es una adaptación que cuenta estructuras con un número global, la referencia del rojo sale de una sola zona y la segmentación sobre el canal azul pierde justamente las zonas azul grisáceas que se asocian al melanoma, aunque con la máscara manual los criterios no mejoraron.

Como mejoras, proponemos segmentar con información de color sin sumar fallas en el resto de las imágenes, medir cada estructura de D con su propio detector en lugar de un único número, repetir el algoritmo sobre imágenes comprimidas y validarlo con otra base de imágenes.

Referencias

[1] Franz Nachbar et al. «The ABCD rule of dermatoscopy: High prospective value in the diagnosis of doubtful melanocytic skin lesions». En: *Journal of the American Academy of Dermatology* 30.4 (1994), págs. 551-559. DOI: 10.1016/S0190-9622(94)70061-3.

[2] Tim Lee et al. «DullRazor: A software approach to hair removal from images». En: *Computers in Biology and Medicine* 27.6 (1997), págs. 533-543. DOI: 10.1016/S0010-4825(97)00020-6.

[3] Robert M. Haralick, K. Shanmugam e Its'hak Dinstein. «Textural features for image classification». En: *IEEE Transactions on Systems, Man, and Cybernetics* SMC-3.6 (1973), págs. 610-621. DOI: 10.1109/TSMC.1973.4309314.

[4] Ralph P. Braun y Katrin Kerl. *Dermoscopic structures*. Dermoscopedia. URL: https://dermoscopedia.org/Dermoscopic_structures (visitado 05-11-2026).

[5] Gregory K. Wallace. «The JPEG still picture compression standard». En: *Communications of the ACM* 34.4 (1991), págs. 30-44. DOI: 10.1145/103085.103089.

[6] M. Emre Celebi et al. «A methodological approach to the classification of dermoscopy images». En: *Computerized Medical Imaging and Graphics* 31.6 (2007), págs. 362-373. DOI: 10.1016/j.compmedimag.2007.01.003.

[7] Andre Esteva et al. «Dermatologist-level classification of skin cancer with deep neural networks». En: *Nature* 542 (2017), págs. 115-118. DOI: 10.1038/nature21056.

[8] Reda Kasmi y Karim Mokrani. «Classification of malignant melanoma and benign skin lesions: Implementation of automatic ABCD rule». En: *IET Image Processing* 10.6 (2016), págs. 448-455. DOI: 10.1049/iet-ipr.2015.0385.

[9] Soumia Oukil et al. «Automatic segmentation and melanoma detection based on color and texture features in dermoscopic images». En: *Skin Research and Technology* 28.2 (2022), págs. 203-211. DOI: 10.1111/srt.13111.

[10] Teresa Mendonça et al. «PH2: A dermoscopic image database for research and benchmarking». En: *35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2013, págs. 5437-5440. DOI: 10.1109/EMBC.2013.6610779.

[11] Giuseppe Argenziano et al. «Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the Internet». En: *Journal of the American Academy of Dermatology* 48.5 (2003), págs. 679-693. DOI: 10.1067/mjd.2003.281.

[12] Alexandru Telea. «An image inpainting technique based on the fast marching method». En: *Journal of Graphics Tools* 9.1 (2004), págs. 23-34. DOI: 10.1080/10867651.2004.10487596.

[13] Zhou Wang et al. «Image quality assessment: From error visibility to structural similarity». En: *IEEE Transactions on Image Processing* 13.4 (2004), págs. 600-612. DOI: 10.1109/TIP.2003.819861.

[14] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». En: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), págs. 62-66. DOI: 10.1109/TSMC.1979.4310076.

[15] Tony F. Chan y Luminita A. Vese. «Active contours without edges». En: *IEEE Transactions on Image Processing* 10.2 (2001), págs. 266-277. DOI: 10.1109/83.902291.

[16] W. J. Youden. «Index for rating diagnostic tests». En: *Cancer* 3.1 (1950), págs. 32-35.

[17] Jacob Cohen. «A coefficient of agreement for nominal scales». En: *Educational and Psychological Measurement* 20.1 (1960), págs. 37-46. DOI: 10.1177/001316446002000104.

[18] J. Richard Landis y Gary G. Koch. «The measurement of observer agreement for categorical data». En: *Biometrics* 33.1 (1977), págs. 159-174. DOI: 10.2307/2529310.

A. Anexo

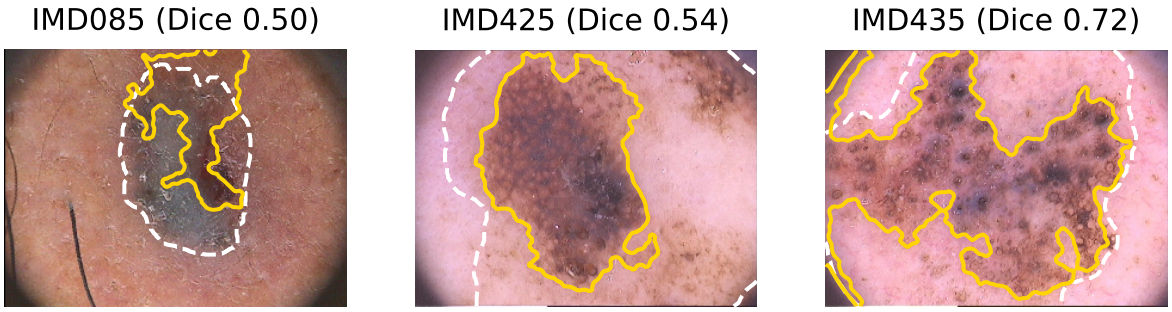


Figura 5: Las imágenes de entrenamiento con peor Dice del método elegido. En blanco punteado, la máscara de PH2; en amarillo, la automática.

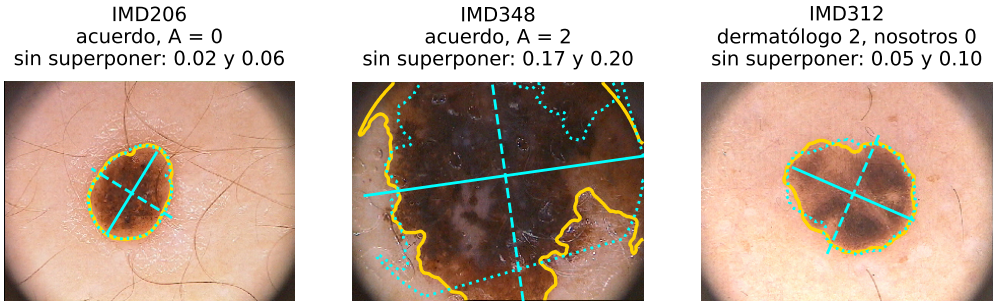


Figura 6: Ejes de simetría y reflejo de la máscara sobre el eje mayor en tres lesiones de entrenamiento. En IMD312 la forma es casi simétrica, pero el pigmento se concentra de un lado, y por eso el dermatólogo puso $A = 2$.

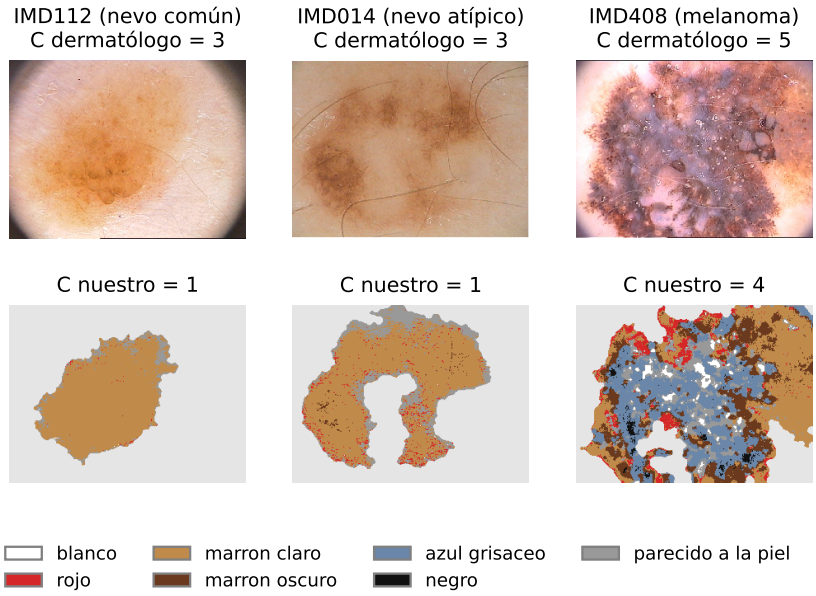


Figura 7: Mapa de colores de la lesión con más colores anotados de cada diagnóstico. En los dos nevos casi todo queda como marrón claro, y en el melanoma el blanco y el negro no llegan al 5 % de la lesión.

Color	Zonas	H	S	V
Blanco	2	0,630	0,152	0,541
Rojo	1	0,976	0,212	0,492
Marrón claro	12	0,083	0,249	0,452
Marrón oscuro	13	0,060	0,242	0,300
Azul grisáceo	6	0,965	0,069	0,285
Negro	3	0,038	0,065	0,254

Tabla 5: Referencias de color en HSV, con la imagen dividida por el color de la piel, que queda en gris medio ($V = 0{,}5$). Cada una es la mediana de las zonas de entrenamiento de ese color.

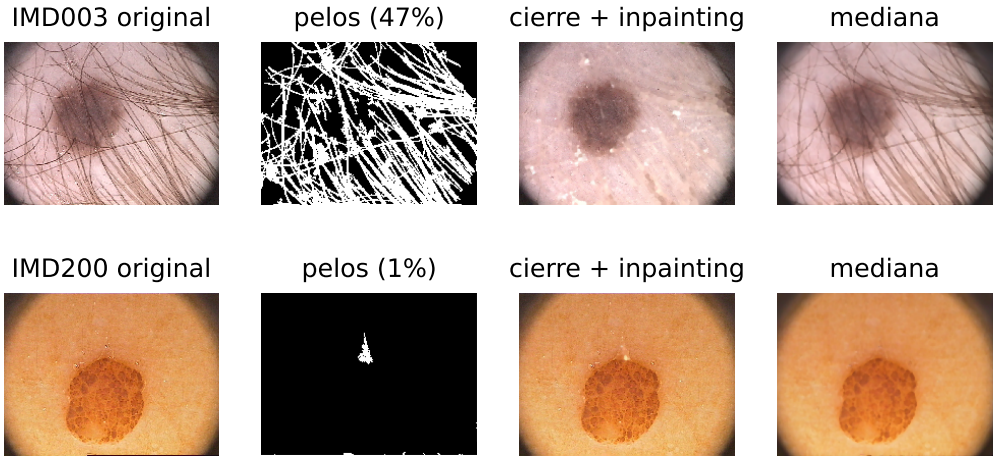


Figura 8: Remoción de pelos en una imagen con muchos pelos (IMD003) y en una sin pelos con red de pigmento (IMD200). Se muestran la original, los pelos detectados, el cierre con *inpainting* y el filtro de mediana.

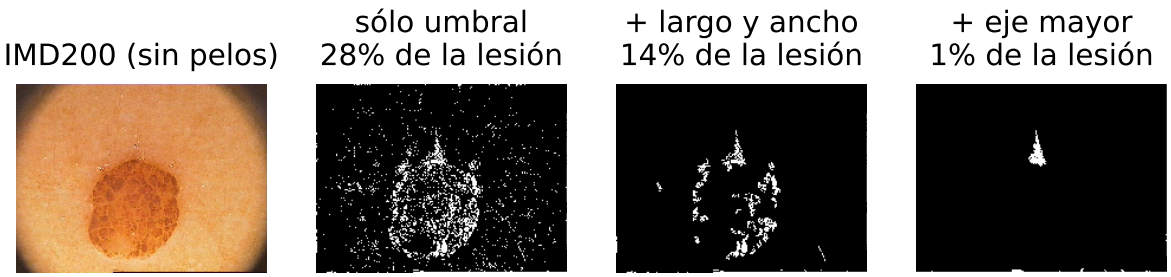


Figura 9: Efecto del filtro de forma en la detección de pelos sobre IMD200, que no tiene pelos. Se comparan los candidatos del *black-hat* (sólo umbral), el filtro por largo y ancho y el filtro completo con eje mayor. Se indica la fracción de la lesión marcada como pelo.

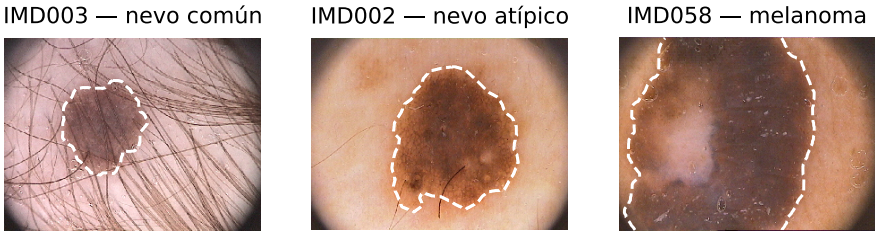


Figura 10: Un ejemplo de cada diagnóstico de PH2 con el contorno de su máscara manual.

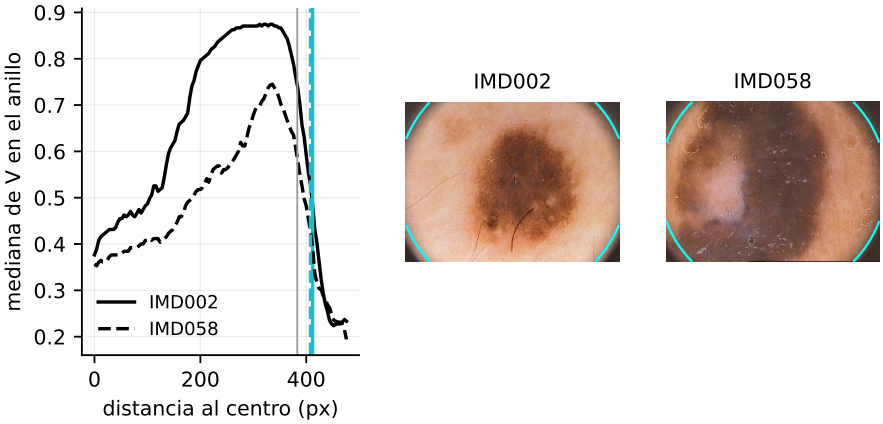


Figura 11: Detección del viñeteo. A la izquierda, la mediana del brillo V en anillos concéntricos para una imagen típica (IMD002) y una con la lesión tocando el borde (IMD058), con el radio detectado en líneas verticales. A la derecha, el límite de la zona válida sobre ambas imágenes.

Etapa	Parámetro	Valor
Viñeta	Anillo / umbral / radio mínimo	4 px / 0,6 del máximo / 0,8 semidiagonal
Pelos	Elemento estructurante	segmento de 21 px, 12 orientaciones
	Umbral del *black-hat*	0,10
	Forma (largo / ancho / eje mayor)	≥ 60 px / ≤ 8 px / ≥ 80 px
	Reconstrucción	*inpainting* de Telea, radio 5 px
Comparación	Filtro de mediana	9×9 por canal

Tabla 6: Parámetros del mejoramiento (módulo M1), elegidos con el conjunto de entrenamiento.

Calidad	Tasa	PSNR (dB)	PSNR lesión (dB)	SSIM	ΔE lesión
95	8,2	41,1	40,7	0,97	1,9
75	23,7	35,9	34,9	0,89	2,7
50	39,7	34,5	33,4	0,85	3,2
25	67,7	32,8	31,7	0,80	3,9
10	121,8	29,6	28,7	0,70	5,8

Tabla 7: Compresión JPEG, con la mediana de cada métrica sobre las 140 imágenes de entrenamiento.



Figura 12: Detalle de la red de pigmento de IMD200 en la imagen original y comprimida a calidades 75, 25 y 10 (entre paréntesis, la tasa de compresión).

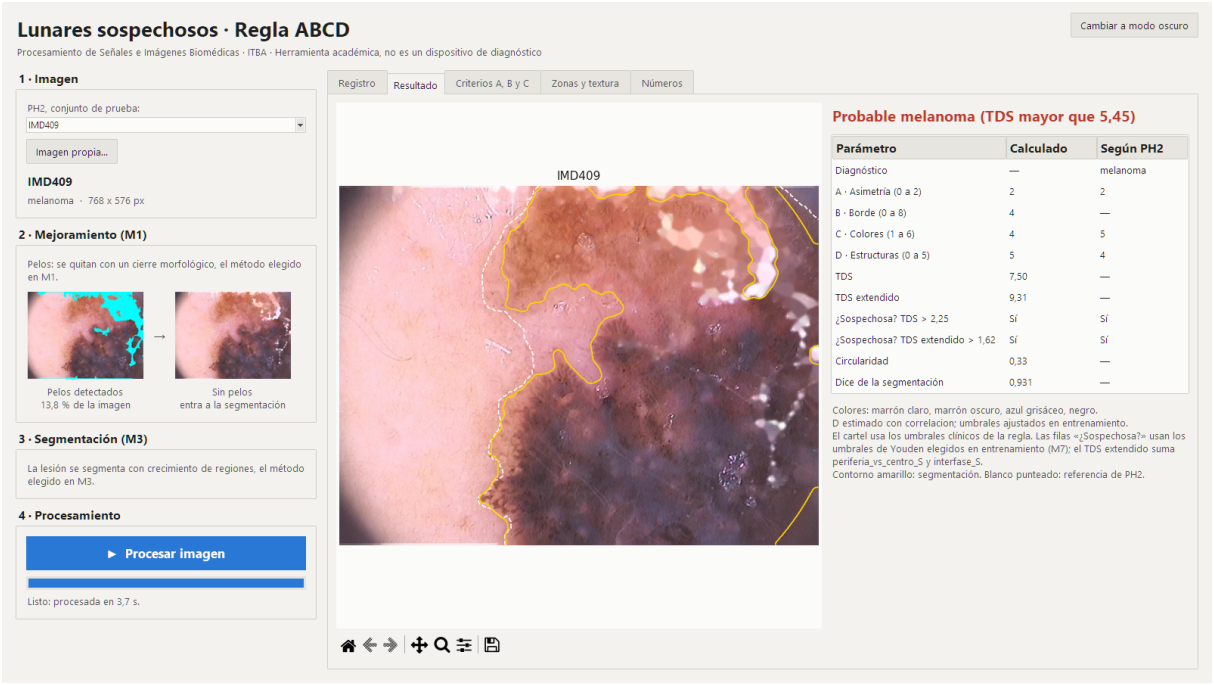


Figura 13: Interfaz gráfica con un melanoma de prueba (IMD409). A la izquierda, los pasos del algoritmo, y a la derecha, la segmentación y la tabla con los criterios calculados junto a los del dermatólogo.

Carpeta	Archivo	Contenido
raíz	`main.py`	Verifica módulos, procesa imágenes y genera resultados
M0	`carga_de_datos.py`	Lectura de PH2, alcance y partición
M1	`mejoramiento.py`	Viñeta y remoción de pelos
M2	`compresion.py`	JPEG, tasa de compresión, PSNR y SSIM
M3	`segmentacion.py`	Métodos de segmentación, posprocesamiento y Dice
M4	`criterios_abc.py`	Asimetría, borde, colores y circularidad
M5	`textura_criterio_d.py`	GLCM y criterio D adaptado
M6	`zonas_y_mapas.py`	Zonas de la lesión y mapas de características
M7	`clasificacion_resultados.py`	TDS, umbrales, métricas y figuras finales
herramientas	`*.py`	Recorrido completo, verificación y gráficos
interfaz	`app.py`	Interfaz gráfica

Tabla 8: Archivos de Python del repositorio. Cada módulo Mn está en `modulos/m`n`_.../`.