Instituto Tecnológico de Buenos Aires

16.63 Procesamiento de Señales e Imágenes Biomédicas
2026 — Segundo cuatrimestre

Comisión BIO

Detección de lunares sospechosos mediante imágenes dermatoscópicas

Trabajo Práctico de Imágenes (TPI)

PSIB2026Q2-TPI-Grupo02-CassanoNieto DElia Ortega

Grupo 2

Integrante	Legajo
Cassano Nieto, Facundo Tomás	65555
D'Elía, Lucas Valentín	65414
Ortega, Facundo	65560

Docentes: Roberto Sebastián Tomás, Lucila Capurro,
Francisco Joaquín Tassara y Victoria Reppucci

5 de noviembre de 2026

Resumen

El melanoma se parece a un lunar común en sus comienzos, y la regla dermatoscópica ABCD ayuda a distinguirlos a partir de la asimetría, el borde, los colores y las estructuras de la lesión. En este trabajo se desarrolló un algoritmo que mide esos criterios en las 200 imágenes de la base PH2 con procesamiento clásico de imágenes, sin entrenar un clasificador. Las imágenes se separaron en 140 de entrenamiento y 60 de prueba, y todo parámetro se fijó con las primeras. La segmentación por crecimiento de regiones alcanzó un Dice medio de 0,916 en prueba. Quitar los pelos con un cierre morfológico no mejoró la segmentación, por lo que la primera hipótesis no se confirmó. El criterio D, estimado detectando cada estructura por separado, separó en prueba las lesiones sospechosas de los lunares comunes con un AUC de 0,67 (IC 95 %, 0,54 a 0,80), y la diferencia de saturación entre la periferia y el centro de la lesión, con 0,71 (0,58 a 0,84). El TDS automático separó las lesiones sospechosas de los nevos comunes con un AUC de 0,77 (0,65 a 0,89) y, con un umbral elegido en entrenamiento, una sensibilidad de 0,69 y una especificidad de 0,88. Agregarle términos de zonas no mejoró esa separación de forma significativa, por lo que la segunda hipótesis se confirmó sólo en parte.

Índice

1. Introducción **2**
- 1.1. Problemática . . . 2
- 1.2. Marco teórico . . . 2
- 1.3. Estado del arte . . . 2
- 1.4. Pregunta, objetivos e hipótesis . . . 3

2. Materiales y métodos **3**
- 2.1. Base de datos y alcance . . . 3
- 2.2. Esquema del algoritmo . . . 4
- 2.3. Pre-procesamiento . . . 4
- 2.4. Segmentación . . . 5
- 2.5. Criterios A, B y C . . . 5
- 2.6. Textura y criterio D adaptado . . . 6
- 2.7. Zonas de la lesión y mapas de características . . . 6
- 2.8. Clasificación . . . 7
- 2.9. Evaluación . . . 7
- 2.10. Interfaz gráfica y código . . . 7

3. Resultados **7**
- 3.1. Pre-procesamiento . . . 7
- 3.2. Segmentación . . . 8
- 3.3. Criterios y comparación con el dermatólogo . . . 8
- 3.4. Zonas y mapas de características . . . 9
- 3.5. Clasificación . . . 9

4. Conclusiones **10**

Referencias **11**

A. Anexo **12**

1. Introducción

1.1. Problemática

El melanoma es un cáncer de piel cuyo pronóstico depende de cuán temprano se lo detecte. Al comienzo se parece mucho a un lunar común, y el dermatólogo lo evalúa con el dermatoscopio, una lente de aumento con iluminación propia. Para hacerlo de forma sistemática usa la regla ABCD, que puntúa la asimetría (A, de 0 a 2 según en cuántos ejes es asimétrica la lesión), el borde (B, de 0 a 8 según en cuántos sectores el pigmento termina de forma abrupta), los colores (C, de 1 a 6) y las estructuras diferenciales, como la red de pigmento o los glóbulos (D, de 1 a 5), y los combina en el puntaje dermatoscópico total

$$\mathrm{TDS} = 1{,}3\,A + 0{,}1\,B + 0{,}5\,C + 0{,}5\,D. \tag{1}$$

Un TDS menor a 4,75 indica una lesión benigna; entre 4,75 y 5,45, una lesión sospechosa, y mayor a 5,45, una lesión probablemente maligna [1]. La evaluación es visual y su precisión depende de la experiencia de quien la hace.

1.2. Marco teórico

La imagen dermatoscópica es una imagen RGB en la que el color tiene valor diagnóstico, porque depende de la profundidad del pigmento. Los marrones y el negro indican melanina en la epidermis, el azul grisáceo indica melanina en la dermis y el blanco, zonas de regresión. Por eso conviene trabajar en el espacio HSV, que separa el matiz (H) y la saturación (S) del brillo (V). Antes de medir ese color hay que lidiar con los artefactos de la imagen. La lente circular deja esquinas oscuras (viñeteo), y los pelos que cruzan la lesión, que se ven como líneas oscuras y finas, desplazan el borde segmentado y agregan un color que no le pertenece. Estos pueden quitarse con un cierre morfológico con un elemento estructurante más ancho que un pelo y más chico que la lesión, idea en la que se basa DullRazor [2].

Además del color, la regla mira las estructuras diferenciales, que son patrones que se repiten dentro de la lesión y que pueden describirse como textura. Una forma clásica de medirla es la matriz de co-ocurrencia de niveles de gris (GLCM), que cuenta con qué frecuencia aparecen juntos dos niveles de gris a una distancia y dirección dadas, y de la que se obtienen atributos como la entropía, el contraste y la correlación [3]. Sin embargo, estas estructuras no se reparten al azar dentro de la lesión. Las estrías, por ejemplo, aparecen de forma focal y asimétrica en la periferia, y las áreas claras sin estructura en la periferia también se asocian al melanoma [4]. Un único número calculado sobre toda la lesión puede entonces promediar zonas que se comportan distinto. La interfase con la piel importa por otro motivo, ya que el criterio B puntúa justamente los sectores donde el pigmento termina de golpe [1], y comparar la lesión con la piel vecina permite medir ese cambio de forma continua.

Todo este detalle puede perderse al guardar o transmitir las imágenes. JPEG, el formato con pérdida más usado para fotografías [5], guarda el color a la mitad de resolución, divide la imagen en bloques de 8×8, les aplica la transformada discreta del coseno y cuantiza los coeficientes según un parámetro de calidad (de 1 a 100), descartando sobre todo las frecuencias altas. Lo que se pierde es justamente el detalle fino y parte del color que usa la regla ABCD.

1.3. Estado del arte

Los sistemas de diagnóstico asistido segmentan la lesión, miden descriptores de forma, color y textura y los entregan a un clasificador [6]. Las redes neuronales convolucionales ya alcanzan un desempeño comparable al de los dermatólogos [7], pero no muestran en qué se basa cada decisión, y la mayoría sólo informa el diagnóstico final, por lo que no permiten comprobar si cada criterio se mide bien.

Medir la regla ABCD de forma automática tampoco es una idea nueva. Un trabajo la implementó sobre 200 imágenes dermatoscópicas, 80 de melanomas y 120 de lesiones benignas, y obtuvo una sensibilidad de 91,25 % y una especificidad de 95,83 % [8]. Otro, sobre PH2, combinó color y textura con una máquina de vectores de soporte y separó melanomas de nevos con una sensibilidad de 99,25 % y una especificidad de 99,58 % [9]. Como referencia humana, el trabajo original de la regla informa 92,8 % y 90,3 % [1]. Estos valores no se pueden comparar directamente con los nuestros, porque ninguno de esos trabajos separa nevos comunes de nevos atípicos y melanomas, que es la pregunta de este trabajo.

Lo que buscamos aportar es una medición que se pueda revisar paso a paso. Cada criterio se compara con el dermatólogo, los mapas muestran en qué parte de la lesión está la información y el algoritmo final no entrena ningún clasificador, sino que usa la fórmula de la regla.

1.4. Pregunta, objetivos e hipótesis

Pregunta y objetivo general. ¿Pueden medirse automáticamente los criterios de la regla ABCD, complementarse con descriptores por zona de la lesión y distinguir lesiones sospechosas de lunares comunes? Para responderlo, buscamos desarrollar un algoritmo que haga esas mediciones y estime si la lesión es sospechosa, con una interfaz gráfica que muestre cada etapa.

Objetivos específicos. (1) Quitar los artefactos (viñeteo y pelos) y medir su efecto en la segmentación; (2) caracterizar la pérdida por compresión JPEG; (3) segmentar la lesión y validar contra la máscara manual (Dice); (4) medir A, B y C y comparar A y C con el dermatólogo (κ de Cohen); (5) estimar un criterio D adaptado detectando cada estructura en la imagen; (6) construir mapas de características y descriptores por zona y evaluar si mejoran la clasificación al agregarse al TDS; (7) clasificar con el TDS y medir sensibilidad, especificidad y AUC en un conjunto de prueba.

Hipótesis. (H1) Quitar los pelos con un cierre morfológico mejora la segmentación de las imágenes con pelos respecto de no quitarlos y de un filtro de mediana. (H2) El TDS automático separa las lesiones sospechosas de los nevos comunes, y agregarle términos de textura y de zonas mejora esa separación. Como objetivo de máxima, se evalúa además si el desempeño se mantiene sobre imágenes comprimidas con JPEG.

2. Materiales y métodos

2.1. Base de datos y alcance

Se usa la base PH2 [10], del Hospital Pedro Hispano (Portugal), con 200 imágenes dermatoscópicas RGB de 8 bits por canal adquiridas con el mismo equipo, que incluyen 80 nevos comunes, 80 nevos atípicos y 40 melanomas (figura 7 del anexo). Hay 24 tamaños de imagen distintos, así que ninguna etapa supone un tamaño fijo. La lesión ocupa entre el 3 % y el 98 % de la imagen (mediana 23 %) y en 50 imágenes toca el borde. Cada imagen trae la máscara de la lesión dibujada a mano y la evaluación de un dermatólogo (diagnóstico, asimetría, colores y estructuras), lo que permite validar cada etapa por separado.

Se considera *sospechosa* toda lesión con diagnóstico de nevo atípico o melanoma (120 imágenes) y *no sospechosa* a los nevos comunes (80), porque la pregunta es distinguir las lesiones que ameritan control de los lunares comunes.

La regla original define D como la cantidad de estructuras diferenciales presentes entre cinco, que son la red de pigmento, las áreas sin estructura, las estrías, los puntos y los glóbulos, y por eso va de 1 a 5 [1]. PH2 no anota exactamente esas estructuras, ya que trae los puntos y los glóbulos juntos, no anota las áreas sin estructura y, en cambio, anota las áreas de regresión y el velo azul-blanquecino. Por eso no podemos medir el D original y usamos un *D adaptado*, que

cuenta cuántas de las cinco estructuras de PH2 marcó el dermatólogo (red de pigmento atípica, puntos o glóbulos, estrías, regresión y velo) y va de 0 a 5. La red se cuenta sólo cuando es atípica porque en PH2 todas las lesiones tienen red, y la atípica es la que se asocia al melanoma [11]. Con esta definición, el D medio es 0,65 en los nevos comunes, 1,79 en los atípicos y 3,12 en los melanomas.

Las imágenes se dividieron en entrenamiento (140, con 56 nevos comunes, 56 atípicos y 28 melanomas) y prueba (60, con 24, 24 y 12), de forma estratificada y con semilla fija. Todos los umbrales y parámetros se eligen únicamente con entrenamiento, y prueba se usa sólo para las métricas finales.

2.2. Esquema del algoritmo

La figura 1 muestra el recorrido de una imagen por el algoritmo. La compresión (M2) no forma parte de ese recorrido, y se estudia aparte para saber qué se pierde al guardar las imágenes en JPEG.

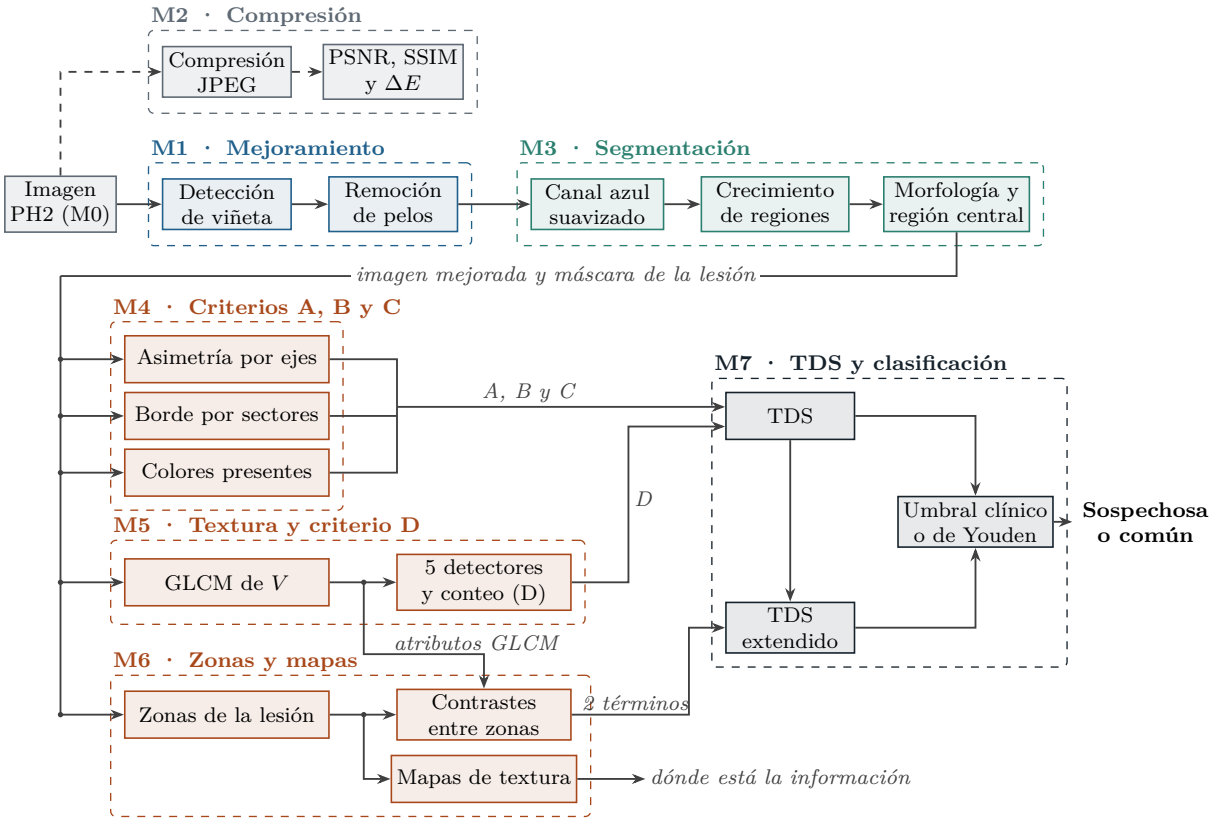


Figura 1: Diagrama de bloques del algoritmo. Los recuadros agrupan los bloques de cada módulo del repositorio, y la línea punteada marca el estudio de compresión, que queda fuera del recorrido principal.

2.3. Pre-procesamiento

Análisis exploratorio. Con las imágenes de entrenamiento se eligió el canal con más contraste entre lesión y piel. En cada imagen se tomaron 2000 píxeles de cada una y se calculó el área bajo la curva ROC (AUC) de separarlos con un umbral sobre cada canal (R, G, B, H, S, V, L de Lab y gris).

Viñeteo. Las esquinas oscuras se excluyen con una máscara de píxeles válidos. Un umbral fijo de brillo no sirve, porque el que captura todas las esquinas captura también zonas oscuras de 124 de las 140 lesiones de entrenamiento. En cambio se aprovecha que la viñeta es circular y

centrada, y que la mediana de V en un anillo no se ve afectada por una lesión que ocupa sólo una parte de él. La viñeta empieza en el primer anillo cuya mediana cae por debajo del 60 % del anillo más brillante, y nunca antes del 80 % de la semidiagonal, para no cortar lesiones muy grandes (figura 8 del anexo).

Pelos. Se detectan con un cierre morfológico del gris con segmentos de 21 píxeles en 12 orientaciones. Son candidatos los píxeles donde la diferencia entre el cierre y la imagen (*black-hat*) supera 0,10 [2]. Como la red de pigmento también es oscura y fina, sólo se conservan las regiones largas, finas y alargadas (tabla 5 del anexo). Esos píxeles se reconstruyen por *inpainting* [12] y el resto de la imagen no se modifica. Para la hipótesis 1 se compara con no quitar los pelos y con un filtro de mediana de 9×9 por canal.

Compresión. Cada imagen de entrenamiento se comprimió con JPEG a calidades 95, 75, 50, 25 y 10, y se midieron la tasa de compresión, el PSNR (en toda la imagen y dentro de la lesión), el SSIM [13] y la diferencia de color media dentro de la lesión en Lab (ΔE, CIE76), para la que 2,3 es el umbral aproximado de percepción. Cada calidad se resume con la mediana de las 140 imágenes.

2.4. Segmentación

Se segmenta sobre el canal azul, que es el que mejor separa la lesión de la piel, suavizado con un filtro gaussiano. Se comparan cinco métodos, que son el umbral de Otsu [14], el crecimiento de regiones, *watershed* con marcadores, k-means sobre el color en Lab y el modelo de Chan-Vese [15]. A la salida de todos se le aplica una apertura para borrar islas, un cierre para rellenar mellas del borde, la selección de la región que contiene el centro de la imagen y el relleno de huecos.

El crecimiento de regiones arranca del píxel más oscuro de un recuadro central y agrega vecinos mientras su brillo quede más cerca del de la lesión que del de la piel de esa imagen.

Los parámetros de cada método se eligieron con una grilla sobre las 140 imágenes de entrenamiento, tomando la combinación de mayor Dice medio. Consideramos mal segmentada a una imagen con Dice menor a 0,7. El método elegido fue el crecimiento de regiones, con $\sigma = 4\,\text{px}$, tolerancia 0,5, apertura de 3 px y cierre de 10 px (la comparación se muestra en la sección 3.2).

2.5. Criterios A, B y C

Los tres criterios se miden sobre la máscara de M3, que es la que el algoritmo tiene con una imagen nueva, y sus umbrales se eligen con las 140 imágenes de entrenamiento.

Asimetría. Se calculan el centroide y los dos ejes principales de la máscara (con los momentos de segundo orden), se la refleja sobre cada eje y se mide la fracción de la lesión que queda sin superponerse con su reflejo. Un eje es asimétrico si esa fracción supera 0,11, el umbral que da el mayor κ con la asimetría del dermatólogo, y A es la cantidad de ejes asimétricos (0 a 2).

Borde. El contorno se divide en 8 sectores de 45°, contados desde el eje mayor para que el resultado no dependa de cómo esté girada la foto. En cada sector se mide el gradiente de V con el filtro de Sobel, sobre la imagen suavizada ($\sigma = 1\,\text{px}$) y buscando el máximo hasta 5 px del contorno. Un sector es abrupto si su gradiente supera 0,0513, y B es la cantidad de sectores abruptos (0 a 8). Como PH2 no anota B, ese umbral se eligió como el que mejor separa las lesiones sospechosas de los nevos comunes en entrenamiento.

Color. El mismo color cambia de una foto a otra con la luz y el tono de piel, así que antes de comparar, la imagen se divide por el color de la piel de esa foto, tomado de un anillo de 10 a 30 px alrededor de la lesión. Cada píxel se asigna al color de referencia más cercano en el cono HSV, o a la piel si se parece más a ella. Las referencias son la mediana de las zonas de cada color que PH2 marca en las imágenes de entrenamiento. PH2 no trae zonas rojas, así que marcamos a mano las de las imágenes de entrenamiento con rojo, y sólo en una se vio una zona claramente roja. Un color está presente si ocupa al menos el 5 % de la lesión, el mínimo que da el mayor κ

con el dermatólogo, y C es la cantidad de colores presentes. Se calcula además la circularidad, 4π área/perímetro^2, que vale 1 para un círculo y menos cuanto más irregular es la forma.

2.6. Textura y criterio D adaptado

Se calcula la GLCM sobre V usando sólo pares de píxeles dentro de la lesión, promediada en las cuatro direcciones, y de ella se obtienen la energía, la entropía, el contraste, el IDM, la correlación, el *cluster shade* y el *cluster prominence* [3]. Se usan 32 niveles de gris, que conservan detalle sin que la matriz de 32×32 quede casi vacía, y distancia 1, que compara píxeles vecinos, la escala de las líneas finas de la red de pigmento. La textura se mide en V, como se propuso en el anteproyecto, y no se comparó con otros canales.

Lo que se estima es el D adaptado de la sección 2.1, y se estima como lo cuenta el dermatólogo, buscando cada estructura por separado con una medida pensada a partir de cómo se ve. La red atípica tiene líneas de distinto grosor y zonas sin red, y como la red se reconoce por su textura [16], se mide cuánto varía el contraste local dentro de la lesión (desvío sobre media del mapa de contraste de M6). Los puntos y glóbulos son manchas oscuras y redondeadas, y se cuentan por unidad de área [17], con un *black-hat* con un disco de 6 px seguido de una apertura con un disco de 2 px que borra las líneas finas de la red. Las estrías son líneas oscuras que salen radialmente del borde y se detectan como valles orientados [18]. Con la matriz Hessiana se marcan las líneas oscuras y su dirección, y se mide qué parte de un anillo de 15 px a cada lado del borde tiene líneas marcadas que apuntan hacia afuera. La regresión y el velo se reconocen por el color [19, 20]. La regresión es más clara y menos saturada que la piel, y como en el canal azul se parece a ella y M3 suele dejarla fuera de la máscara, se busca en toda la envolvente convexa de la lesión. El velo es la única estructura azulada, y se mide con el percentil 90 de $B - R$ dentro de la lesión. Una estructura se considera presente si su medida supera un umbral, y el D estimado es la cantidad de estructuras detectadas. Cada umbral se elige en entrenamiento con el índice de Youden [21], $J = \text{sensibilidad} + \text{especificidad} - 1$, donde la sensibilidad es la fracción de imágenes con la estructura que se detectan y la especificidad, la fracción de imágenes sin ella que quedan sin detectar. Se prueban todos los umbrales posibles y se elige el de mayor J, que es el que mejor equilibra no perder estructuras y no inventarlas.

2.7. Zonas de la lesión y mapas de características

Siguiendo la devolución del anteproyecto, se mira por separado el centro, la periferia y la interfase con la piel. Las zonas se definen con la transformada de distancia al borde de la máscara (figura 2). El centro es donde esa distancia supera la mitad de su máximo y la periferia es el resto de la lesión. Las interfases interna y externa son anillos de 15 px a cada lado del borde, y la externa no incluye las esquinas de la viñeta. Los 15 px salen del perfil de brillo alrededor del borde, que en entrenamiento alcanza el 90 % del brillo de la piel a 12 px en la mediana y a 19 px en el percentil 75.

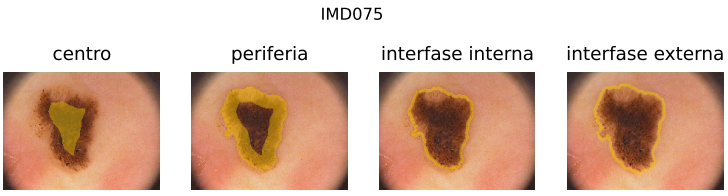


Figura 2: Las cuatro zonas sobre una lesión de tamaño típico de entrenamiento.

En cada zona se miden el color medio en HSV y los atributos GLCM de V. A partir de ellos se calculan 10 contrastes, restando periferia menos centro y piel menos lesión para H, S, V, contraste y entropía. El signo importa, porque el TDS extendido suma cada término y uno que

baje en las sospechosas lo empeoraría. Además, para ver dónde está la información se calculan mapas de un atributo GLCM en ventanas de 31 px cada 8 px.

2.8. Clasificación

Una lesión se clasifica como sospechosa si su TDS automático (ec. 1) supera un umbral. Se comparan el umbral clínico (4,75) con el que maximiza el índice de Youden en entrenamiento, en este caso para detectar lesiones sospechosas. La comparación importa porque el umbral clínico se fijó para el TDS original, y como nuestro D se mide distinto, no es seguro que ese umbral funcione igual. Para la hipótesis 2 se define un TDS extendido sumando al TDS los términos de textura y de zonas elegidos en entrenamiento, estandarizados con la media y el desvío de entrenamiento, y se vuelve a elegir el umbral. Los dos términos se eligieron en entrenamiento, antes de mirar prueba, y son la saturación de periferia menos centro (AUC 0,76) y la de piel menos lesión (AUC 0,69). No se eligió el contraste de V entre piel y lesión, aunque su AUC es 0,74, porque se correlaciona con el primero ($\rho = 0{,}68$), mientras que los dos elegidos casi no se correlacionan entre sí ($\rho = 0{,}08$). Aquí ρ es la correlación de Spearman, que compara cómo ordenan las imágenes dos medidas y vale 1 si las ordenan igual, 0 si no tienen relación y -1 si las ordenan al revés.

2.9. Evaluación

La segmentación se compara con la máscara de PH2 mediante el coeficiente de Dice, y A y C con el dermatólogo mediante el κ de Cohen [22], cuyos valores entre 0,41 y 0,60 indican un acuerdo moderado [23]. La clasificación se mide con la sensibilidad, la especificidad y el AUC.

Para H1 se usa la prueba de Wilcoxon de rangos con signo, porque el Dice se mide de a pares en las mismas imágenes. El intervalo de confianza del 95 % del AUC se calcula con un *bootstrap* de percentiles, sorteando 2000 veces con reposición dentro de cada grupo. Para comparar dos AUC se usa el mismo sorteo sobre las mismas imágenes, y la diferencia se considera significativa si su intervalo no incluye al cero.

2.10. Interfaz gráfica y código

La interfaz es una aplicación de escritorio en tkinter, que se abre con `python interfaz/app.py`. Permite elegir una imagen de prueba de PH2 o una propia y el método para quitar los pelos, y muestra la máscara de pelos, el contorno automático junto al de referencia, las zonas, los mapas de textura y de colores, los ejes de simetría y el borde por sector. También da los criterios A, B, C y D, las estructuras detectadas, el TDS, el TDS extendido y la clasificación, junto a lo que anotó el dermatólogo cuando la imagen es de PH2. Sólo llama a las funciones de los módulos, de modo que lo que se ve es lo mismo que se evalúa.

El código está en `https://github.com/facortega/PSIB2026Q2-TPI-Grupo02-CassanoNieto-DElia-Ortega`. Cada módulo tiene un archivo `.py` con las funciones y un cuaderno `.ipynb` con las pruebas, las figuras y la discusión. La tabla 7 del anexo detalla el contenido de cada archivo.

3. Resultados

3.1. Pre-procesamiento

Canal de trabajo. El canal azul es el que mejor separa la lesión de la piel en entrenamiento (AUC medio 0,976, seguido por G con 0,965), lo que es coherente con que la melanina absorbe más la luz azul que la roja. El canal V, propuesto en el anteproyecto, queda entre los peores (0,902), porque $V = \max(R, G, B)$ y en la piel y la lesión domina el rojo. Por eso la segmentación

se hace sobre B. El borde, en cambio, se mide sobre V, porque lo que importa ahí es cuánto cambia el brillo y no separar la lesión de la piel.

Viñeteo y pelos. Con el perfil radial, sólo 4 de las 200 imágenes pierden más del 2 % de la lesión por quedar fuera de la zona válida (máximo 5,9 %). En cuanto a los pelos, el cierre reconstruye sólo sus píxeles, mientras que la mediana suaviza toda la imagen, incluidas la red y el borde (figura 5 del anexo). El filtro de forma es lo que evita borrar la red. En IMD200, que no tiene pelos, el umbral solo marca como pelo el 28 % de la lesión, y el filtro completo, el 1 % (figura 6 del anexo).

Hipótesis 1. Se consideran con pelos las imágenes con más del 10 % de sus píxeles marcados, que son 30 de entrenamiento y 9 de prueba. La hipótesis no se confirmó (tabla 1). En entrenamiento, el cierre empeora más imágenes de las que mejora, y la diferencia sólo es significativa frente a la mediana. En prueba no se detecta diferencia. El promedio de entrenamiento cae sobre todo por cuatro imágenes (IMD331, IMD418, IMD403 e IMD404) que pierden más de 0,1 de Dice, ya que las medianas de los tres métodos casi coinciden (0,906, 0,913 y 0,906). El algoritmo mantiene el cierre porque, a diferencia de la mediana, no suaviza la red de pigmento que mide M5, y porque cambiarlo después de mirar prueba invalidaría la evaluación.

	Dice medio			Cierre mejora / empeora (p)	
Conjunto (imágenes)	Sin quitar	Mediana	Cierre	Frente a sin quitar	Frente a mediana
Entrenamiento (30)	0,893	0,898	0,873	10 / 20 (0,10)	9 / 21 (0,025)
Prueba (9)	0,841	0,841	0,838	4 / 5 (0,65)	3 / 6 (0,36)

Tabla 1: Segmentación de las imágenes con pelos según cómo se quitan. El valor p es de la prueba de Wilcoxon.

Compresión. Incluso a calidad 95 el archivo ocupa unas 8 veces menos, con una pérdida imperceptible (tabla 6 del anexo). A esa calidad el PSNR dentro de la lesión es de 40,7 dB y el SSIM de 0,97, y a calidad 10 bajan a 28,7 dB y 0,70. El SSIM cae más que el PSNR al bajar la calidad, lo que indica que lo más afectado es la estructura local, es decir, la textura, y a calidad 10 la red de pigmento se reemplaza por bloques de 8×8 (figura 9 del anexo). Esperábamos entonces que la segmentación resistiera mejor que la textura y el borde, pero no lo comprobamos, porque no se llegó a repetir el algoritmo sobre imágenes comprimidas.

3.2. Segmentación

Los cinco métodos quedaron muy cerca en entrenamiento (tabla 8 del anexo). Elegimos el crecimiento de regiones aunque *watershed* tiene un Dice medio 0,003 mayor, porque esa diferencia es despreciable, falla en una imagen menos y es casi diez veces más rápido. k-means quedó último, con 10 imágenes mal segmentadas.

En las 60 imágenes de prueba, el crecimiento de regiones da un Dice medio de 0,916 y una mediana de 0,946, muy parecidos a los de entrenamiento. Encuentra el 82,8 % de los píxeles de lesión y marca como lesión sólo el 1,1 % de los de piel, así que su error típico es quedarse corto. Falla en 2 de las 60 imágenes de prueba y en 2 de las 140 de entrenamiento, y las 4 son melanomas con azul grisáceo en los que dejó lesión afuera (figura 4 del anexo). El azul grisáceo se ve casi como la piel en el canal B, aunque 34 de las 38 imágenes con ese color salen bien.

3.3. Criterios y comparación con el dermatólogo

Los detectores de cada estructura se mantienen en prueba (tabla 2). El velo y la regresión se detectan bien y casi igual que en entrenamiento. Las estrías bajan de 0,79 a 0,67, aunque

hay sólo 12 imágenes de prueba con estrías. La red atípica y los puntos y glóbulos, que son patrones finos, se detectan peor y con especificidad baja (0,46 y 0,44), así que se marcan en muchas imágenes que no los tienen y el D estimado tiende a pasarse. Como medida del valor exacto de D el resultado es débil, porque acierta en el 27 % de las imágenes de prueba, menos que decir siempre la mediana de entrenamiento (50 %), con $\kappa = 0{,}07$. Basta errar en una estructura para errar el valor exacto, aunque el conteo siga ordenando bien las lesiones.

Estructura	Imágenes con la estructura	AUC entrenamiento	AUC prueba
Red de pigmento atípica	82 / 34	0,66	0,61
Puntos y glóbulos	78 / 35	0,60	0,63
Estrías	18 / 12	0,79	0,67
Regresión	19 / 6	0,79	0,79
Velo azul-blanquecino	24 / 12	0,95	0,93

Tabla 2: Detección de cada estructura de D. El AUC mide qué tan bien la medida separa las imágenes en que el dermatólogo marcó la estructura de las demás. Las cantidades son de entrenamiento y de prueba.

En prueba, la asimetría coincide con el dermatólogo en el 67 % de las imágenes, con $\kappa = 0{,}38$, un acuerdo aceptable (en entrenamiento, 0,44). Casi todo el acuerdo está en los extremos, y el valor intermedio $A = 1$ es el más difícil. La principal limitación es que el dermatólogo evalúa también si los colores y las estructuras se reparten de forma simétrica, y nosotros sólo miramos la forma del contorno. El color coincide exactamente en el 45 % de las imágenes y difiere en a lo sumo un color en el 80 %, con $\kappa = 0{,}24$. El marrón claro aparece de más, porque es el color del borde, donde el pigmento se aclara hacia la piel; el blanco casi nunca se encuentra, porque es tan claro como la piel, y el rojo, con una sola zona de referencia, tampoco. Los colores oscuros, en cambio, se reconocen razonablemente (κ entre 0,49 y 0,57). El borde separa poco las sospechosas de las comunes (AUC 0,60), porque en PH2 los nevos comunes suelen tener el borde más nítido que los atípicos y los melanomas. La circularidad separa mejor (AUC 0,72). Repetir las medidas con la máscara manual no mejoró el acuerdo, así que los desacuerdos vienen de los criterios y no de la segmentación.

3.4. Zonas y mapas de características

Los mapas sugieren que la información no está repartida de manera pareja (figura 10 del anexo). Medido en las 140 imágenes de entrenamiento, en los nevos comunes la mediana de la entropía baja de adentro hacia afuera (4,40 en el centro, 4,31 en la periferia y 4,16 en la interfase interna), y en las sospechosas esa caída no aparece (4,31, 4,40 y 4,33). Un número global promedia esos comportamientos opuestos.

La tabla 3 muestra qué pasó al llevar estas medidas a prueba. D estimado alcanza un AUC de 0,67, con un intervalo que no incluye al 0,5, así que separa los grupos aunque de forma modesta. La saturación de periferia menos centro llega a 0,71, aunque hay que leerla con cuidado, porque sigue de cerca al brillo de la lesión ($\rho = -0{,}67$ en prueba) y ese brillo solo da un AUC parecido. Con estos datos no podemos separar los dos efectos. La saturación de piel menos lesión queda en 0,60, con un intervalo que incluye al 0,5, y además baja cuando M3 acierta más ($\rho = -0{,}42$ con el Dice), así que en parte mide errores de segmentación.

3.5. Clasificación

La tabla 4 y la figura 3 resumen la clasificación en prueba. El TDS automático separa las lesiones sospechosas de los nevos comunes con un AUC de 0,77, y su intervalo no incluye al 0,5, así que la primera parte de la hipótesis 2 se confirma. El TDS extendido llega a 0,79, pero la diferencia con el TDS es de 0,02 y su intervalo (de $-0{,}06$ a 0,09) incluye al cero, así que la segunda parte no se confirma. Sumar los contrastes de zonas no mejora la separación de forma

Medida	AUC entrenamiento	AUC prueba	IC 95 % en prueba
D del dermatólogo (techo)	0,92	0,88	0,81 a 0,94
D estimado	0,76	0,67	0,54 a 0,80
Periferia menos centro, S	0,76	0,71	0,58 a 0,84
Piel menos lesión, S	0,69	0,60	0,46 a 0,75
Oscuridad de la lesión ($-V$)	0,75	0,68	0,54 a 0,80

Tabla 3: Capacidad de cada medida para separar lesiones sospechosas de nevos comunes (140 imágenes de entrenamiento y 60 de prueba).

significativa, posiblemente porque el primero de ellos sigue de cerca al brillo de la lesión, y los colores oscuros ya los cuenta C.

Clasificador	Umbral	Sensibilidad	Especificidad	AUC (IC 95 %)
TDS, umbral clínico	4,75	0,39	0,96	0,77 (0,65 a 0,89)
TDS, umbral de Youden	3,25	0,69	0,88	0,77 (0,65 a 0,89)
TDS extendido, umbral de Youden	3,49	0,72	0,75	0,79 (0,67 a 0,90)

Tabla 4: Clasificación de las 60 imágenes de prueba en lesiones sospechosas y nevos comunes. Los umbrales de Youden se eligieron en entrenamiento.

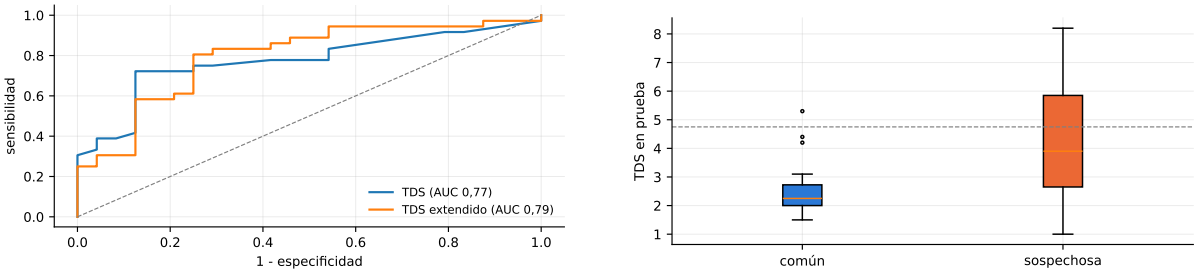


Figura 3: Curvas ROC del TDS y del TDS extendido en prueba (izquierda) y distribución del TDS por grupo, con el umbral clínico en línea punteada (derecha).

El umbral clínico resulta muy conservador con nuestro TDS, porque detecta sólo el 39 % de las sospechosas, aunque casi no se equivoca con los nevos comunes. El umbral de Youden queda más abajo (3,25) y equilibra mejor las dos medidas. Que el mejor umbral sea más bajo es esperable, porque nuestro D adaptado parte de 0 y no de 1, y el borde automático suele dar valores bajos.

4. Conclusiones

La segmentación cumplió su objetivo, con un Dice medio de 0,916 en prueba y fallas en sólo 4 de las 200 imágenes. La compresión quedó caracterizada, aunque no se llegó al objetivo de máxima de repetir el algoritmo sobre imágenes comprimidas.

La hipótesis 1 no se confirmó. Quitar los pelos con un cierre no mejoró la segmentación y, en entrenamiento, resultó peor que el filtro de mediana. Una posible razón, que no comprobamos, es que el suavizado gaussiano previo a la segmentación ya atenúa buena parte de los pelos.

Para estimar D buscamos cada estructura por separado, como hace el dermatólogo. Los detectores de velo y regresión mantuvieron en prueba un AUC de 0,93 y 0,79, y el D que resulta de contarlos separa los grupos (AUC 0,67), aunque todavía acierta el valor exacto en pocas imágenes. Mirar la lesión por zonas también aportó, porque la saturación de periferia menos centro se mantuvo en un AUC de 0,71, pero con 60 imágenes el intervalo es ancho y no alcanza para distinguirla del brillo de la lesión ni para afirmar que mejore a D.

Los criterios A y C se midieron de forma automática, con un acuerdo aceptable en la asimetría ($\kappa = 0{,}38$) y bajo en el color ($\kappa = 0{,}24$) en prueba. El TDS que resulta de combinarlos separa las lesiones sospechosas de los nevos comunes (AUC 0,77), con lo que se confirma la primera parte de la hipótesis 2, pero agregarle los contrastes de zonas no mejoró esa separación de forma significativa, y la segunda parte no se confirma. Con el umbral de Youden, el TDS alcanza en prueba una sensibilidad de 0,69 y una especificidad de 0,88. Estos valores quedan por debajo de los del dermatólogo con la regla original (92,8 % y 90,3 %) y de los trabajos del estado del arte, aunque no son directamente comparables, porque esos trabajos separan melanomas de lesiones benignas y nosotros separamos nevos atípicos y melanomas de nevos comunes, una distinción más difícil.

Las limitaciones principales son la base, chica y de un solo equipo y un solo hospital, y el conjunto de prueba, que tiene sólo 60 imágenes y 9 con pelos. Además, D es una adaptación, la red atípica y los puntos y glóbulos se detectan con poca precisión, y la segmentación sobre el canal azul pierde justamente las zonas azul grisáceas que se asocian al melanoma, lo que puede afectar a los criterios que dependen de la máscara.

Como mejoras, proponemos segmentar con información de color sin sumar fallas en el resto de las imágenes, mejorar los detectores de red atípica y de puntos y glóbulos, que son los más débiles, repetir el algoritmo sobre imágenes comprimidas y validarlo con otra base de imágenes.

Referencias

[1] Franz Nachbar et al. «The ABCD rule of dermatoscopy: High prospective value in the diagnosis of doubtful melanocytic skin lesions». En: *Journal of the American Academy of Dermatology* 30.4 (1994), págs. 551-559. DOI: 10.1016/S0190-9622(94)70061-3.

[2] Tim Lee et al. «DullRazor: A software approach to hair removal from images». En: *Computers in Biology and Medicine* 27.6 (1997), págs. 533-543. DOI: 10.1016/S0010-4825(97)00020-6.

[3] Robert M. Haralick, K. Shanmugam e Its'hak Dinstein. «Textural features for image classification». En: *IEEE Transactions on Systems, Man, and Cybernetics* SMC-3.6 (1973), págs. 610-621. DOI: 10.1109/TSMC.1973.4309314.

[4] Ralph P. Braun y Katrin Kerl. *Dermoscopic structures*. Dermoscopedia. URL: https://dermoscopedia.org/Dermoscopic_structures (visitado 05-11-2026).

[5] Gregory K. Wallace. «The JPEG still picture compression standard». En: *Communications of the ACM* 34.4 (1991), págs. 30-44. DOI: 10.1145/103085.103089.

[6] M. Emre Celebi et al. «A methodological approach to the classification of dermoscopy images». En: *Computerized Medical Imaging and Graphics* 31.6 (2007), págs. 362-373. DOI: 10.1016/j.compmedimag.2007.01.003.

[7] Andre Esteva et al. «Dermatologist-level classification of skin cancer with deep neural networks». En: *Nature* 542 (2017), págs. 115-118. DOI: 10.1038/nature21056.

[8] Reda Kasmi y Karim Mokrani. «Classification of malignant melanoma and benign skin lesions: Implementation of automatic ABCD rule». En: *IET Image Processing* 10.6 (2016), págs. 448-455. DOI: 10.1049/iet-ipr.2015.0385.

[9] Soumia Oukil et al. «Automatic segmentation and melanoma detection based on color and texture features in dermoscopic images». En: *Skin Research and Technology* 28.2 (2022), págs. 203-211. DOI: 10.1111/srt.13111.

[10] Teresa Mendonça et al. «PH2: A dermoscopic image database for research and benchmarking». En: *35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2013, págs. 5437-5440. DOI: 10.1109/EMBC.2013.6610779.

[11] Giuseppe Argenziano et al. «Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the Internet». En: *Journal of the American Academy of Dermatology* 48.5 (2003), págs. 679-693. DOI: 10.1067/mjd.2003.281.

[12] Alexandru Telea. «An image inpainting technique based on the fast marching method». En: *Journal of Graphics Tools* 9.1 (2004), págs. 23-34. DOI: 10.1080/10867651.2004.10487596.

[13] Zhou Wang et al. «Image quality assessment: From error visibility to structural similarity». En: *IEEE Transactions on Image Processing* 13.4 (2004), págs. 600-612. DOI: 10.1109/TIP.2003.819861.

[14] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». En: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), págs. 62-66. DOI: 10.1109/TSMC.1979.4310076.

[15] Tony F. Chan y Luminita A. Vese. «Active contours without edges». En: *IEEE Transactions on Image Processing* 10.2 (2001), págs. 266-277. DOI: 10.1109/83.902291.

[16] Murali Anantha, Randy H. Moss y William V. Stoecker. «Detection of pigment network in dermatoscopy images using texture analysis». En: *Computerized Medical Imaging and Graphics* 28.5 (2004), págs. 225-234. DOI: 10.1016/j.compmedimag.2004.04.002.

[17] Ilias Maglogiannis y Konstantinos K. Delibasis. «Enhancing classification accuracy utilizing globules and dots features in digital dermoscopy». En: *Computer Methods and Programs in Biomedicine* 118.2 (2015), págs. 124-133. DOI: 10.1016/j.cmpb.2014.12.001.

[18] Maryam Sadeghi et al. «Detection and analysis of irregular streaks in dermoscopic images of skin lesions». En: *IEEE Transactions on Medical Imaging* 32.5 (2013), págs. 849-861.

[19] Giuseppe Di Leo et al. «Automatic diagnosis of melanoma: A software system based on the 7-point check-list». En: *43rd Hawaii International Conference on System Sciences*. 2010, págs. 1-10. DOI: 10.1109/HICSS.2010.76.

[20] M. Emre Celebi et al. «Automatic detection of blue-white veil and related structures in dermoscopy images». En: *Computerized Medical Imaging and Graphics* 32.8 (2008), págs. 670-677. DOI: 10.1016/j.compmedimag.2008.08.003.

[21] W. J. Youden. «Index for rating diagnostic tests». En: *Cancer* 3.1 (1950), págs. 32-35.

[22] Jacob Cohen. «A coefficient of agreement for nominal scales». En: *Educational and Psychological Measurement* 20.1 (1960), págs. 37-46. DOI: 10.1177/001316446002000104.

[23] J. Richard Landis y Gary G. Koch. «The measurement of observer agreement for categorical data». En: *Biometrics* 33.1 (1977), págs. 159-174. DOI: 10.2307/2529310.

A. Anexo

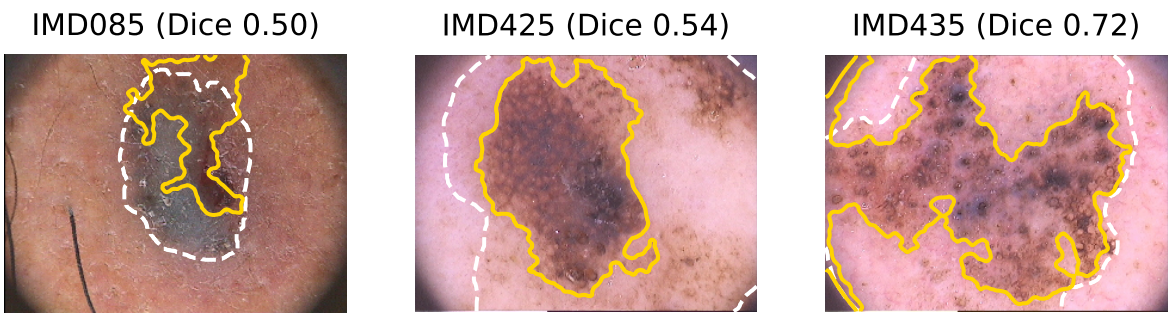


Figura 4: Las imágenes de entrenamiento con peor Dice del método elegido. En blanco punteado, la máscara de PH2; en amarillo, la automática.

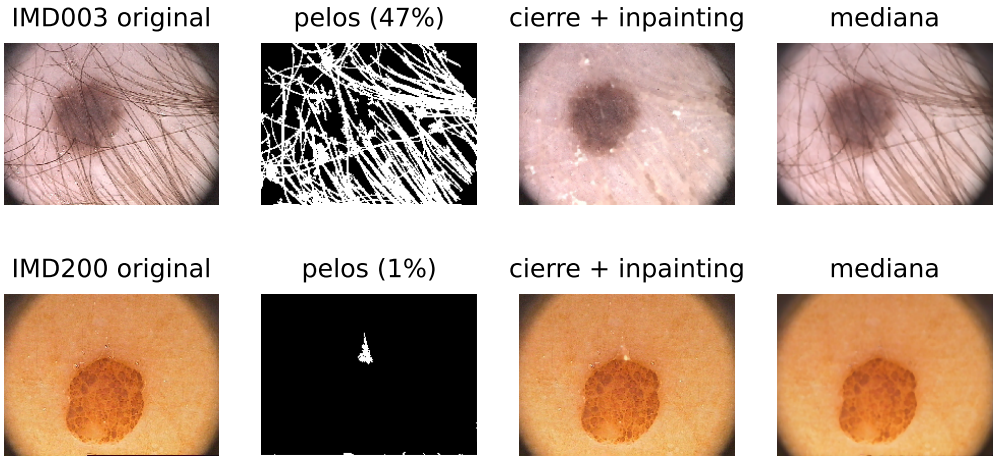


Figura 5: Remoción de pelos en una imagen con muchos pelos (IMD003) y en una sin pelos con red de pigmento (IMD200). Se muestran la original, los pelos detectados, el cierre con *inpainting* y el filtro de mediana.

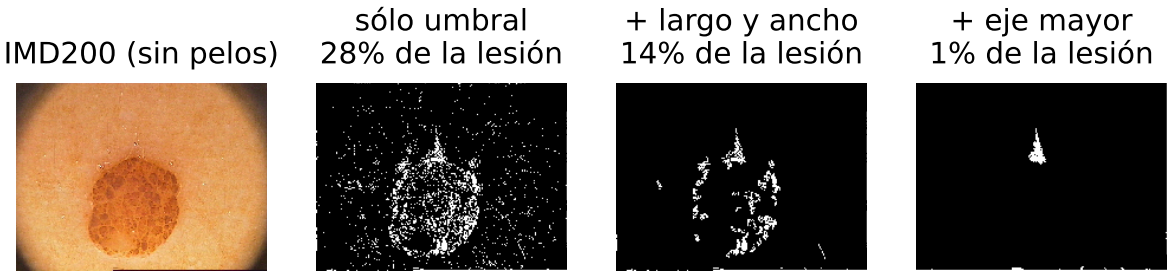


Figura 6: Efecto del filtro de forma en la detección de pelos sobre IMD200, que no tiene pelos. Se comparan los candidatos del *black-hat* (sólo umbral), el filtro por largo y ancho y el filtro completo con eje mayor. Se indica la fracción de la lesión marcada como pelo.

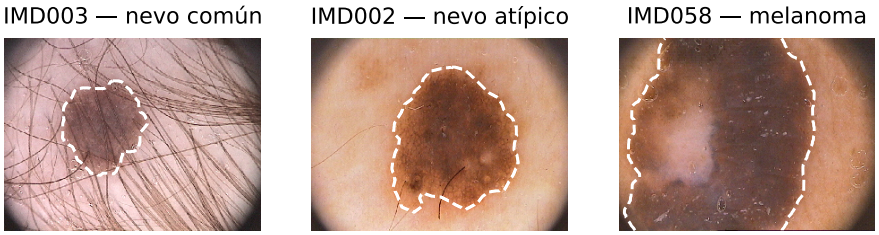


Figura 7: Un ejemplo de cada diagnóstico de PH2 con el contorno de su máscara manual.

Etapa	Parámetro	Valor
Viñeta	Anillo / umbral / radio mínimo	4 px / 0,6 del máximo / 0,8 semidiagonal
Pelos	Elemento estructurante	segmento de 21 px, 12 orientaciones
	Umbral del *black-hat*	0,10
	Forma (largo / ancho / eje mayor)	≥ 60 px / ≤ 8 px / ≥ 80 px
	Reconstrucción	*inpainting* de Telea, radio 5 px
Comparación	Filtro de mediana	9×9 por canal

Tabla 5: Parámetros del mejoramiento (módulo M1), elegidos con el conjunto de entrenamiento.

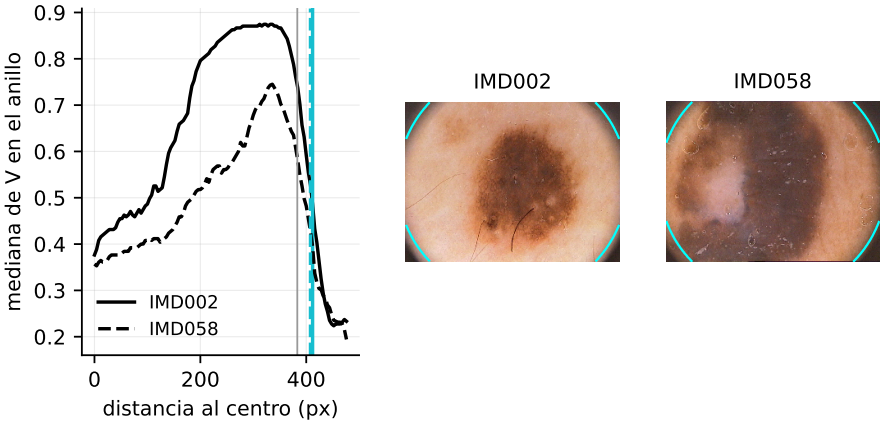


Figura 8: Detección del viñeteo. A la izquierda, la mediana del brillo V en anillos concéntricos para una imagen típica (IMD002) y una con la lesión tocando el borde (IMD058), con el radio detectado en líneas verticales. A la derecha, el límite de la zona válida sobre ambas imágenes.

Calidad	Tasa	PSNR (dB)	PSNR lesión (dB)	SSIM	ΔE lesión
95	8,2	41,1	40,7	0,97	1,9
75	23,7	35,9	34,9	0,89	2,7
50	39,7	34,5	33,4	0,85	3,2
25	67,7	32,8	31,7	0,80	3,9
10	121,8	29,6	28,7	0,70	5,8

Tabla 6: Compresión JPEG, con la mediana de cada métrica sobre las 140 imágenes de entrenamiento.



Figura 9: Detalle de la red de pigmento de IMD200 en la imagen original y comprimida a calidades 75, 25 y 10 (entre paréntesis, la tasa de compresión).

Carpeta	Archivo	Contenido
raíz	`main.py`	Verifica módulos, procesa imágenes y genera resultados
M0	`carga_de_datos.py`	Lectura de PH2, alcance y partición
M1	`mejoramiento.py`	Viñeta y remoción de pelos
M2	`compresion.py`	JPEG, tasa de compresión, PSNR y SSIM
M3	`segmentacion.py`	Métodos de segmentación, posprocesamiento y Dice
M4	`criterios_abc.py`	Asimetría, borde, colores y circularidad
M5	`textura_criterio_d.py`	GLCM y criterio D adaptado
M6	`zonas_y_mapas.py`	Zonas de la lesión y mapas de características
M7	`clasificacion_resultados.py`	TDS, umbrales, métricas y figuras finales
herramientas	`*.py`	Recorrido completo, verificación y gráficos
interfaz	`app.py`	Interfaz gráfica

Tabla 7: Archivos de Python del repositorio. Cada módulo Mn está en `modulos/m`n`_.../`.

Método	Dice medio	Mediana	Peor	Dice $< 0{,}7$	Segundos por imagen
Watershed	0,911	0,936	0,504	3	0,151
Crecimiento de regiones	**0,908**	**0,931**	**0,501**	**2**	**0,016**
Otsu	0,906	0,940	0,262	6	0,013
Chan-Vese	0,900	0,938	0,262	7	0,351
k-means	0,880	0,925	0,259	10	0,207

Tabla 8: Métodos de segmentación con su mejor combinación de parámetros, sobre las 140 imágenes de entrenamiento.

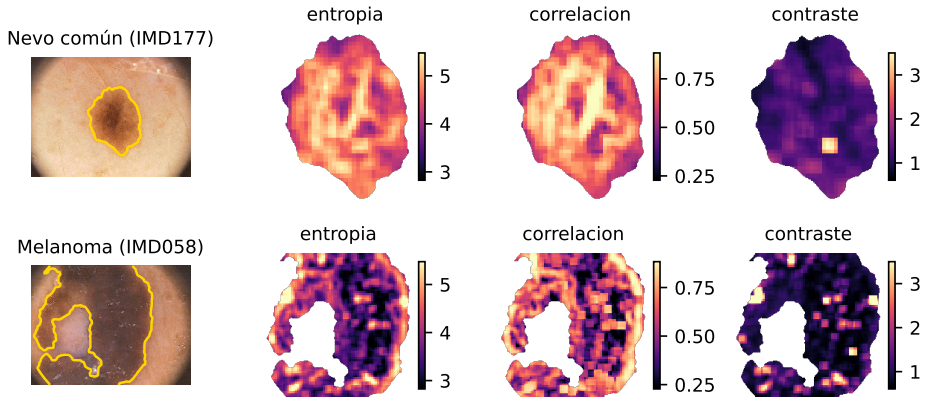


Figura 10: Mapas de entropía, correlación y contraste en un nevo común y un melanoma de entrenamiento. El hueco del mapa del melanoma es una zona central clara que la máscara automática dejó afuera.