Instituto Tecnológico de Buenos Aires

16.63 Procesamiento de Señales e Imágenes Biomédicas
2026 — Segundo cuatrimestre

Comisión BIO

# Detección de lunares sospechosos mediante imágenes dermatoscópicas

Trabajo Práctico de Imágenes (TPI)

PSIB2026Q2-TPI-Grupo02-CassanoNieto DElia Ortega

Grupo 2

| Integrante | Legajo |
|---|---|
| Cassano Nieto, Facundo Tomás | 65555 |
| D'Elía, Lucas Valentín | 65414 |
| Ortega, Facundo | 65560 |

Docentes: Roberto Sebastián Tomás, Lucila Capurro,
Francisco Joaquín Tassara y Victoria Reppucci

5 de noviembre de 2026

### Resumen

El melanoma se parece a un lunar común en sus comienzos, y la regla dermatoscópica ABCD ayuda a distinguirlos a partir de la asimetría, el borde, los colores y las estructuras de la lesión. En este trabajo se desarrolló un algoritmo que mide esos criterios en las 200 imágenes de la base PH2 con procesamiento clásico de imágenes, sin entrenar un clasificador. Las imágenes se separaron en 140 de entrenamiento y 60 de prueba, y todo parámetro se fijó con las primeras. La segmentación por crecimiento de regiones alcanzó un Dice medio de 0,916 en prueba. Quitar los pelos con un cierre morfológico no mejoró la segmentación, por lo que la primera hipótesis no se confirmó. El criterio D, estimado detectando cada estructura por separado, separó en prueba las lesiones sospechosas de los lunares comunes con un AUC de 0,67 (IC 95 %, 0,54 a 0,80), y la diferencia de saturación entre la periferia y el centro de la lesión, con 0,71 (0,58 a 0,84). La asimetría y los colores medidos coincidieron con los del dermatólogo con un $\kappa$ de 0,38 y 0,24. El TDS automático separó las lesiones sospechosas de los nevos comunes con un AUC de 0,77 (0,65 a 0,89) y, con un umbral elegido en entrenamiento, una sensibilidad de 0,69 y una especificidad de 0,88. Agregarle términos de zonas no mejoró esa separación de forma significativa, por lo que la segunda hipótesis se confirmó sólo en parte.

# Índice

**1. Introducción** **2**
1.1. Problemática 2
1.2. Marco teórico 2
1.3. Estado del arte 2
1.4. Pregunta, objetivos e hipótesis 3

**2. Materiales y métodos** **3**
2.1. Base de datos y alcance 3
2.2. Esquema del algoritmo 4
2.3. Pre-procesamiento 4
2.4. Segmentación 5
2.5. Criterios A, B y C 5
2.6. Textura y criterio D adaptado 6
2.7. Zonas de la lesión y mapas de características 6
2.8. Clasificación 7
2.9. Evaluación 7
2.10. Interfaz gráfica y código 7

**3. Resultados** **8**
3.1. Pre-procesamiento 8
3.2. Segmentación 8
3.3. Criterios y comparación con el dermatólogo 9
3.4. Zonas y mapas de características 10
3.5. Clasificación 11

**4. Conclusiones** **11**

**Referencias** **12**

**A. Anexo** **13**

# 1. Introducción

## 1.1. Problemática

El melanoma es un cáncer de piel cuyo pronóstico depende de cuán temprano se lo detecte. Al comienzo se parece mucho a un lunar común, y el dermatólogo lo evalúa con el dermatoscopio, una lente de aumento con iluminación propia. Para hacerlo de forma sistemática usa la regla ABCD, que puntúa la asimetría ($A$, de 0 a 2 según en cuántos ejes es asimétrica la lesión), el borde ($B$, de 0 a 8 según en cuántos sectores el pigmento termina de forma abrupta), los colores ($C$, de 1 a 6) y las estructuras diferenciales, como la red de pigmento o los glóbulos ($D$, de 1 a 5), y los combina en el puntaje dermatoscópico total

$$\mathrm{TDS} = 1{,}3\,A + 0{,}1\,B + 0{,}5\,C + 0{,}5\,D. \tag{1}$$

Un TDS menor a 4,75 indica una lesión benigna; entre 4,75 y 5,45, una lesión sospechosa, y mayor a 5,45, una lesión probablemente maligna [1]. La evaluación es visual y su precisión depende de la experiencia de quien la hace.

## 1.2. Marco teórico

La imagen dermatoscópica es una imagen RGB en la que el color tiene valor diagnóstico, porque depende de la profundidad del pigmento. Los marrones y el negro indican melanina en la epidermis, el azul grisáceo indica melanina en la dermis y el blanco, zonas de regresión. Por eso conviene trabajar en el espacio HSV, que separa el matiz ($H$) y la saturación ($S$) del brillo ($V$). Antes de medir ese color hay que lidiar con los artefactos de la imagen. La lente circular deja esquinas oscuras (viñeteo), y los pelos que cruzan la lesión, que se ven como líneas oscuras y finas, desplazan el borde segmentado y agregan un color que no le pertenece. Estos pueden quitarse con un cierre morfológico con un elemento estructurante más ancho que un pelo y más chico que la lesión, idea en la que se basa DullRazor [2].

Además del color, la regla mira las estructuras diferenciales, que son patrones que se repiten dentro de la lesión y que pueden describirse como textura. Una forma clásica de medirla es la matriz de co-ocurrencia de niveles de gris (GLCM), que cuenta con qué frecuencia aparecen juntos dos niveles de gris a una distancia y dirección dadas, y de la que se obtienen atributos como la entropía, el contraste y la correlación [3]. Sin embargo, estas estructuras no se reparten al azar dentro de la lesión. Las estrías, por ejemplo, aparecen de forma focal y asimétrica en la periferia, y las áreas claras sin estructura en la periferia también se asocian al melanoma [4]. Un único número calculado sobre toda la lesión puede entonces promediar zonas que se comportan distinto. La interfase con la piel importa por otro motivo, ya que el criterio B puntúa justamente los sectores donde el pigmento termina de golpe [1], y comparar la lesión con la piel vecina permite medir ese cambio de forma continua.

Todo este detalle puede perderse al guardar o transmitir las imágenes. JPEG, el formato con pérdida más usado para fotografías [5], guarda el color a la mitad de resolución, divide la imagen en bloques de $8 \times 8$, les aplica la transformada discreta del coseno y cuantiza los coeficientes según un parámetro de calidad (de 1 a 100), descartando sobre todo las frecuencias altas. Lo que se pierde es justamente el detalle fino y parte del color que usa la regla ABCD.

## 1.3. Estado del arte

Los sistemas de diagnóstico asistido segmentan la lesión, miden descriptores de forma, color y textura y los entregan a un clasificador [6]. Las redes neuronales convolucionales ya alcanzan un desempeño comparable al de los dermatólogos [7], pero no muestran en qué se basa cada decisión, y la mayoría sólo informa el diagnóstico final, por lo que no permiten comprobar si cada criterio se mide bien.

Medir la regla ABCD de forma automática tampoco es una idea nueva. Un trabajo la implementó sobre 200 imágenes dermatoscópicas, 80 de melanomas y 120 de lesiones benignas, y obtuvo una sensibilidad de 91,25 % y una especificidad de 95,83 % [8]. Otro, sobre PH2, combinó color y textura con una máquina de vectores de soporte y separó melanomas de nevos con una sensibilidad de 99,25 % y una especificidad de 99,58 % [9]. Como referencia humana, el trabajo original de la regla informa 92,8 % y 90,3 % [1]. Estos valores no se pueden comparar directamente con los nuestros, porque ninguno de esos trabajos separa nevos comunes de nevos atípicos y melanomas, que es la pregunta de este trabajo.

Lo que buscamos aportar es una medición que se pueda revisar paso a paso. Cada criterio se compara con el dermatólogo, los mapas muestran en qué parte de la lesión está la información y el algoritmo final no entrena ningún clasificador, sino que usa la fórmula de la regla.

### 1.4. Pregunta, objetivos e hipótesis

**Pregunta y objetivo general.** ¿Pueden medirse automáticamente los criterios de la regla ABCD, complementarse con descriptores por zona de la lesión y distinguir lesiones sospechosas de lunares comunes? Para responderlo, buscamos desarrollar un algoritmo que haga esas mediciones y estime si la lesión es sospechosa, con una interfaz gráfica que muestre cada etapa.

**Objetivos específicos.** (1) Quitar los artefactos (viñeteo y pelos) y medir su efecto en la segmentación; (2) caracterizar la pérdida por compresión JPEG; (3) segmentar la lesión y validar contra la máscara manual (Dice); (4) medir A, B y C y comparar A y C con el dermatólogo ($\kappa$ de Cohen); (5) estimar un criterio D adaptado detectando cada estructura en la imagen; (6) construir mapas de características y descriptores por zona y evaluar si mejoran la clasificación al agregarse al TDS; (7) clasificar con el TDS y medir sensibilidad, especificidad y AUC en un conjunto de prueba.

**Hipótesis.** (H1) Quitar los pelos con un cierre morfológico mejora la segmentación de las imágenes con pelos respecto de no quitarlos y de un filtro de mediana. (H2) El TDS automático separa las lesiones sospechosas de los nevos comunes, y agregarle términos de textura y de zonas mejora esa separación. Como objetivo de máxima, se evalúa además si el desempeño se mantiene sobre imágenes comprimidas con JPEG.

## 2. Materiales y métodos

### 2.1. Base de datos y alcance

Se usa la base PH2 [10], del Hospital Pedro Hispano (Portugal), con 200 imágenes dermatoscópicas RGB de 8 bits por canal adquiridas con el mismo equipo, que incluyen 80 nevos comunes, 80 nevos atípicos y 40 melanomas (figura 9 del anexo). Hay 24 tamaños de imagen distintos, así que ninguna etapa supone un tamaño fijo. La lesión ocupa entre el 3 % y el 98 % de la imagen (mediana 23 %) y en 50 imágenes toca el borde. Cada imagen trae la máscara de la lesión dibujada a mano y la evaluación de un dermatólogo (diagnóstico, asimetría, colores y estructuras), lo que permite validar cada etapa por separado.

Se considera *sospechosa* toda lesión con diagnóstico de nevo atípico o melanoma (120 imágenes) y *no sospechosa* a los nevos comunes (80), porque la pregunta es distinguir las lesiones que ameritan control de los lunares comunes.

La regla original define D como la cantidad de estructuras diferenciales presentes entre cinco, que son la red de pigmento, las áreas sin estructura, las estrías, los puntos y los glóbulos, y por eso va de 1 a 5 [1]. PH2 no anota exactamente esas estructuras, ya que trae los puntos y los glóbulos juntos, no anota las áreas sin estructura y, en cambio, anota las áreas de regresión y el velo azul-blanquecino. Por eso no podemos medir el D original y usamos un *D adaptado*, que cuenta cuántas de las cinco estructuras de PH2 marcó el dermatólogo (red de pigmento atípica, puntos o glóbulos, estrías, regresión y velo) y va de 0 a 5. La red se cuenta sólo cuando es atípica porque en PH2 todas las lesiones tienen red, y la atípica es la que se asocia al melanoma [11]. Con esta definición, el D medio es 0,65 en los nevos comunes, 1,79 en los atípicos y 3,12 en los melanomas.

Las imágenes se dividieron en entrenamiento (140, con 56 nevos comunes, 56 atípicos y 28 melanomas) y prueba (60, con 24, 24 y 12), de forma estratificada y con semilla fija. Todos los umbrales y parámetros se eligen únicamente con entrenamiento, y prueba se usa sólo para las métricas finales.

## 2.2. Esquema del algoritmo

La figura 1 muestra el recorrido de una imagen por el algoritmo. La compresión (M2) no forma parte de ese recorrido, y se estudia aparte para saber qué se pierde al guardar las imágenes en JPEG.

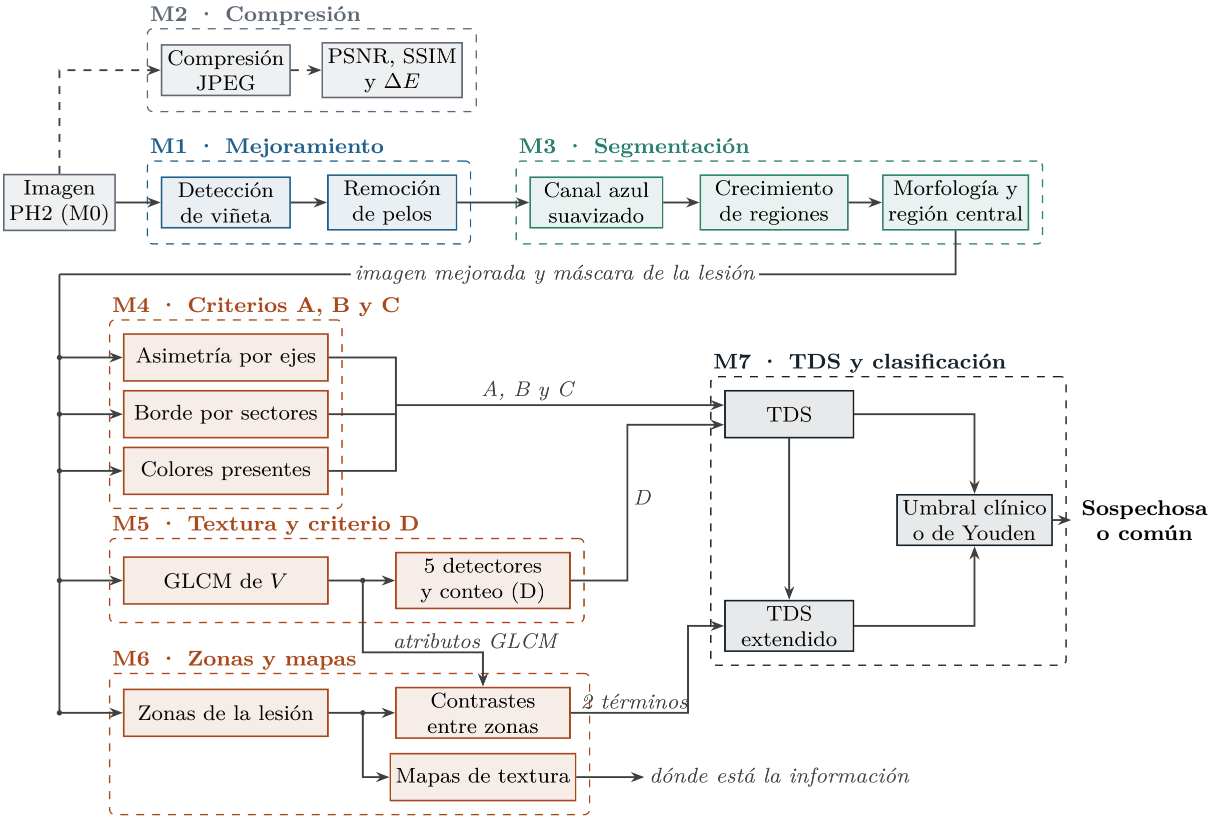
M2 · Compresión
Compresión JPEG
PSNR, SSIM y $\Delta E$
M1 · Mejoramiento
M3 · Segmentación
Imagen PH2 (M0)
Detección de viñeta
Remoción de pelos
Canal azul suavizado
Crecimiento de regiones
Morfología y región central
imagen mejorada y máscara de la lesión
M4 · Criterios A, B y C
Asimetría por ejes
Borde por sectores
Colores presentes
A, B y C
M7 · TDS y clasificación
TDS
D
Umbral clínico o de Youden
Sospechosa o común
M5 · Textura y criterio D
GLCM de $V$
5 detectores y conteo (D)
TDS extendido
atributos GLCM
M6 · Zonas y mapas
Zonas de la lesión
Contrastes entre zonas
2 términos
Mapas de textura
dónde está la información

Figura 1: Diagrama de bloques del algoritmo. Los recuadros agrupan los bloques de cada módulo del repositorio, y la línea punteada marca el estudio de compresión, que queda fuera del recorrido principal.

## 2.3. Pre-procesamiento

**Análisis exploratorio.** Con las imágenes de entrenamiento se eligió el canal con más contraste entre lesión y piel. En cada imagen se tomaron 2000 píxeles de cada una y se calculó el área bajo la curva ROC (AUC) de separarlos con un umbral sobre cada canal (R, G, B, H, S, V, L de Lab y gris).

**Viñeteo.** Las esquinas oscuras se excluyen con una máscara de píxeles válidos. Un umbral fijo de brillo no sirve, porque el que captura todas las esquinas captura también zonas oscuras de 124 de las 140 lesiones de entrenamiento. En cambio se aprovecha que la viñeta es circular y centrada, y que la mediana de $V$ en un anillo no se ve afectada por una lesión que ocupa sólo una parte de él. La viñeta empieza en el primer anillo cuya mediana cae por debajo del 60 % del anillo más brillante, y nunca antes del 80 % de la semidiagonal, para no cortar lesiones muy grandes (figura 10 del anexo).

**Pelos.** Se detectan con un cierre morfológico del gris con segmentos de 21 píxeles en 12 orientaciones. Son candidatos los píxeles donde la diferencia entre el cierre y la imagen (*black-hat*) supera 0,10 [2]. Como la red de pigmento también es oscura y fina, sólo se conservan las regiones largas, finas y alargadas (tabla 7 del anexo). Esos píxeles se reconstruyen por *inpainting* [12] y el resto de la imagen no se modifica. Para la hipótesis 1 se compara con no quitar los pelos y con un filtro de mediana de $9 \times 9$ por canal.

**Compresión.** Cada imagen de entrenamiento se comprimió con JPEG a calidades 95, 75, 50, 25 y 10, y se midieron la tasa de compresión, el PSNR (en toda la imagen y dentro de la lesión), el SSIM [13] y la diferencia de color media dentro de la lesión en Lab ($\Delta E$, CIE76), para la que 2,3 es el umbral aproximado de percepción. Cada calidad se resume con la mediana de las 140 imágenes.

## 2.4. Segmentación

Se segmenta sobre el canal azul, que es el que mejor separa la lesión de la piel, suavizado con un filtro gaussiano para que el pigmento y los puntos no dejen un borde dentado. El suavizado se hace en esta etapa y no en el mejoramiento porque la imagen mejorada también se usa para medir colores y textura, y suavizarla borraría la red de pigmento.

Se compararon cinco métodos. El umbral de Otsu [14] se calcula sólo con los píxeles válidos, para que la viñeta no corra el histograma. El crecimiento de regiones arranca del píxel más oscuro de un recuadro central, ya que en PH2 la foto apunta a la lesión, y agrega vecinos mientras no superen un límite de brillo a mitad de camino entre la lesión (percentil 5 del recuadro central) y la piel (percentil 90 de la zona válida), así que se adapta a lesiones oscuras y claras. En *watershed* se marca como lesión todo lo oscuro y como piel sólo lo claro conectado con el borde de la zona válida, porque si cualquier zona clara contaba como piel, las partes claras de las lesiones grandes quedaban afuera. k-means agrupa el color en Lab, ya que sobre un solo canal daría lo mismo que Otsu, y Chan-Vese [15] arranca desde el contorno de Otsu porque con el arranque por defecto se trababa en las lesiones chicas. A todas las salidas se les aplica una apertura para borrar islas, un cierre para rellenar mellas del borde, la selección de la región del centro de la imagen y el relleno de huecos.

Los parámetros de cada método se eligieron con una grilla sobre las 140 imágenes de entrenamiento, tomando la combinación de mayor Dice medio, y se amplió para *watershed*, el único que mejoraba más allá de los valores probados. Consideramos mal segmentada a una imagen con Dice menor a 0,7. El método elegido fue el crecimiento de regiones, con $\sigma = 4\,\text{px}$, tolerancia 0,5, apertura de $3\,\text{px}$ y cierre de $10\,\text{px}$.

## 2.5. Criterios A, B y C

Los criterios se miden sobre la máscara automática, que es la que tendría el programa con una imagen nueva, y cada umbral se eligió en entrenamiento probando una lista de valores.

**Asimetría.** La máscara se refleja sobre sus dos ejes principales, calculados con los momentos de segundo orden, y se mide qué fracción de la lesión queda sin pareja. Un eje es asimétrico si esa fracción supera 0,11, el umbral con mayor $\kappa$ con el dermatólogo, y $A$ es la cantidad de ejes asimétricos.

**Borde.** El contorno se divide en 8 sectores de 45° contados desde el eje mayor, y en cada uno se promedia el gradiente de $V$ (filtro de Sobel) sobre el contorno, sin contar los puntos pegados al marco de la foto, donde la lesión no termina sino que está cortada. Además del gradiente crudo se probó dividirlo por el salto de brillo entre lesión y piel, para medir qué tan rápido cambia el brillo y no cuánto. Como PH2 no anota $B$, el umbral de sector abrupto es el que mejor separa los nevos comunes de las lesiones sospechosas.

**Color.** Una referencia fija de cada color no sirve, porque en las zonas que pintaron los autores de PH2 el azul grisáceo es casi igual al negro, el blanco se ve rosado y todo cambia con la luz y el tono de piel. Comparados con la piel de la misma foto, en cambio, los colores se ordenan con sentido. El blanco es tan claro como la piel pero más azulado, los marrones son más rojizos y el azul grisáceo y el negro son oscuros y grises. Por eso, y es la decisión más importante de este criterio, cada imagen se divide por el color de la piel de un anillo alrededor de la lesión. Las referencias son la mediana en HSV de las zonas de cada color en entrenamiento (tabla 6 del anexo). Como PH2 no trae zonas rojas, las marcamos a mano en las 7 imágenes con rojo anotado, aunque sólo una tenía rojo claro. Cada píxel se asigna al color más cercano, o a la piel si se parece más a ella, y un color está presente si ocupa más del 5 % de la lesión. Se calcula además la circularidad $4\pi$ área/perímetro$^2$, sin umbral.

## 2.6. Textura y criterio D adaptado

Se calcula la GLCM sobre $V$ usando sólo pares de píxeles dentro de la lesión, promediada en las cuatro direcciones, y de ella se obtienen la energía, la entropía, el contraste, el IDM, la correlación, el *cluster shade* y el *cluster prominence* [3]. Se usan 32 niveles de gris, que conservan detalle sin que la matriz de $32 \times 32$ quede casi vacía, y distancia 1, que compara píxeles vecinos, la escala de las líneas finas de la red de pigmento. La textura se mide en $V$, como se propuso en el anteproyecto, y no se comparó con otros canales.

Lo que se estima es el $D$ adaptado de la sección 2.1, y se estima como lo cuenta el dermatólogo, buscando cada estructura por separado con una medida pensada a partir de cómo se ve. La red atípica tiene líneas de distinto grosor y zonas sin red, y como la red se reconoce por su textura [16], se mide cuánto varía el contraste local dentro de la lesión (desvío sobre media del mapa de contraste de M6). Los puntos y glóbulos son manchas oscuras y redondeadas, y se cuentan por unidad de área [17], con un *black-hat* con un disco de 6 px seguido de una apertura con un disco de 2 px que borra las líneas finas de la red. Las estrías son líneas oscuras que salen radialmente del borde y se detectan como valles orientados [18]. Con la matriz Hessiana se marcan las líneas oscuras y su dirección, y se mide qué parte de un anillo de 15 px a cada lado del borde tiene líneas marcadas que apuntan hacia afuera. La regresión y el velo se reconocen por el color [19, 20]. La regresión es más clara y menos saturada que la piel, y como en el canal azul se parece a ella y M3 suele dejarla fuera de la máscara, se busca en toda la envolvente convexa de la lesión. El velo es la única estructura azulada, y se mide con el percentil 90 de $B - R$ dentro de la lesión. Una estructura se considera presente si su medida supera un umbral, y el $D$ estimado es la cantidad de estructuras detectadas. Cada umbral se elige en entrenamiento con el índice de Youden [21], $J = \text{sensibilidad} + \text{especificidad} - 1$, donde la sensibilidad es la fracción de imágenes con la estructura que se detectan y la especificidad, la fracción de imágenes sin ella que quedan sin detectar. Se prueban todos los umbrales posibles y se elige el de mayor $J$, que es el que mejor equilibra no perder estructuras y no inventarlas.

## 2.7. Zonas de la lesión y mapas de características

Siguiendo la devolución del anteproyecto, se mira por separado el centro, la periferia y la interfase con la piel. Las zonas se definen con la transformada de distancia al borde de la máscara (figura 2). El centro es donde esa distancia supera la mitad de su máximo y la periferia es el resto de la lesión. Las interfases interna y externa son anillos de 15 px a cada lado del borde, y la externa no incluye las esquinas de la viñeta. Los 15 px salen del perfil de brillo alrededor del borde, que en entrenamiento alcanza el 90 % del brillo de la piel a 12 px en la mediana y a 19 px en el percentil 75.

En cada zona se miden el color medio en HSV y los atributos GLCM de $V$. A partir de ellos

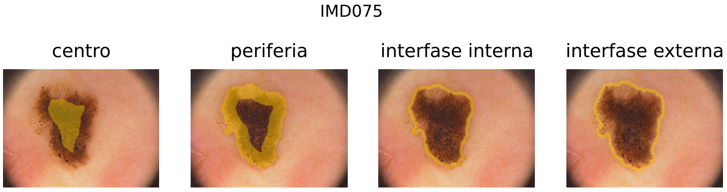

Figura 2: Las cuatro zonas sobre una lesión de tamaño típico de entrenamiento.

se calculan 10 contrastes, restando periferia menos centro y piel menos lesión para $H$, $S$, $V$, contraste y entropía. El signo importa, porque el TDS extendido suma cada término y uno que baje en las sospechosas lo empeoraría. Además, para ver dónde está la información se calculan mapas de un atributo GLCM en ventanas de 31 px cada 8 px.

### 2.8. Clasificación

Una lesión se clasifica como sospechosa si su TDS automático (ec. 1) supera un umbral. Se comparan el umbral clínico (4,75) con el que maximiza el índice de Youden en entrenamiento, en este caso para detectar lesiones sospechosas. La comparación importa porque el umbral clínico se fijó para el TDS original, y como nuestro $D$ se mide distinto, no es seguro que ese umbral funcione igual. Para la hipótesis 2 se define un TDS extendido sumando al TDS los términos de textura y de zonas elegidos en entrenamiento, estandarizados con la media y el desvío de entrenamiento, y se vuelve a elegir el umbral. Los dos términos se eligieron en entrenamiento, antes de mirar prueba, y son la saturación de periferia menos centro (AUC 0,76) y la de piel menos lesión (AUC 0,69). No se eligió el contraste de $V$ entre piel y lesión, aunque su AUC es 0,74, porque se correlaciona con el primero ($\rho = 0{,}68$), mientras que los dos elegidos casi no se correlacionan entre sí ($\rho = 0{,}08$). Aquí $\rho$ es la correlación de Spearman, que compara cómo ordenan las imágenes dos medidas y vale 1 si las ordenan igual, 0 si no tienen relación y $-1$ si las ordenan al revés.

### 2.9. Evaluación

La segmentación se compara con la máscara de PH2 mediante el coeficiente de Dice, y A, C y D con el dermatólogo mediante el $\kappa$ de Cohen [22], cuyos valores entre 0,41 y 0,60 indican un acuerdo moderado [23]. La clasificación se mide con la sensibilidad, la especificidad y el AUC.

Para H1 se usa la prueba de Wilcoxon de rangos con signo, porque el Dice se mide de a pares en las mismas imágenes. El intervalo de confianza del 95 % del AUC se calcula con un *bootstrap* de percentiles, sorteando 2000 veces con reposición dentro de cada grupo. Para comparar dos AUC se usa el mismo sorteo sobre las mismas imágenes, y la diferencia se considera significativa si su intervalo no incluye al cero.

### 2.10. Interfaz gráfica y código

La interfaz es una aplicación de escritorio en tkinter, que se abre con `python interfaz/app.py` (figura 12 del anexo). Permite elegir una imagen de prueba de PH2 o una propia, la procesa con los mismos métodos que el algoritmo final y muestra cada etapa, desde los pelos detectados y el contorno automático junto al de referencia hasta los ejes de simetría, el borde por sector, el mapa de colores, las zonas y los mapas de textura. En la pestaña de resultados presenta A, B, C, D, las estructuras detectadas, el TDS, el TDS extendido y la clasificación al lado de lo que anotó el dermatólogo. Sólo llama a las funciones de los módulos, de modo que lo que se ve es lo mismo que se evalúa.

El código está en `https://github.com/facortega/PSIB2026Q2-TPI-Grupo02-CassanoNieto-DElia-Ortega`. Cada módulo tiene un archivo `.py` con las funciones y un cuaderno `.ipynb` con las pruebas, las figuras y la discusión. La tabla 9 del anexo detalla el contenido de cada archivo.

# 3. Resultados

## 3.1. Pre-procesamiento

**Canal de trabajo.** El canal azul es el que mejor separa la lesión de la piel en entrenamiento (AUC medio 0,976, seguido por $G$ con 0,965), lo que es coherente con que la melanina absorbe más la luz azul que la roja. El canal $V$, propuesto en el anteproyecto, queda entre los peores (0,902), porque $V = \text{máx}(R, G, B)$ y en la piel y la lesión domina el rojo. Por eso la segmentación se hace sobre $B$. El borde, en cambio, se mide sobre $V$, como estaba propuesto, porque ahí interesa el cambio de brillo en el contorno y no separar lesión de piel.

**Viñeteo y pelos.** Con el perfil radial, sólo 4 de las 200 imágenes pierden más del 2 % de la lesión por quedar fuera de la zona válida (máximo 5,9 %). En cuanto a los pelos, el cierre reconstruye sólo sus píxeles, mientras que la mediana suaviza toda la imagen, incluidas la red y el borde (figura 7 del anexo). El filtro de forma es lo que evita borrar la red. En IMD200, que no tiene pelos, el umbral solo marca como pelo el 28 % de la lesión, y el filtro completo, el 1 % (figura 8 del anexo).

**Hipótesis 1.** Se consideran con pelos las imágenes con más del 10 % de sus píxeles marcados, que son 30 de entrenamiento y 9 de prueba. La hipótesis no se confirmó (tabla 1). En entrenamiento, el cierre empeora más imágenes de las que mejora, y la diferencia sólo es significativa frente a la mediana. En prueba no se detecta diferencia. El promedio de entrenamiento cae sobre todo por cuatro imágenes (IMD331, IMD418, IMD403 e IMD404) que pierden más de 0,1 de Dice, ya que las medianas de los tres métodos casi coinciden (0,906, 0,913 y 0,906). En esas cuatro imágenes el detector marca como pelo entre el 46 y el 78 % de la lesión, porque confunde la red y la textura oscura con pelos, y el *inpainting* aclara la lesión, que M3 recorta. Como el grupo con pelos lo define el mismo detector, incluye también imágenes en las que se equivoca. El algoritmo mantiene el cierre porque, a diferencia de la mediana, no suaviza la red de pigmento que mide M5, y porque cambiarlo después de mirar prueba invalidaría la evaluación.

| | Dice medio | | | Cierre mejora / empeora (p) | |
|---|---|---|---|---|---|
| Conjunto (imágenes) | Sin quitar | Mediana | Cierre | Frente a sin quitar | Frente a mediana |
| Entrenamiento (30) | 0,893 | 0,898 | 0,873 | 10 / 20 (0,10) | 9 / 21 (0,025) |
| Prueba (9) | 0,841 | 0,841 | 0,838 | 4 / 5 (0,65) | 3 / 6 (0,36) |

Tabla 1: Segmentación de las imágenes con pelos según cómo se quitan. El valor p es de la prueba de Wilcoxon.

**Compresión.** Incluso a calidad 95 el archivo ocupa unas 8 veces menos, con una pérdida imperceptible (tabla 8 del anexo). A esa calidad el PSNR dentro de la lesión es de 40,7 dB y el SSIM de 0,97, y a calidad 10 bajan a 28,7 dB y 0,70. El SSIM cae más que el PSNR al bajar la calidad, lo que indica que lo más afectado es la estructura local, es decir, la textura, y a calidad 10 la red de pigmento se reemplaza por bloques de 8 × 8 (figura 11 del anexo). Esperábamos entonces que la segmentación resistiera mejor que la textura y el borde, pero no lo comprobamos, porque no se llegó a repetir el algoritmo sobre imágenes comprimidas.

## 3.2. Segmentación

Los cinco métodos quedaron muy cerca en entrenamiento (tabla 2). Elegimos el crecimiento de regiones aunque *watershed* tiene un Dice medio 0,003 mayor, porque esa diferencia es despreciable, falla en una imagen menos y es casi diez veces más rápido. Otsu y Chan-Vese tienen la mediana más alta, pero fallan en 6 y 7 imágenes, y k-means quedó último, con 10 fallas. El crecimiento de regiones depende mucho de la tolerancia (de 0,69 a 0,91 de Dice medio), y en las lesiones chicas supera a Otsu por 0,04, porque ahí el histograma casi no tiene un pico de lesión y el umbral de Otsu se corre hacia la piel.

| Método | Dice medio | Mediana | Peor | Dice < 0,7 | Segundos por imagen |
|---|---|---|---|---|---|
| *Watershed* | 0,911 | 0,936 | 0,504 | 3 | 0,151 |
| **Crecimiento de regiones** | **0,908** | **0,931** | **0,501** | **2** | **0,016** |
| Otsu | 0,906 | 0,940 | 0,262 | 6 | 0,013 |
| Chan-Vese | 0,900 | 0,938 | 0,262 | 7 | 0,351 |
| k-means | 0,880 | 0,925 | 0,259 | 10 | 0,207 |

Tabla 2: Métodos de segmentación con su mejor combinación de parámetros, sobre las 140 imágenes de entrenamiento.

En las 60 imágenes de prueba, el crecimiento de regiones da un Dice medio de 0,916 y una mediana de 0,946, muy parecidos a los de entrenamiento. Encuentra el 82,8 % de los píxeles de lesión y marca como lesión sólo el 1,1 % de los de piel, así que su error típico es quedarse corto, sobre todo en los melanomas. Falla en 2 de las 60 imágenes de prueba y en 2 de las 140 de entrenamiento, y las 4 son melanomas con azul grisáceo en los que dejó lesión afuera (figura 4 del anexo), porque ese color refleja bastante luz azul y en el canal $B$ se ve casi como la piel. Aun así, 34 de las 38 imágenes con azul grisáceo salen bien, y ningún método, ni siquiera k-means, que mira el color completo, resolvió esos casos sin empeorar el resto, así que mantuvimos el canal azul.

## 3.3. Criterios y comparación con el dermatólogo

En prueba los criterios dan valores parecidos a los de entrenamiento, así que sus umbrales no quedaron ajustados sólo a esas imágenes.

**Asimetría.** El $\kappa$ con el dermatólogo es 0,44 en entrenamiento y 0,38 en prueba, con coincidencia exacta en el 67 % de las imágenes de prueba. El acuerdo está en los extremos y el $A = 1$ es el más difícil. Muchos desacuerdos aparecen porque el dermatólogo también mira si el pigmento está repartido de forma pareja, y el programa sólo mira la forma del contorno (figura 5 del anexo).

**Borde.** Esperábamos que el gradiente normalizado separara mejor, y separó al revés (AUC entre 0,24 y 0,38 con cualquier umbral), porque en PH2 los nevos comunes suelen ser manchas parejas de borde nítido y los atípicos y melanomas tienen bordes que se desvanecen. Elegimos el gradiente crudo con umbral 0,0513, el único que suma en el sentido del TDS, aunque separa poco (AUC 0,60 en prueba).

**Color.** El $\kappa$ de C es 0,17 en entrenamiento y 0,24 en prueba, aunque en el 80 % de las imágenes la diferencia es de un color como mucho. El marrón claro aparece casi siempre, incluso en 42 de las 44 lesiones de entrenamiento donde no fue anotado, porque es el color del borde, donde el pigmento se aclara. El blanco casi nunca se encuentra, porque el programa lo asigna a la piel, y el rojo sólo en la imagen de la que salió su referencia, mientras que el marrón oscuro, el azul grisáceo y el negro andan mejor ($\kappa$ entre 0,49 y 0,57 en prueba) (figura 6 del anexo). Un mínimo propio para cada color mejora cada color por separado pero no el $\kappa$ de C, así que mantuvimos uno solo.

**Circularidad.** Separa bien los grupos (AUC 0,72 en prueba), porque los melanomas son mucho menos circulares (mediana 0,34, contra 0,71 en los nevos comunes).

**¿Error de segmentación o del criterio?** Con la máscara de PH2 los criterios no mejoran. El $\kappa$ de A baja de 0,44 a 0,29 y el AUC de la circularidad de 0,75 a 0,57, y B y C quedan parecidos, así que los desacuerdos vienen de los criterios y no de la segmentación. Una explicación posible es que nuestra máscara sigue el pigmento más oscuro y su forma refleja también cómo está repartido.

**Estructuras.** Los detectores de cada estructura se mantienen en prueba (tabla 3). El velo y la regresión se detectan bien y casi igual que en entrenamiento. Las estrías bajan de 0,79 a 0,67, aunque hay sólo 12 imágenes de prueba con estrías. La red atípica y los puntos y glóbulos, que son patrones finos, se detectan peor y con especificidad baja (0,46 y 0,44), así que se marcan en muchas imágenes que no los tienen y el D estimado tiende a pasarse. Como medida del valor exacto de D el resultado es débil, porque acierta en el 27 % de las imágenes de prueba, menos que decir siempre la mediana de entrenamiento (50 %), con $\kappa = 0{,}07$. Basta errar en una estructura para errar el valor exacto, aunque el conteo siga ordenando bien las lesiones.

| Estructura | Imágenes con la estructura | AUC entrenamiento | AUC prueba |
|---|---|---|---|
| Red de pigmento atípica | 82 / 34 | 0,66 | 0,61 |
| Puntos y glóbulos | 78 / 35 | 0,60 | 0,63 |
| Estrías | 18 / 12 | 0,79 | 0,67 |
| Regresión | 19 / 6 | 0,79 | 0,79 |
| Velo azul-blanquecino | 24 / 12 | 0,95 | 0,93 |

Tabla 3: Detección de cada estructura de D. El AUC mide qué tan bien la medida separa las imágenes en que el dermatólogo marcó la estructura de las demás. Las cantidades son de entrenamiento y de prueba.

### 3.4. Zonas y mapas de características

Los mapas sugieren que la información no está repartida de manera pareja (figura 13 del anexo). Medido en las 140 imágenes de entrenamiento, en los nevos comunes la mediana de la entropía baja de adentro hacia afuera (4,40 en el centro, 4,31 en la periferia y 4,16 en la interfase interna), y en las sospechosas esa caída no aparece (4,31, 4,40 y 4,33). Un número global promedia esos comportamientos opuestos.

La tabla 4 muestra qué pasó al llevar estas medidas a prueba. D estimado alcanza un AUC de 0,67, con un intervalo que no incluye al 0,5, así que separa los grupos aunque de forma modesta. La saturación de periferia menos centro llega a 0,71, aunque hay que leerla con cuidado, porque sigue de cerca al brillo de la lesión ($\rho = -0{,}67$ en prueba) y ese brillo solo da un AUC parecido. Con estos datos no podemos separar los dos efectos. La saturación de piel menos lesión queda en 0,60, con un intervalo que incluye al 0,5, y además baja cuando M3 acierta más ($\rho = -0{,}42$ con el Dice), así que en parte mide errores de segmentación.

| Medida | AUC entrenamiento | AUC prueba | IC 95 % en prueba |
|---|---|---|---|
| D del dermatólogo (techo) | 0,92 | 0,88 | 0,81 a 0,94 |
| D estimado | 0,76 | 0,67 | 0,54 a 0,80 |
| Periferia menos centro, $S$ | 0,76 | 0,71 | 0,58 a 0,84 |
| Piel menos lesión, $S$ | 0,69 | 0,60 | 0,46 a 0,75 |
| Oscuridad de la lesión ($-V$) | 0,75 | 0,68 | 0,54 a 0,80 |

Tabla 4: Capacidad de cada medida para separar lesiones sospechosas de nevos comunes (140 imágenes de entrenamiento y 60 de prueba).

## 3.5. Clasificación

La tabla 5 y la figura 3 resumen la clasificación en prueba. El TDS automático separa las lesiones sospechosas de los nevos comunes con un AUC de 0,77, y su intervalo no incluye al 0,5, así que la primera parte de la hipótesis 2 se confirma. Por separado, los criterios que más aportan son A y C (AUC de 0,73 y 0,69), seguidos por D (0,67), mientras que B queda en 0,60. El TDS extendido llega a 0,79, pero la diferencia con el TDS es de 0,02 y su intervalo (de $-0{,}06$ a 0,09) incluye al cero, así que la segunda parte no se confirma. Sumar los contrastes de zonas no mejora la separación de forma significativa, posiblemente porque el primero de ellos sigue de cerca al brillo de la lesión, y los colores oscuros ya los cuenta $C$.

| Clasificador | Umbral | Sensibilidad | Especificidad | AUC (IC 95 %) |
|---|---|---|---|---|
| TDS, umbral clínico | 4,75 | 0,39 | 0,96 | 0,77 (0,65 a 0,89) |
| TDS, umbral de Youden | 3,25 | 0,69 | 0,88 | 0,77 (0,65 a 0,89) |
| TDS extendido, umbral de Youden | 3,49 | 0,72 | 0,75 | 0,79 (0,67 a 0,90) |

Tabla 5: Clasificación de las 60 imágenes de prueba en lesiones sospechosas y nevos comunes. Los umbrales de Youden se eligieron en entrenamiento.

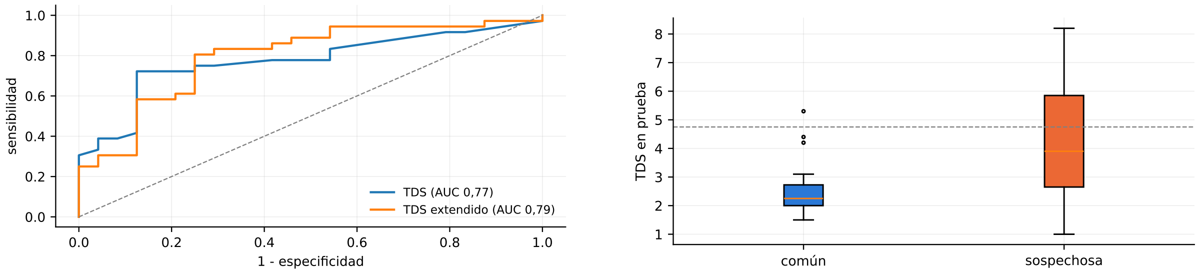

Figura 3: Curvas ROC del TDS y del TDS extendido en prueba (izquierda) y distribución del TDS por grupo, con el umbral clínico en línea punteada (derecha).

El umbral clínico resulta muy conservador con nuestro TDS, porque detecta sólo el 39 % de las sospechosas, aunque casi no se equivoca con los nevos comunes. El umbral de Youden queda más abajo (3,25) y equilibra mejor las dos medidas. Que el mejor umbral sea más bajo es esperable, porque nuestro $D$ adaptado parte de 0 y no de 1, y el borde automático suele dar valores bajos.

# 4. Conclusiones

La segmentación cumplió su objetivo, con un Dice medio de 0,916 en prueba y fallas en sólo 4 de las 200 imágenes. La compresión quedó caracterizada, aunque no se llegó al objetivo de máxima de repetir el algoritmo sobre imágenes comprimidas.

La hipótesis 1 no se confirmó. Quitar los pelos con un cierre no mejoró la segmentación y, en entrenamiento, resultó peor que el filtro de mediana. La causa es que el detector confunde con pelos parte de la red y de la textura oscura de la lesión, y al reconstruirlas la lesión se aclara y la segmentación queda corta.

Para estimar D buscamos cada estructura por separado, como hace el dermatólogo. Los detectores de velo y regresión mantuvieron en prueba un AUC de 0,93 y 0,79, y el D que resulta de contar las cinco estructuras separa los grupos (AUC 0,67), aunque todavía acierta el valor exacto en pocas imágenes. Mirar la lesión por zonas también aportó, porque la saturación de periferia menos centro se mantuvo en un AUC de 0,71, pero con 60 imágenes el intervalo es ancho y no alcanza para distinguirla del brillo de la lesión ni para afirmar que mejore a D.

A, B y C se pudieron medir, aunque sólo en parte como el dermatólogo. A coincide con él de forma aceptable ($\kappa = 0{,}38$) y falla cuando la asimetría está en el color y no en la forma, C coincide poco ($\kappa = 0{,}24$) y B separa poco porque en PH2 los nevos comunes tienen el borde más nítido. La circularidad, que no es parte de la regla, separó casi igual que A, y es una buena candidata a término extra del TDS.

El TDS automático separa las lesiones sospechosas de los nevos comunes (AUC 0,77), con lo que se confirma la primera parte de la hipótesis 2, pero agregarle los contrastes de zonas no mejoró esa separación de forma significativa, y la segunda parte no se confirma. Con el umbral de Youden, el TDS alcanza en prueba una sensibilidad de 0,69 y una especificidad de 0,88. Estos valores quedan por debajo de los del dermatólogo con la regla original (92,8 % y 90,3 %) y de los trabajos del estado del arte, aunque no son directamente comparables, porque esos trabajos separan melanomas de lesiones benignas y nosotros separamos nevos atípicos y melanomas de nevos comunes, una distinción más difícil.

Las limitaciones principales son la base, chica y de un solo equipo y un solo hospital, y el conjunto de prueba, que tiene sólo 60 imágenes y 9 con pelos. Además, D es una adaptación, la red atípica y los puntos y glóbulos se detectan con poca precisión, la referencia del rojo sale de una sola zona y la segmentación sobre el canal azul pierde justamente las zonas azul grisáceas que se asocian al melanoma, aunque con la máscara manual los criterios no mejoraron.

Como mejoras, proponemos que el detector de pelos no actúe sobre la red de la lesión, segmentar con información de color sin sumar fallas en el resto de las imágenes, mejorar los detectores de red atípica y de puntos y glóbulos, que son los más débiles, repetir el algoritmo sobre imágenes comprimidas y validarlo con otra base de imágenes.

## Referencias

[1] Franz Nachbar et al. «The ABCD rule of dermatoscopy: High prospective value in the diagnosis of doubtful melanocytic skin lesions». En: *Journal of the American Academy of Dermatology* 30.4 (1994), págs. 551-559. DOI: `10.1016/S0190-9622(94)70061-3`.

[2] Tim Lee et al. «DullRazor: A software approach to hair removal from images». En: *Computers in Biology and Medicine* 27.6 (1997), págs. 533-543. DOI: `10.1016/S0010-4825(97)00020-6`.

[3] Robert M. Haralick, K. Shanmugam e Its'hak Dinstein. «Textural features for image classification». En: *IEEE Transactions on Systems, Man, and Cybernetics* SMC-3.6 (1973), págs. 610-621. DOI: `10.1109/TSMC.1973.4309314`.

[4] Ralph P. Braun y Katrin Kerl. *Dermoscopic structures*. Dermoscopedia. URL: `https://dermoscopedia.org/Dermoscopic_structures` (visitado 05-11-2026).

[5] Gregory K. Wallace. «The JPEG still picture compression standard». En: *Communications of the ACM* 34.4 (1991), págs. 30-44. DOI: `10.1145/103085.103089`.

[6] M. Emre Celebi et al. «A methodological approach to the classification of dermoscopy images». En: *Computerized Medical Imaging and Graphics* 31.6 (2007), págs. 362-373. DOI: `10.1016/j.compmedimag.2007.01.003`.

[7] Andre Esteva et al. «Dermatologist-level classification of skin cancer with deep neural networks». En: *Nature* 542 (2017), págs. 115-118. DOI: `10.1038/nature21056`.

[8] Reda Kasmi y Karim Mokrani. «Classification of malignant melanoma and benign skin lesions: Implementation of automatic ABCD rule». En: *IET Image Processing* 10.6 (2016), págs. 448-455. DOI: `10.1049/iet-ipr.2015.0385`.

[9] Soumia Oukil et al. «Automatic segmentation and melanoma detection based on color and texture features in dermoscopic images». En: *Skin Research and Technology* 28.2 (2022), págs. 203-211. DOI: `10.1111/srt.13111`.

[10] Teresa Mendonça et al. «PH2: A dermoscopic image database for research and benchmarking». En: *35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC).* 2013, págs. 5437-5440. DOI: `10.1109/EMBC.2013.6610779`.

[11] Giuseppe Argenziano et al. «Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the Internet». En: *Journal of the American Academy of Dermatology* 48.5 (2003), págs. 679-693. DOI: `10.1067/mjd.2003.281`.

[12] Alexandru Telea. «An image inpainting technique based on the fast marching method». En: *Journal of Graphics Tools* 9.1 (2004), págs. 23-34. DOI: `10.1080/10867651.2004.10487596`.

[13] Zhou Wang et al. «Image quality assessment: From error visibility to structural similarity». En: *IEEE Transactions on Image Processing* 13.4 (2004), págs. 600-612. DOI: `10.1109/TIP.2003.819861`.

[14] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». En: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), págs. 62-66. DOI: `10.1109/TSMC.1979.4310076`.

[15] Tony F. Chan y Luminita A. Vese. «Active contours without edges». En: *IEEE Transactions on Image Processing* 10.2 (2001), págs. 266-277. DOI: `10.1109/83.902291`.

[16] Murali Anantha, Randy H. Moss y William V. Stoecker. «Detection of pigment network in dermatoscopy images using texture analysis». En: *Computerized Medical Imaging and Graphics* 28.5 (2004), págs. 225-234. DOI: `10.1016/j.compmedimag.2004.04.002`.

[17] Ilias Maglogiannis y Konstantinos K. Delibasis. «Enhancing classification accuracy utilizing globules and dots features in digital dermoscopy». En: *Computer Methods and Programs in Biomedicine* 118.2 (2015), págs. 124-133. DOI: `10.1016/j.cmpb.2014.12.001`.

[18] Maryam Sadeghi et al. «Detection and analysis of irregular streaks in dermoscopic images of skin lesions». En: *IEEE Transactions on Medical Imaging* 32.5 (2013), págs. 849-861.

[19] Giuseppe Di Leo et al. «Automatic diagnosis of melanoma: A software system based on the 7-point check-list». En: *43rd Hawaii International Conference on System Sciences.* 2010, págs. 1-10. DOI: `10.1109/HICSS.2010.76`.

[20] M. Emre Celebi et al. «Automatic detection of blue-white veil and related structures in dermoscopy images». En: *Computerized Medical Imaging and Graphics* 32.8 (2008), págs. 670-677. DOI: `10.1016/j.compmedimag.2008.08.003`.

[21] W. J. Youden. «Index for rating diagnostic tests». En: *Cancer* 3.1 (1950), págs. 32-35.

[22] Jacob Cohen. «A coefficient of agreement for nominal scales». En: *Educational and Psychological Measurement* 20.1 (1960), págs. 37-46. DOI: `10.1177/001316446002000104`.

[23] J. Richard Landis y Gary G. Koch. «The measurement of observer agreement for categorical data». En: *Biometrics* 33.1 (1977), págs. 159-174. DOI: `10.2307/2529310`.

# A. Anexo

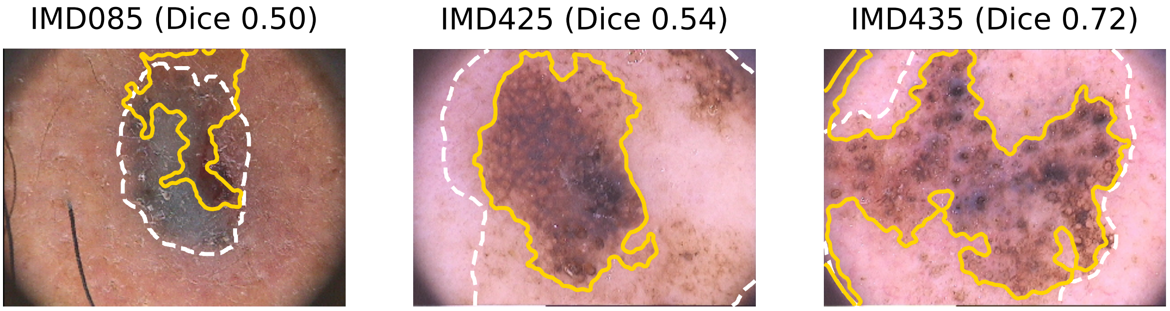
IMD085 (Dice 0.50)

IMD425 (Dice 0.54)

IMD435 (Dice 0.72)

Figura 4: Las imágenes de entrenamiento con peor Dice del método elegido. En blanco punteado, la máscara de PH2; en amarillo, la automática.

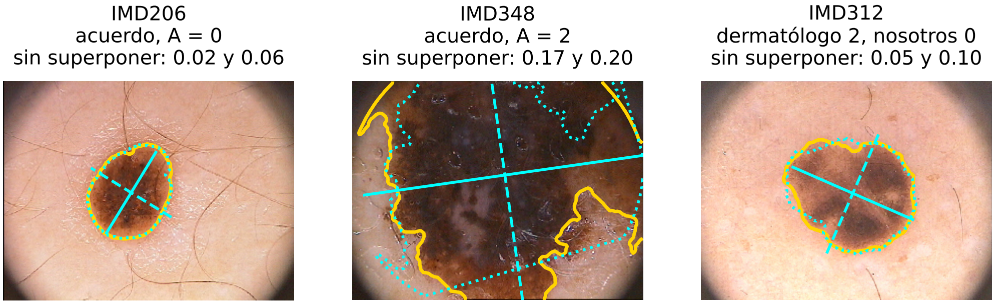
IMD206
acuerdo, A = 0
sin superponer: 0.02 y 0.06

IMD348
acuerdo, A = 2
sin superponer: 0.17 y 0.20

IMD312
dermatólogo 2, nosotros 0
sin superponer: 0.05 y 0.10

Figura 5: Ejes de simetría y reflejo de la máscara sobre el eje mayor en tres lesiones de entrenamiento. En IMD312 la forma es casi simétrica, pero el pigmento se concentra de un lado, y por eso el dermatólogo puso $A = 2$.

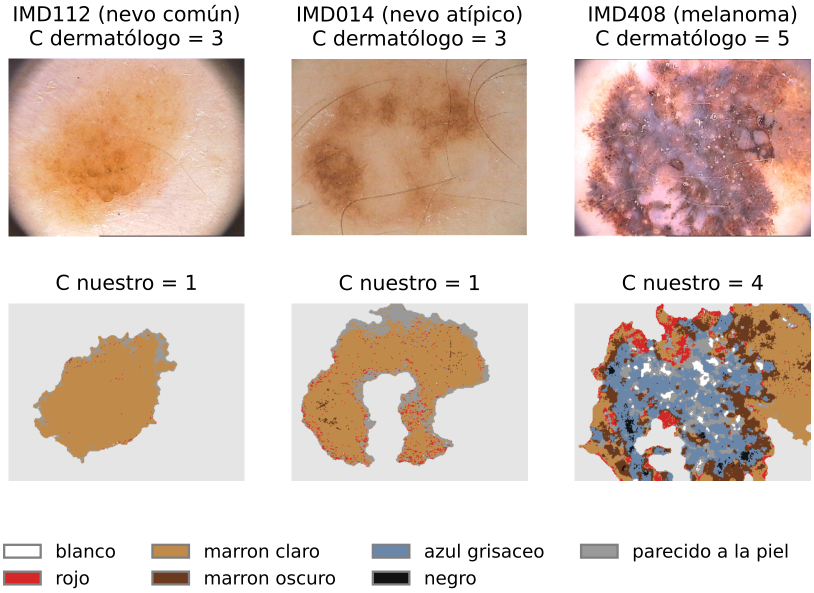
IMD112 (nevo común)
C dermatólogo = 3

IMD014 (nevo atípico)
C dermatólogo = 3

IMD408 (melanoma)
C dermatólogo = 5

C nuestro = 1

C nuestro = 1

C nuestro = 4

Figura 6: Mapa de colores de la lesión con más colores anotados de cada diagnóstico. En los dos nevos casi todo queda como marrón claro, y en el melanoma el blanco y el negro no llegan al 5 % de la lesión.

| Color | Zonas | $H$ | $S$ | $V$ |
|---|---|---|---|---|
| Blanco | 2 | 0,630 | 0,152 | 0,541 |
| Rojo | 1 | 0,976 | 0,212 | 0,492 |
| Marrón claro | 12 | 0,083 | 0,249 | 0,452 |
| Marrón oscuro | 13 | 0,060 | 0,242 | 0,300 |
| Azul grisáceo | 6 | 0,965 | 0,069 | 0,285 |
| Negro | 3 | 0,038 | 0,065 | 0,254 |

Tabla 6: Referencias de color en HSV, con la imagen dividida por el color de la piel, que queda en gris medio ($V = 0{,}5$). Cada una es la mediana de las zonas de entrenamiento de ese color.

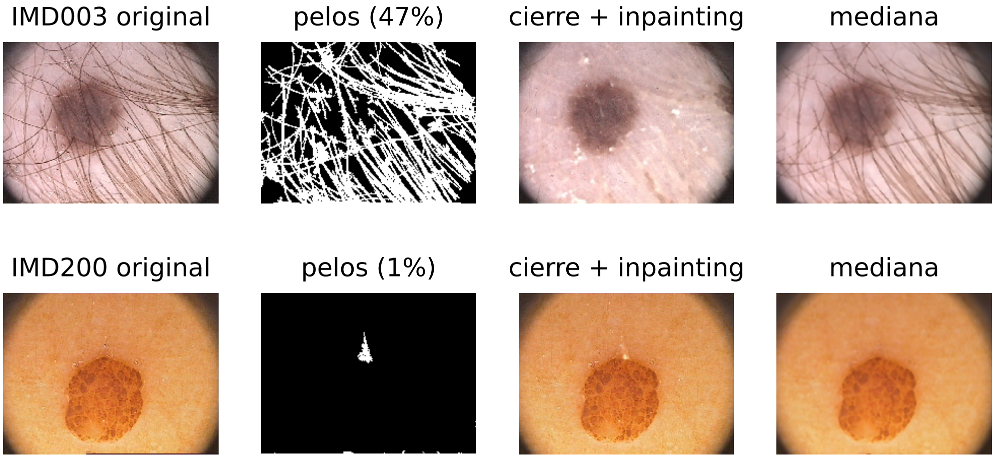
IMD003 original
pelos (47%)
cierre + inpainting
mediana
IMD200 original
pelos (1%)
cierre + inpainting
mediana

Figura 7: Remoción de pelos en una imagen con muchos pelos (IMD003) y en una sin pelos con red de pigmento (IMD200). Se muestran la original, los pelos detectados, el cierre con *inpainting* y el filtro de mediana.

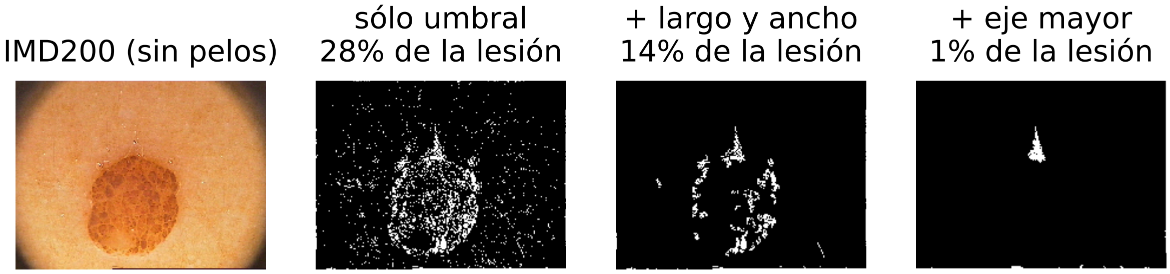
IMD200 (sin pelos)
sólo umbral
28% de la lesión
+ largo y ancho
14% de la lesión
+ eje mayor
1% de la lesión

Figura 8: Efecto del filtro de forma en la detección de pelos sobre IMD200, que no tiene pelos. Se comparan los candidatos del *black-hat* (sólo umbral), el filtro por largo y ancho y el filtro completo con eje mayor. Se indica la fracción de la lesión marcada como pelo.

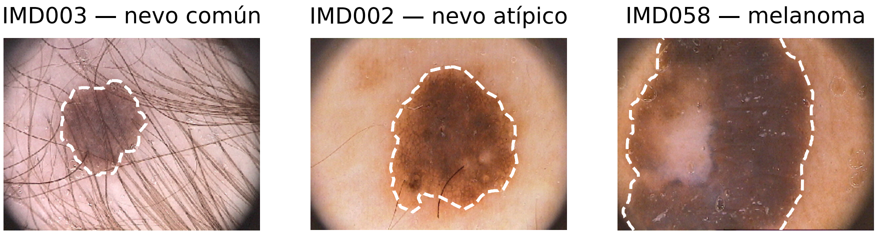
IMD003 — nevo común
IMD002 — nevo atípico
IMD058 — melanoma

Figura 9: Un ejemplo de cada diagnóstico de PH2 con el contorno de su máscara manual.

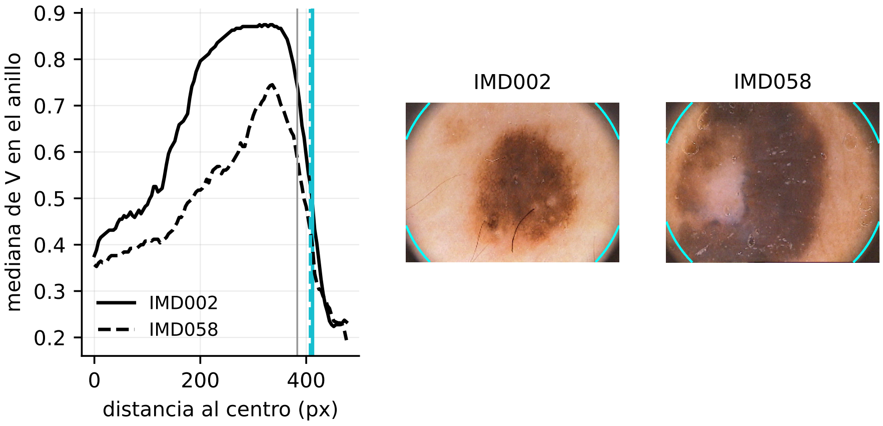

IMD002

IMD058

Figura 10: Detección del viñeteo. A la izquierda, la mediana del brillo $V$ en anillos concéntricos para una imagen típica (IMD002) y una con la lesión tocando el borde (IMD058), con el radio detectado en líneas verticales. A la derecha, el límite de la zona válida sobre ambas imágenes.

| Etapa | Parámetro | Valor |
|---|---|---|
| Viñeta | Anillo / umbral / radio mínimo | 4 px / 0,6 del máximo / 0,8 semidiagonal |
| Pelos | Elemento estructurante | segmento de 21 px, 12 orientaciones |
| | Umbral del *black-hat* | 0,10 |
| | Forma (largo / ancho / eje mayor) | $\geq 60$ px / $\leq 8$ px / $\geq 80$ px |
| | Reconstrucción | *inpainting* de Telea, radio 5 px |
| Comparación | Filtro de mediana | $9 \times 9$ por canal |

Tabla 7: Parámetros del mejoramiento (módulo M1), elegidos con el conjunto de entrenamiento.

| Calidad | Tasa | PSNR (dB) | PSNR lesión (dB) | SSIM | $\Delta E$ lesión |
|---|---|---|---|---|---|
| 95 | 8,2 | 41,1 | 40,7 | 0,97 | 1,9 |
| 75 | 23,7 | 35,9 | 34,9 | 0,89 | 2,7 |
| 50 | 39,7 | 34,5 | 33,4 | 0,85 | 3,2 |
| 25 | 67,7 | 32,8 | 31,7 | 0,80 | 3,9 |
| 10 | 121,8 | 29,6 | 28,7 | 0,70 | 5,8 |

Tabla 8: Compresión JPEG, con la mediana de cada métrica sobre las 140 imágenes de entrenamiento.

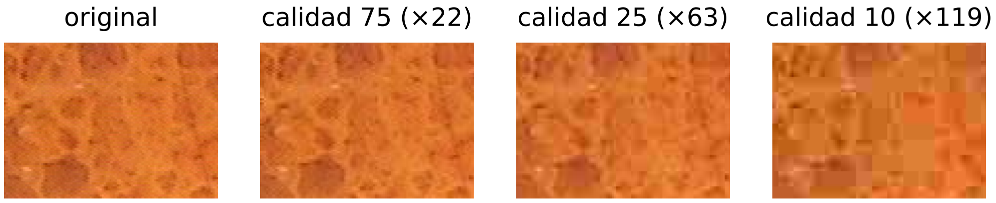

original

calidad 75 (×22)

calidad 25 (×63)

calidad 10 (×119)

Figura 11: Detalle de la red de pigmento de IMD200 en la imagen original y comprimida a calidades 75, 25 y 10 (entre paréntesis, la tasa de compresión).

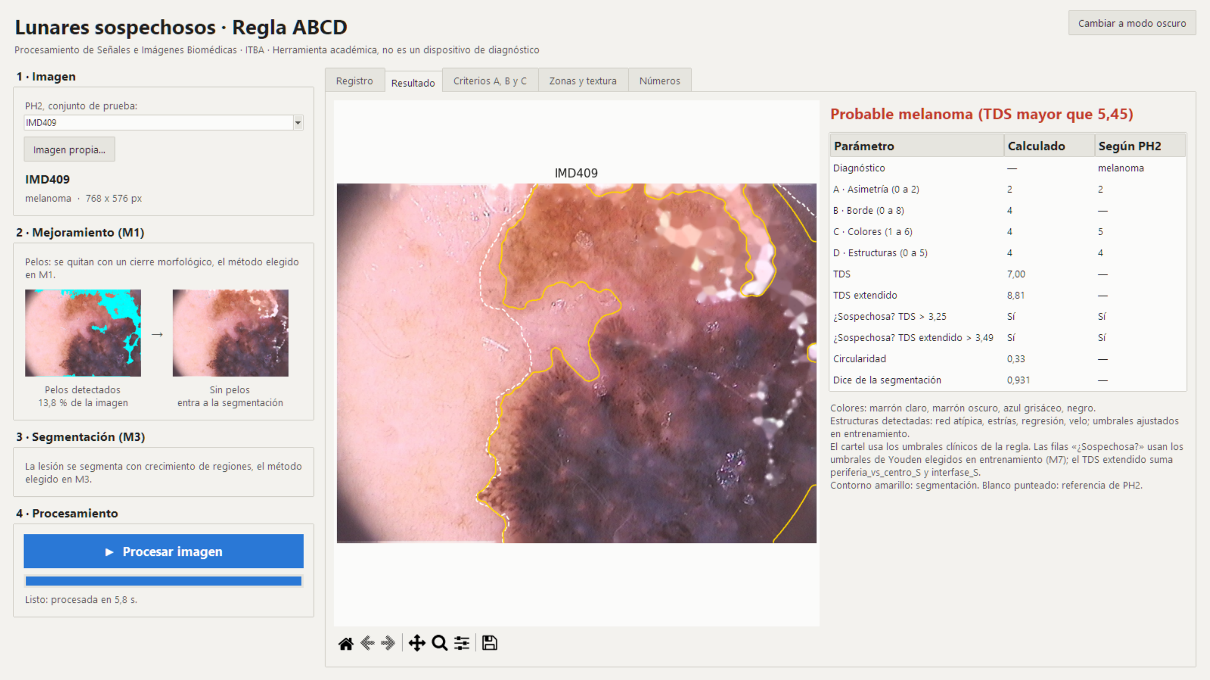

**Lunares sospechosos · Regla ABCD**

Procesamiento de Señales e Imágenes Biomédicas · ITBA · Herramienta académica, no es un dispositivo de diagnóstico

**1 · Imagen**

PH2, conjunto de prueba: IMD409

**IMD409**

melanoma · 768 x 576 px

**2 · Mejoramiento (M1)**

Pelos: se quitan con un cierre morfológico, el método elegido en M1.

Pelos detectados
13,8 % de la imagen

Sin pelos
entra a la segmentación

**3 · Segmentación (M3)**

La lesión se segmenta con crecimiento de regiones, el método elegido en M3.

**4 · Procesamiento**

Listo: procesada en 5,8 s.

**Probable melanoma (TDS mayor que 5,45)**

| Parámetro | Calculado | Según PH2 |
|---|---|---|
| Diagnóstico | — | melanoma |
| A · Asimetría (0 a 2) | 2 | 2 |
| B · Borde (0 a 8) | 4 | — |
| C · Colores (1 a 6) | 4 | 5 |
| D · Estructuras (0 a 5) | 4 | 4 |
| TDS | 7,00 | — |
| TDS extendido | 8,81 | — |
| ¿Sospechosa? TDS > 3,25 | Sí | Sí |
| ¿Sospechosa? TDS extendido > 3,49 | Sí | Sí |
| Circularidad | 0,33 | — |
| Dice de la segmentación | 0,931 | — |

Colores: marrón claro, marrón oscuro, azul grisáceo, negro.
Estructuras detectadas: red atípica, estrías, regresión, velo; umbrales ajustados en entrenamiento.
El cartel usa los umbrales clínicos de la regla. Las filas «¿Sospechosa?» usan los umbrales de Youden elegidos en entrenamiento (M7); el TDS extendido suma periferia_vs_centro_S y interfase_S.
Contorno amarillo: segmentación. Blanco punteado: referencia de PH2.

Figura 12: Interfaz gráfica con un melanoma de prueba (IMD409). A la izquierda, los pasos del algoritmo, y a la derecha, la segmentación y la tabla con los criterios calculados junto a los del dermatólogo.

| Carpeta | Archivo | Contenido |
|---|---|---|
| raíz | `main.py` | Verifica módulos, procesa imágenes y genera resultados |
| M0 | `carga_de_datos.py` | Lectura de PH2, alcance y partición |
| M1 | `mejoramiento.py` | Viñeta y remoción de pelos |
| M2 | `compresion.py` | JPEG, tasa de compresión, PSNR y SSIM |
| M3 | `segmentacion.py` | Métodos de segmentación, posprocesamiento y Dice |
| M4 | `criterios_abc.py` | Asimetría, borde, colores y circularidad |
| M5 | `textura_criterio_d.py` | GLCM y detectores de las estructuras de D |
| M6 | `zonas_y_mapas.py` | Zonas de la lesión y mapas de características |
| M7 | `clasificacion_resultados.py` | TDS, umbrales, métricas y figuras finales |
| herramientas | `*.py` | Recorrido completo, verificación y gráficos |
| interfaz | `app.py` | Interfaz gráfica |

Tabla 9: Archivos de Python del repositorio. Cada módulo M$n$ está en `modulos/mn_.../`.

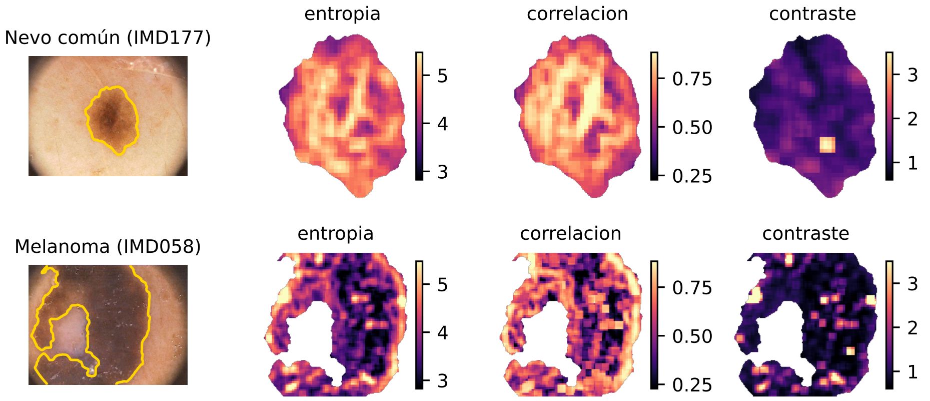

Figura 13: Mapas de entropía, correlación y contraste en un nevo común y un melanoma de entrenamiento. El hueco del mapa del melanoma es una zona central clara que la máscara automática dejó afuera.