Instituto Tecnológico de Buenos Aires

16.63 Procesamiento de Señales e Imágenes Biomédicas
2026 — Segundo cuatrimestre

Comisión BIO

Detección de lunares sospechosos mediante imágenes dermatoscópicas

Trabajo Práctico de Imágenes (TPI)

PSIB2026Q2-TPI-Grupo02-CassanoNieto DElia Ortega

Grupo 2

Integrante	Legajo
Cassano Nieto, Facundo Tomás	65555
D'Elía, Lucas Valentín	65414
Ortega, Facundo	65560

Docentes: Roberto Sebastián Tomás, Lucila Capurro,
Francisco Joaquín Tassara y Victoria Reppucci

5 de noviembre de 2026

Resumen

El melanoma se parece a un lunar común en sus comienzos, y la regla dermatoscópica ABCD ayuda a distinguirlos a partir de la asimetría, el borde, los colores y las estructuras de la lesión. En este trabajo se desarrolló un algoritmo que mide esos criterios en las 200 imágenes de la base PH2 con procesamiento clásico de imágenes, sin entrenar un clasificador. Las imágenes se separaron en 140 de entrenamiento y 60 de prueba, y todo parámetro se fijó con las primeras. La segmentación por crecimiento de regiones alcanzó un Dice medio de 0,916 en prueba. Quitar los pelos con un cierre morfológico no mejoró la segmentación, por lo que la primera hipótesis no se confirmó. El criterio D, estimado detectando cada estructura por separado, separó en prueba las lesiones sospechosas de los lunares comunes con un AUC de 0,67 (IC 95 %, 0,54 a 0,80), y la diferencia de saturación entre la periferia y el centro de la lesión, con 0,71 (0,58 a 0,84). La asimetría y los colores medidos coincidieron con los del dermatólogo con un κ de 0,38 y 0,24. El TDS automático separó las lesiones sospechosas de los nevos comunes con un AUC de 0,77 (0,65 a 0,89) y, con un umbral elegido en entrenamiento, una sensibilidad de 0,69 y una especificidad de 0,88. Agregarle términos de zonas no mejoró esa separación de forma significativa, por lo que la segunda hipótesis se confirmó sólo en parte.

Índice

1. Introducción **1**
1.1. Problemática . . . 1
1.2. Marco teórico . . . 1
1.3. Estado del arte . . . 1
1.4. Pregunta, objetivos e hipótesis . . . 2

2. Materiales y métodos **2**
2.1. Base de datos y alcance . . . 2
2.2. Esquema del algoritmo . . . 3
2.3. Pre-procesamiento . . . 3
2.4. Segmentación . . . 4
2.5. Criterios A, B y C . . . 4
2.6. Textura y criterio D adaptado . . . 4
2.7. Zonas de la lesión y mapas de características . . . 5
2.8. Clasificación y evaluación . . . 5
2.9. Interfaz gráfica y código . . . 5

3. Resultados **5**
3.1. Pre-procesamiento . . . 5
3.2. Segmentación . . . 6
3.3. Criterios y comparación con el dermatólogo . . . 6
3.4. Zonas y mapas de características . . . 7
3.5. Clasificación . . . 8

4. Conclusiones **8**

Referencias **9**

A. Anexo **11**

1. Introducción

1.1. Problemática

El melanoma es un cáncer de piel cuyo pronóstico depende de cuán temprano se lo detecte. Al comienzo se parece mucho a un lunar común, y el dermatólogo lo evalúa con el dermatoscopio, una lente de aumento con iluminación propia. Para hacerlo de forma sistemática usa la regla ABCD, que puntúa la asimetría (A, de 0 a 2 según en cuántos ejes es asimétrica la lesión), el borde (B, de 0 a 8 según en cuántos sectores el pigmento termina de forma abrupta), los colores (C, de 1 a 6) y las estructuras diferenciales, como la red de pigmento o los glóbulos (D, de 1 a 5), y los combina en el puntaje dermatoscópico total

$$\mathrm{TDS} = 1{,}3\,A + 0{,}1\,B + 0{,}5\,C + 0{,}5\,D. \tag{1}$$

Un TDS menor a 4,75 indica una lesión benigna; entre 4,75 y 5,45, una lesión sospechosa, y mayor a 5,45, una lesión probablemente maligna [1]. La evaluación es visual y su precisión depende de la experiencia de quien la hace.

1.2. Marco teórico

La imagen dermatoscópica es una imagen RGB en la que el color tiene valor diagnóstico, porque depende de la profundidad del pigmento. Los marrones y el negro indican melanina en la epidermis, el azul grisáceo indica melanina en la dermis y el blanco, zonas de regresión. Por eso conviene trabajar en el espacio HSV, que separa el matiz (H) y la saturación (S) del brillo (V). Antes de medirlo hay que lidiar con los artefactos. La lente circular deja esquinas oscuras (viñeteo), y los pelos que cruzan la lesión desplazan el borde segmentado y agregan un color que no le pertenece. Estos pueden quitarse con un cierre morfológico con un elemento estructurante más ancho que un pelo y más chico que la lesión, idea en la que se basa DullRazor [2].

Además del color, la regla mira las estructuras diferenciales, que son patrones que se repiten dentro de la lesión y que pueden describirse como textura. Una forma clásica de medirla es la matriz de co-ocurrencia de niveles de gris (GLCM), que cuenta con qué frecuencia aparecen juntos dos niveles de gris a una distancia y dirección dadas, y de la que se obtienen atributos como la entropía, el contraste y la correlación [3]. Sin embargo, estas estructuras no se reparten al azar dentro de la lesión. Las estrías, por ejemplo, aparecen en la periferia de la lesión [4]. Un único número calculado sobre toda la lesión puede entonces promediar zonas que se comportan distinto, y comparar la lesión con la piel vecina permite medir de forma continua el cambio que puntúa el criterio B.

Este detalle puede perderse al guardar las imágenes en JPEG [5], que guarda el color a la mitad de resolución, divide la imagen en bloques de 8×8 y cuantiza sus coeficientes de la transformada discreta del coseno según una calidad de 1 a 100, descartando sobre todo las frecuencias altas.

1.3. Estado del arte

Los sistemas de diagnóstico asistido segmentan la lesión, miden descriptores de forma, color y textura y los entregan a un clasificador [6]. Las redes neuronales convolucionales ya alcanzan un desempeño comparable al de los dermatólogos [7], pero no muestran en qué se basa cada decisión ni permiten comprobar si cada criterio se mide bien.

Medir la regla ABCD de forma automática tampoco es una idea nueva. Un trabajo la implementó sobre 200 imágenes dermatoscópicas, 80 de melanomas y 120 de lesiones benignas, y obtuvo una sensibilidad de 91,25 % y una especificidad de 95,83 % [8]. Otro, sobre PH2, combinó color y textura con una máquina de vectores de soporte y separó melanomas de nevos con una sensibilidad de 99,25 % y una especificidad de 99,58 % [9]. Como referencia humana, el trabajo

original de la regla informa 92,8 % y 90,3 % [1]. Ninguno separa nevos comunes de nevos atípicos y melanomas, que es la pregunta de este trabajo.

Lo que buscamos aportar es una medición revisable paso a paso, en la que cada criterio se compara con el dermatólogo y la clasificación usa la fórmula de la regla, sin entrenar un clasificador.

1.4. Pregunta, objetivos e hipótesis

Pregunta y objetivo general. ¿Pueden medirse automáticamente los criterios de la regla ABCD, complementarse con descriptores por zona de la lesión y distinguir lesiones sospechosas de lunares comunes? Buscamos desarrollar un algoritmo que haga esas mediciones y estime si la lesión es sospechosa, con una interfaz que muestre cada etapa.

Objetivos específicos. (1) Quitar los artefactos (viñeteo y pelos) y medir su efecto en la segmentación; (2) caracterizar la pérdida por compresión JPEG; (3) segmentar la lesión y validar contra la máscara manual (Dice); (4) medir A, B y C y comparar A y C con el dermatólogo (κ de Cohen); (5) estimar un criterio D adaptado detectando cada estructura en la imagen; (6) construir mapas de características y descriptores por zona y evaluar si mejoran la clasificación al agregarse al TDS; (7) clasificar con el TDS y medir sensibilidad, especificidad y AUC en un conjunto de prueba.

Hipótesis. (H1) Quitar los pelos con un cierre morfológico mejora la segmentación de las imágenes con pelos respecto de no quitarlos y de un filtro de mediana. (H2) El TDS automático separa las lesiones sospechosas de los nevos comunes, y agregarle términos de textura y de zonas mejora esa separación. Como objetivo de máxima, se propuso además evaluar si el desempeño se mantiene sobre imágenes comprimidas con JPEG.

2. Materiales y métodos

2.1. Base de datos y alcance

Se usa la base PH2 [10], del Hospital Pedro Hispano (Portugal), con 200 imágenes dermatoscópicas RGB de 8 bits adquiridas con el mismo equipo, 80 de nevos comunes, 80 de nevos atípicos y 40 de melanomas. Las imágenes tienen 24 tamaños distintos y la lesión ocupa entre el 3 % y el 98 % de la imagen (mediana 23 %). Cada una trae la máscara manual y la evaluación de un dermatólogo (diagnóstico, asimetría, colores y estructuras). Se considera *sospechosa* toda lesión con diagnóstico de nevo atípico o melanoma (120 imágenes) y *no sospechosa* a los nevos comunes (80).

La regla original define D como la cantidad de estructuras presentes entre la red de pigmento, las áreas sin estructura, las estrías, los puntos y los glóbulos, y por eso va de 1 a 5 [1]. PH2 no anota esas mismas estructuras, ya que junta puntos y glóbulos, no anota las áreas sin estructura y sí anota la regresión y el velo azul-blanquecino. Usamos entonces un *D adaptado*, que cuenta cuántas de las cinco estructuras de PH2 marcó el dermatólogo (red atípica, puntos o glóbulos, estrías, regresión y velo) y va de 0 a 5. La red se cuenta sólo cuando es atípica, porque en PH2 todas las lesiones tienen red y la atípica es la que se asocia al melanoma [11]. Así definido, el D medio es 0,65 en los nevos comunes, 1,79 en los atípicos y 3,12 en los melanomas.

Las imágenes se dividieron de forma estratificada y con semilla fija en entrenamiento (140, con 56 nevos comunes, 56 atípicos y 28 melanomas) y prueba (60, con 24, 24 y 12). Todos los umbrales y parámetros se eligen sólo con entrenamiento, y prueba se usa únicamente para las métricas finales.

2.2. Esquema del algoritmo

La figura 1 muestra el recorrido de una imagen por el algoritmo. La compresión (M2) no forma parte de ese recorrido, y se estudia aparte para saber qué se pierde al guardar las imágenes en JPEG.

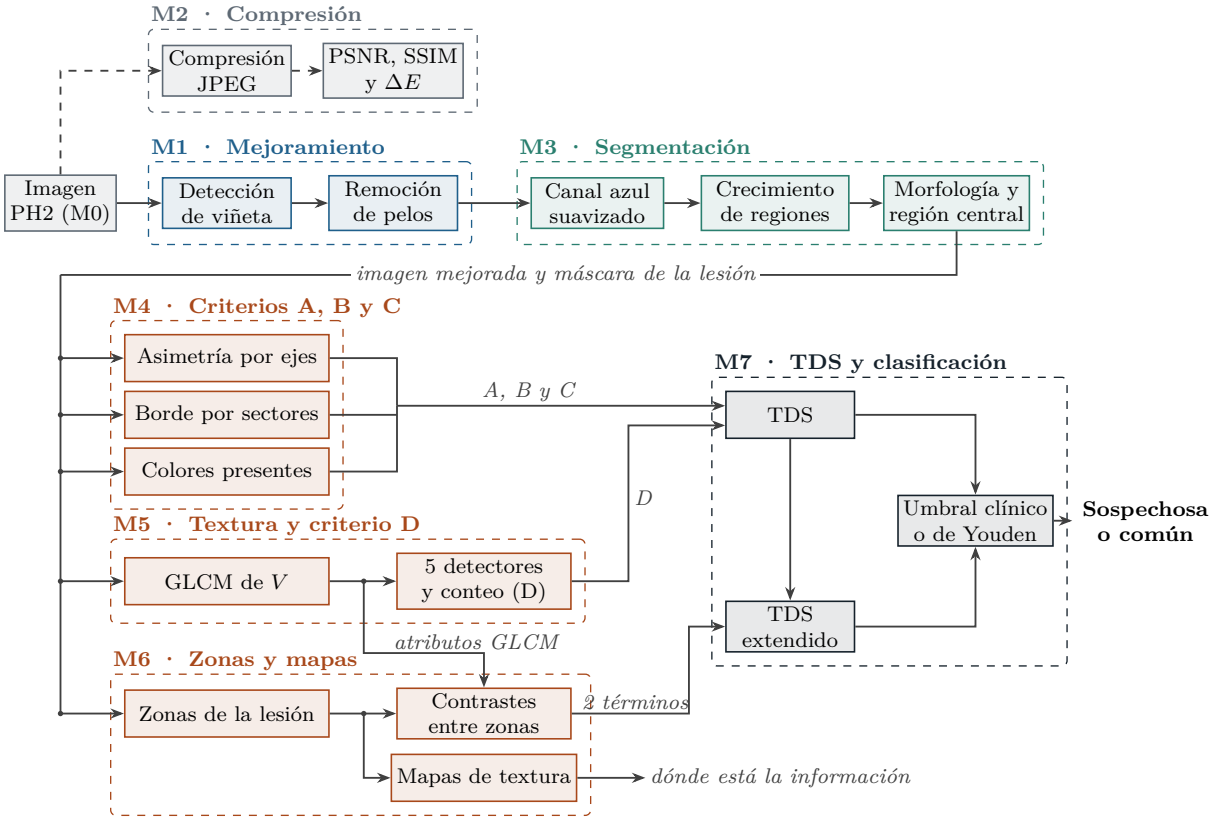


Figura 1: Diagrama de bloques del algoritmo. Los recuadros agrupan los bloques de cada módulo del repositorio, y la línea punteada marca el estudio de compresión, que queda fuera del recorrido principal.

2.3. Pre-procesamiento

Con las imágenes de entrenamiento se eligió el canal de trabajo, calculando en cada imagen el área bajo la curva ROC (AUC) de separar 2000 píxeles de lesión y 2000 de piel con un umbral sobre cada canal (R, G, B, H, S, V, L de Lab y gris).

Viñeteo. Las esquinas oscuras se excluyen con una máscara de píxeles válidos. Un umbral fijo de brillo no sirve, porque captura también zonas oscuras de 124 de las 140 lesiones de entrenamiento. Como la viñeta es circular y centrada, se calcula la mediana de V en anillos concéntricos de 4 px, que no cambia por una lesión que ocupa sólo parte del anillo. La viñeta empieza en el primer anillo cuya mediana cae por debajo del 60 % del anillo más brillante, y nunca antes del 80 % de la semidiagonal, para no cortar lesiones grandes.

Pelos. Se detectan con un cierre morfológico del gris con segmentos de 21 px en 12 orientaciones, y son candidatos los píxeles donde la diferencia entre el cierre y la imagen (*black-hat*) supera 0,10 [2]. Como la red de pigmento también es oscura y fina, sólo se conservan las regiones de al menos 60 px de largo, como mucho 8 px de ancho y un eje mayor de 80 px o más. Esos píxeles se reconstruyen por *inpainting* [12] y el resto de la imagen no cambia. Para la hipótesis 1 se compara con no quitar los pelos y con un filtro de mediana de 9×9 por canal.

Compresión. Cada imagen de entrenamiento se comprimió con JPEG a calidades 95, 75, 50, 25 y 10, y se midieron la tasa de compresión, el PSNR (en toda la imagen y en la lesión), el SSIM

[13] y la diferencia de color media en la lesión en Lab (ΔE, CIE76), cuyo umbral aproximado de percepción es 2,3.

2.4. Segmentación

Se segmenta sobre el canal azul suavizado con un filtro gaussiano, para que el pigmento y los puntos no dejen un borde dentado. No se suaviza en el mejoramiento porque eso borraría la red que miden M4 y M5.

Se compararon cinco métodos. El umbral de Otsu [14] se calcula sólo con los píxeles válidos. El crecimiento de regiones arranca del píxel más oscuro de un recuadro central y agrega vecinos mientras no superen un límite de brillo a mitad de camino entre la lesión (percentil 5 del recuadro) y la piel (percentil 90 de la zona válida), de modo que se adapta a lesiones oscuras y claras. También se probaron *watershed*, k-means en Lab y Chan-Vese [15] desde el contorno de Otsu. A todas las salidas se les aplica una apertura, un cierre, la selección de la región central y el relleno de huecos. Los parámetros se eligieron con una grilla sobre entrenamiento, tomando la combinación de mayor Dice medio, y se considera mal segmentada una imagen con Dice menor a 0,7.

2.5. Criterios A, B y C

Los criterios se miden sobre la máscara automática y cada umbral se eligió en entrenamiento.

Asimetría. La máscara se refleja sobre sus dos ejes principales, obtenidos de los momentos de segundo orden, y se mide qué fracción de la lesión queda sin pareja. Un eje es asimétrico si esa fracción supera 0,11, el umbral de mayor κ con el dermatólogo, y A es la cantidad de ejes asimétricos.

Borde. El contorno se divide en 8 sectores de 45° desde el eje mayor, y en cada uno se promedia el gradiente de Sobel de V, sin contar los puntos pegados al marco de la foto. Además del gradiente crudo se probó dividirlo por el salto de brillo entre lesión y piel. Como PH2 no anota B, el umbral de sector abrupto es el que mejor separa los nevos comunes de las sospechosas.

Color. Una referencia fija de cada color no sirve, porque en las zonas de color de PH2 el azul grisáceo es casi igual al negro y todo cambia con la luz y el tono de piel. Por eso cada imagen se divide por el color de la piel de un anillo alrededor de la lesión, y así los colores se ordenan con sentido (tabla 6 del anexo). Las referencias son la mediana en HSV de las zonas de cada color en entrenamiento. PH2 no trae zonas rojas, así que revisamos a mano las 7 imágenes con rojo anotado, pero sólo en una (IMD035) había una zona claramente roja, de la que sale esa referencia. Cada píxel se asigna al color más cercano o a la piel, y un color está presente si ocupa más del 5 % de la lesión. Se calcula además la circularidad 4π área/perímetro^2.

2.6. Textura y criterio D adaptado

La GLCM se calcula sobre V con los pares de píxeles dentro de la lesión, promediada en cuatro direcciones, y de ella se obtienen la energía, la entropía, el contraste, el IDM, la correlación, el *cluster shade* y el *cluster prominence* [3]. Se usan 32 niveles y distancia 1, la escala de las líneas finas de la red.

El D adaptado se estima como lo cuenta el dermatólogo, buscando cada estructura con una medida basada en cómo se ve. Para la red atípica, que tiene líneas de distinto grosor y zonas sin red, se mide cuánto varía el contraste local (desvío sobre media del mapa de contraste de M6), ya que la red se reconoce por su textura [16]. Los puntos y glóbulos se cuentan por unidad de área [17] con un *black-hat* con un disco de 6 px y una apertura con un disco de 2 px que borra las líneas de la red. Las estrías, líneas oscuras que salen radialmente del borde [4], se marcan con la matriz Hessiana y se mide qué parte de un anillo de 15 px a cada lado del borde tiene líneas que apuntan hacia afuera. La regresión y el velo se reconocen por el color [18, 19]. La

regresión es más clara y menos saturada que la piel, y como M3 suele dejarla fuera de la máscara, se busca en la envolvente convexa. El velo, única estructura azulada, se mide con el percentil 90 de $B - R$ en la lesión. Cada estructura está presente si su medida supera un umbral, y D es la cantidad detectada. Los umbrales se eligen en entrenamiento con el índice de Youden [20], $J = \text{sensibilidad} + \text{especificidad} - 1$, que equilibra no perder estructuras y no inventarlas.

2.7. Zonas de la lesión y mapas de características

Siguiendo la devolución del anteproyecto, se miran por separado el centro, la periferia y la interfase con la piel, definidos con la transformada de distancia al borde (figura 9 del anexo). El centro es donde la distancia supera la mitad de su máximo y la periferia es el resto. Las interfases interna y externa son anillos de 15 px a cada lado del borde, ancho que sale del perfil de brillo, que en entrenamiento llega al 90 % del de la piel a 12 px (mediana) y 19 px (percentil 75).

En cada zona se miden el color medio en HSV y los atributos GLCM de V, y con ellos 10 contrastes, periferia menos centro y piel menos lesión para H, S, V, contraste y entropía. Los mapas de atributos GLCM, en ventanas de 31 px cada 8 px, muestran dónde está la información.

2.8. Clasificación y evaluación

Una lesión es sospechosa si su TDS (ec. 1) supera un umbral. Se compara el umbral clínico (4,75), fijado para el D original, con el de Youden en entrenamiento. Para la hipótesis 2, el TDS extendido suma dos de los 10 contrastes de zonas, de color y de textura, estandarizados con la media y el desvío de entrenamiento, y se vuelve a elegir el umbral. Los términos, elegidos en entrenamiento, son la saturación de periferia menos centro (AUC 0,76) y la de piel menos lesión (AUC 0,69). Se descartó el contraste de V entre piel y lesión (AUC 0,74) porque su correlación de Spearman con el primero es $\rho = 0{,}68$, mientras que la de los dos elegidos es 0,08.

La segmentación se compara con la máscara de PH2 mediante el coeficiente de Dice, y A, C y D con el dermatólogo mediante el κ de Cohen [21], que entre 0,21 y 0,40 indica acuerdo aceptable y entre 0,41 y 0,60, moderado [22]. Para H1 se usa la prueba de Wilcoxon de rangos con signo, porque el Dice se mide de a pares en las mismas imágenes. El intervalo de confianza del 95 % del AUC sale de un *bootstrap* de percentiles con 2000 sorteos con reposición dentro de cada grupo, y dos AUC se comparan con el mismo sorteo, considerando significativa la diferencia si su intervalo no incluye al cero.

2.9. Interfaz gráfica y código

La interfaz, en tkinter (figura 8 del anexo), se abre con `python interfaz/app.py`. Se elige una imagen de prueba de PH2 o una propia y se aprieta *Procesar imagen*, que corre el algoritmo con las mismas funciones de los módulos. La columna izquierda muestra cada paso, y las pestañas, el avance, el resultado con A, B, C, D, el TDS, el TDS extendido y la clasificación junto a lo anotado por el dermatólogo, los ejes, el borde y el mapa de colores, las zonas y los mapas de textura, y los atributos GLCM. El código está en el repositorio de la carátula, con un `.py` y un cuaderno por módulo (tabla 8 del anexo), y la entrega incluye la presentación oral (`PSIB2026Q2-TPI-Grupo02-presentacion.pptx`).

3. Resultados

3.1. Pre-procesamiento

El canal azul es el que mejor separa la lesión de la piel en entrenamiento (AUC medio 0,976, seguido por G con 0,965), porque la melanina absorbe más la luz azul, y V, propuesto en el anteproyecto, queda entre los peores (0,902). Por eso se segmenta sobre B, y el borde se sigue midiendo sobre V, donde interesa el cambio de brillo. Con el perfil radial de la viñeta, sólo 4

de las 200 imágenes pierden más del 2 % de la lesión (máximo 5,9 %). El filtro de forma de los pelos evita borrar la red, ya que en IMD200, sin pelos, el umbral solo marca como pelo el 28 % de la lesión y el filtro completo el 1 % (figura 6 del anexo).

Hipótesis 1. Se consideran con pelos las imágenes con más del 10 % de sus píxeles marcados, 30 de entrenamiento y 9 de prueba. La hipótesis no se confirmó (tabla 1). En entrenamiento el cierre empeora más imágenes de las que mejora, con diferencia significativa sólo frente a la mediana, y en prueba no hay diferencia. El promedio de entrenamiento cae por cuatro imágenes que pierden más de 0,1 de Dice. En ellas el detector marca como pelo entre el 46 y el 78 % de la lesión, porque confunde la red y la textura oscura con pelos, y el *inpainting* aclara la lesión, que M3 recorta. Se mantiene el cierre porque no suaviza la red que mide M5 y porque cambiarlo después de mirar prueba invalidaría la evaluación.

	Dice medio			Cierre mejora / empeora (p)	
Conjunto (imágenes)	Sin quitar	Mediana	Cierre	Frente a sin quitar	Frente a mediana
Entrenamiento (30)	0,893	0,898	0,873	10 / 20 (0,10)	9 / 21 (0,025)
Prueba (9)	0,841	0,841	0,838	4 / 5 (0,65)	3 / 6 (0,36)

Tabla 1: Segmentación de las imágenes con pelos según cómo se quitan. El valor p es de la prueba de Wilcoxon.

Compresión. A calidad 95 el archivo ocupa unas 8 veces menos, con un PSNR en la lesión de 40,7 dB, un SSIM de 0,97 y un ΔE de 1,9, imperceptible (tabla 7 del anexo). Desde calidad 75 el ΔE (2,7) supera el umbral de percepción, así que los colores en los que se basa C cambian de forma visible, y a calidad 10 el PSNR baja a 28,7 dB, el SSIM a 0,70 y la red se reemplaza por bloques de 8×8 (figura 7 del anexo).

3.2. Segmentación

Los cinco métodos quedaron muy cerca en entrenamiento (tabla 5 del anexo). Elegimos el crecimiento de regiones ($\sigma = 4$ px, tolerancia 0,5, apertura de 3 px y cierre de 10 px), que falla en una imagen menos que *watershed* y es casi diez veces más rápido. Otsu y Chan-Vese tienen la mediana más alta, pero fallan en 6 y 7 imágenes, porque en las lesiones chicas el histograma casi no tiene pico de lesión y el umbral se corre hacia la piel.

En prueba, el crecimiento de regiones da un Dice medio de 0,916 y una mediana de 0,946, parecidos a los de entrenamiento. Encuentra el 82,8 % de los píxeles de lesión y marca como lesión sólo el 1,1 % de los de piel, así que su error típico es quedarse corto. Falla en 2 imágenes de prueba y 2 de entrenamiento, las 4 melanomas con azul grisáceo que dejó afuera (figura 3 del anexo), porque ese color refleja bastante luz azul y en B se ve casi como la piel. Ningún método resolvió esos casos sin empeorar el resto.

3.3. Criterios y comparación con el dermatólogo

Asimetría. El κ con el dermatólogo es 0,44 en entrenamiento y 0,38 en prueba, con coincidencia exacta en el 67 % de las imágenes de prueba. Muchos desacuerdos aparecen porque el dermatólogo también mira cómo está repartido el pigmento, y el programa sólo mira la forma (figura 4 del anexo).

Borde. El gradiente normalizado separó al revés de lo esperado (AUC entre 0,24 y 0,38), porque en PH2 los nevos comunes suelen tener borde nítido y los atípicos y melanomas, bordes que se desvanecen. Elegimos el gradiente crudo con umbral 0,0513, el único que suma en el sentido del TDS, aunque separa poco (AUC 0,60 en prueba).

Color. El κ de C es 0,17 en entrenamiento y 0,24 en prueba, aunque en el 80 % de las imágenes la diferencia es de un color como mucho. El marrón claro aparece en 42 de las 44 lesiones de entrenamiento donde no fue anotado, porque es el color del borde, y el blanco casi nunca, porque se asigna a la piel, mientras que el marrón oscuro, el azul grisáceo y el negro andan mejor (κ entre 0,49 y 0,57 en prueba, figura 5 del anexo).

Circularidad y máscara manual. La circularidad separa bien los grupos (AUC 0,72 en prueba), con mediana 0,34 en los melanomas y 0,71 en los nevos comunes. Con la máscara de PH2 los criterios no mejoran, ya que el κ de A baja de 0,44 a 0,29 y el AUC de la circularidad de 0,75 a 0,57 en entrenamiento, así que los desacuerdos no vienen de la segmentación.

Estructuras. Los detectores se mantienen en prueba (tabla 2). Las estrías bajan de 0,79 a 0,67, con sólo 12 imágenes de prueba con estrías. La red atípica y los puntos y glóbulos, patrones finos, se detectan peor y con especificidad baja (0,46 y 0,44), así que el D estimado tiende a pasarse. El valor exacto de D acierta en el 27 % de las imágenes de prueba, menos que decir siempre la mediana de entrenamiento (50 %), con $\kappa = 0{,}07$, porque basta errar una estructura para errar el valor.

Estructura	Imágenes con la estructura	AUC entrenamiento	AUC prueba
Red de pigmento atípica	82 / 34	0,66	0,61
Puntos y glóbulos	78 / 35	0,60	0,63
Estrías	18 / 12	0,79	0,67
Regresión	19 / 6	0,79	0,79
Velo azul-blanquecino	24 / 12	0,95	0,93

Tabla 2: Detección de cada estructura de D. El AUC mide qué tan bien la medida separa las imágenes en que el dermatólogo marcó la estructura de las demás. Las cantidades son de entrenamiento y de prueba.

3.4. Zonas y mapas de características

Los atributos GLCM de toda la lesión no se sostienen en prueba (la correlación, el mejor, pasa de un AUC de 0,76 en entrenamiento a 0,62). La información no está repartida de manera pareja (figura 10 del anexo). En entrenamiento, en los nevos comunes la mediana de la entropía baja de adentro hacia afuera (4,40 en el centro, 4,31 en la periferia y 4,16 en la interfase interna), y en las sospechosas esa caída no aparece (4,31, 4,40 y 4,33).

En prueba (tabla 3), D estimado alcanza un AUC de 0,67 y la saturación de periferia menos centro, 0,71, pero sigue de cerca al brillo de la lesión ($\rho = -0{,}67$), que solo da un AUC parecido. La saturación de piel menos lesión queda en 0,60, con un intervalo que incluye al 0,5, y baja cuando M3 acierta más ($\rho = -0{,}42$ con el Dice), así que en parte mide errores de segmentación.

Medida	AUC entrenamiento	AUC prueba	IC 95 % en prueba
D del dermatólogo (techo)	0,92	0,88	0,81 a 0,94
D estimado	0,76	0,67	0,54 a 0,80
Periferia menos centro, S	0,76	0,71	0,58 a 0,84
Piel menos lesión, S	0,69	0,60	0,46 a 0,75
Oscuridad de la lesión ($-V$)	0,75	0,68	0,54 a 0,80

Tabla 3: Capacidad de cada medida para separar lesiones sospechosas de nevos comunes (140 imágenes de entrenamiento y 60 de prueba).

3.5. Clasificación

El TDS automático separa las lesiones sospechosas de los nevos comunes con un AUC de 0,77 en prueba, con un intervalo que no incluye al 0,5, y la primera parte de la hipótesis 2 se confirma (tabla 4 y figura 2). Por separado, los criterios que más aportan son A y C (AUC 0,73 y 0,69), seguidos por D (0,67) y B (0,60). El TDS extendido llega a 0,79, pero la diferencia con el TDS es de 0,02 y su intervalo ($-0{,}06$ a 0,09) incluye al cero, así que la segunda parte no se confirma. El umbral clínico resulta muy conservador, porque detecta sólo el 39 % de las sospechosas, mientras que el de Youden queda en 3,25 y equilibra mejor las dos medidas. Que sea más bajo es esperable, porque nuestro D parte de 0 y el borde automático suele dar valores bajos.

Clasificador	Umbral	Sensibilidad	Especificidad	AUC (IC 95 %)
TDS, umbral clínico	4,75	0,39	0,96	0,77 (0,65 a 0,89)
TDS, umbral de Youden	3,25	0,69	0,88	0,77 (0,65 a 0,89)
TDS extendido, umbral de Youden	3,49	0,72	0,75	0,79 (0,67 a 0,90)

Tabla 4: Clasificación de las 60 imágenes de prueba en lesiones sospechosas y nevos comunes. Los umbrales de Youden se eligieron en entrenamiento.

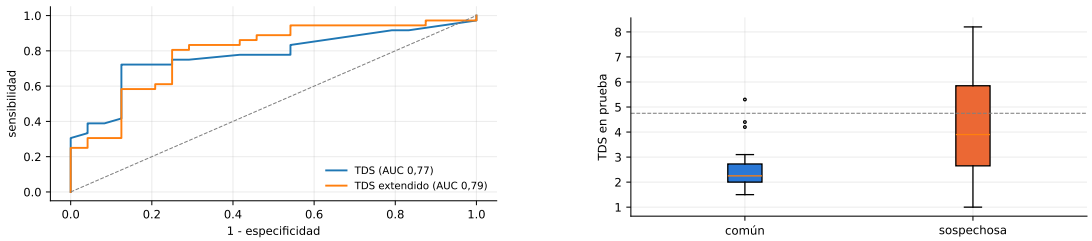


Figura 2: Curvas ROC del TDS y del TDS extendido en prueba (izquierda) y distribución del TDS por grupo, con el umbral clínico en línea punteada (derecha).

4. Conclusiones

La segmentación cumplió su objetivo, con un Dice medio de 0,916 en prueba y fallas en sólo 4 de las 200 imágenes. La hipótesis 1 no se confirmó, porque quitar los pelos con un cierre no mejoró la segmentación, ya que el detector confunde con pelos parte de la red y de la textura oscura.

A coincide de forma aceptable ($\kappa = 0{,}38$) y falla cuando la asimetría está en el color y no en la forma, C coincide poco ($\kappa = 0{,}24$) y B separa poco porque en PH2 los nevos comunes tienen el borde más nítido. Para D buscamos cada estructura por separado, como hace el dermatólogo. El velo y la regresión se detectan bien en prueba (AUC 0,93 y 0,79), y el D resultante separa los grupos (AUC 0,67), aunque acierta el valor exacto en pocas imágenes.

El TDS automático separa las lesiones sospechosas de los nevos comunes (AUC 0,77), lo que confirma la primera parte de la hipótesis 2. Agregarle los contrastes de zonas, que resultaron de color y no de textura, no la mejoró de forma significativa, y la segunda parte no se confirma. Con el umbral de Youden, el TDS alcanza en prueba una sensibilidad de 0,69 y una especificidad de 0,88, por debajo del dermatólogo con la regla original (92,8 % y 90,3 %) y del estado del arte, aunque esos trabajos no incluyen los nevos atípicos entre las lesiones a detectar, lo que hace más difícil nuestra distinción.

Las limitaciones principales son la base, chica y de un solo hospital, la prueba de sólo 60 imágenes y los detectores de red atípica y de puntos y glóbulos, poco precisos. Proponemos mejorar esos detectores y el de pelos, sumar la circularidad, que separó casi igual que A, como término del TDS, repetir el algoritmo sobre imágenes comprimidas, que no se llegó a hacer, y validarlo con otra base.

Referencias

[1] Franz Nachbar et al. «The ABCD rule of dermatoscopy: High prospective value in the diagnosis of doubtful melanocytic skin lesions». En: *Journal of the American Academy of Dermatology* 30.4 (1994), págs. 551-559. DOI: 10.1016/S0190-9622(94)70061-3.

[2] Tim Lee et al. «DullRazor: A software approach to hair removal from images». En: *Computers in Biology and Medicine* 27.6 (1997), págs. 533-543. DOI: 10.1016/S0010-4825(97)00020-6.

[3] Robert M. Haralick, K. Shanmugam e Its'hak Dinstein. «Textural features for image classification». En: *IEEE Transactions on Systems, Man, and Cybernetics* SMC-3.6 (1973), págs. 610-621. DOI: 10.1109/TSMC.1973.4309314.

[4] Maryam Sadeghi et al. «Detection and analysis of irregular streaks in dermoscopic images of skin lesions». En: *IEEE Transactions on Medical Imaging* 32.5 (2013), págs. 849-861.

[5] Gregory K. Wallace. «The JPEG still picture compression standard». En: *Communications of the ACM* 34.4 (1991), págs. 30-44. DOI: 10.1145/103085.103089.

[6] M. Emre Celebi et al. «A methodological approach to the classification of dermoscopy images». En: *Computerized Medical Imaging and Graphics* 31.6 (2007), págs. 362-373. DOI: 10.1016/j.compmedimag.2007.01.003.

[7] Andre Esteva et al. «Dermatologist-level classification of skin cancer with deep neural networks». En: *Nature* 542 (2017), págs. 115-118. DOI: 10.1038/nature21056.

[8] Reda Kasmi y Karim Mokrani. «Classification of malignant melanoma and benign skin lesions: Implementation of automatic ABCD rule». En: *IET Image Processing* 10.6 (2016), págs. 448-455. DOI: 10.1049/iet-ipr.2015.0385.

[9] Soumia Oukil et al. «Automatic segmentation and melanoma detection based on color and texture features in dermoscopic images». En: *Skin Research and Technology* 28.2 (2022), págs. 203-211. DOI: 10.1111/srt.13111.

[10] Teresa Mendonça et al. «PH2: A dermoscopic image database for research and benchmarking». En: *35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2013, págs. 5437-5440. DOI: 10.1109/EMBC.2013.6610779.

[11] Giuseppe Argenziano et al. «Dermoscopy of pigmented skin lesions: Results of a consensus meeting via the Internet». En: *Journal of the American Academy of Dermatology* 48.5 (2003), págs. 679-693. DOI: 10.1067/mjd.2003.281.

[12] Alexandru Telea. «An image inpainting technique based on the fast marching method». En: *Journal of Graphics Tools* 9.1 (2004), págs. 23-34. DOI: 10.1080/10867651.2004.10487596.

[13] Zhou Wang et al. «Image quality assessment: From error visibility to structural similarity». En: *IEEE Transactions on Image Processing* 13.4 (2004), págs. 600-612. DOI: 10.1109/TIP.2003.819861.

[14] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». En: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), págs. 62-66. DOI: 10.1109/TSMC.1979.4310076.

[15] Tony F. Chan y Luminita A. Vese. «Active contours without edges». En: *IEEE Transactions on Image Processing* 10.2 (2001), págs. 266-277. DOI: 10.1109/83.902291.

[16] Murali Anantha, Randy H. Moss y William V. Stoecker. «Detection of pigment network in dermatoscopy images using texture analysis». En: *Computerized Medical Imaging and Graphics* 28.5 (2004), págs. 225-234. DOI: 10.1016/j.compmedimag.2004.04.002.

[17] Ilias Maglogiannis y Konstantinos K. Delibasis. «Enhancing classification accuracy utilizing globules and dots features in digital dermoscopy». En: *Computer Methods and Programs in Biomedicine* 118.2 (2015), págs. 124-133. DOI: 10.1016/j.cmpb.2014.12.001.

[18] Giuseppe Di Leo et al. «Automatic diagnosis of melanoma: A software system based on the 7-point check-list». En: *43rd Hawaii International Conference on System Sciences*. 2010, págs. 1-10. DOI: 10.1109/HICSS.2010.76.

[19] M. Emre Celebi et al. «Automatic detection of blue-white veil and related structures in dermoscopy images». En: *Computerized Medical Imaging and Graphics* 32.8 (2008), págs. 670-677. DOI: 10.1016/j.compmedimag.2008.08.003.

[20] W. J. Youden. «Index for rating diagnostic tests». En: *Cancer* 3.1 (1950), págs. 32-35.

[21] Jacob Cohen. «A coefficient of agreement for nominal scales». En: *Educational and Psychological Measurement* 20.1 (1960), págs. 37-46. DOI: 10.1177/001316446002000104.

[22] J. Richard Landis y Gary G. Koch. «The measurement of observer agreement for categorical data». En: *Biometrics* 33.1 (1977), págs. 159-174. DOI: 10.2307/2529310.

A. Anexo

Método	Dice medio	Mediana	Peor	Dice $< 0{,}7$	Segundos por imagen
Watershed	0,911	0,936	0,504	3	0,151
Crecimiento de regiones	**0,908**	**0,931**	**0,501**	**2**	**0,016**
Otsu	0,906	0,940	0,262	6	0,013
Chan-Vese	0,900	0,938	0,262	7	0,351
k-means	0,880	0,925	0,259	10	0,207

Tabla 5: Métodos de segmentación con su mejor combinación de parámetros, sobre las 140 imágenes de entrenamiento.

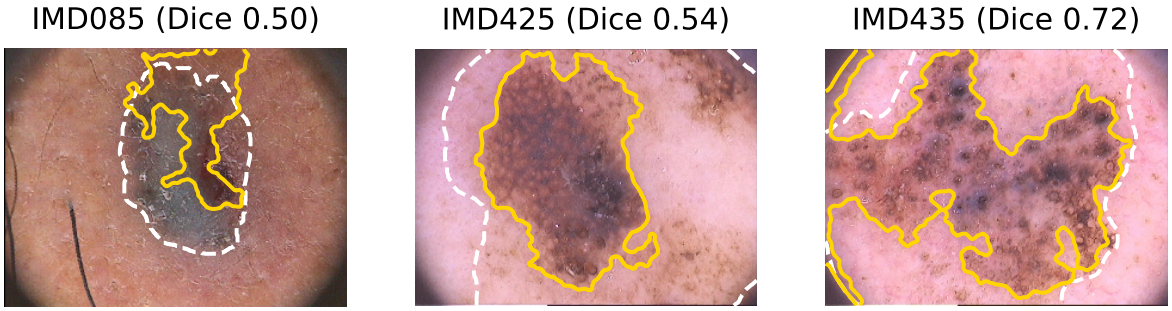


Figura 3: Las imágenes de entrenamiento con peor Dice del método elegido. En blanco punteado, la máscara de PH2; en amarillo, la automática.

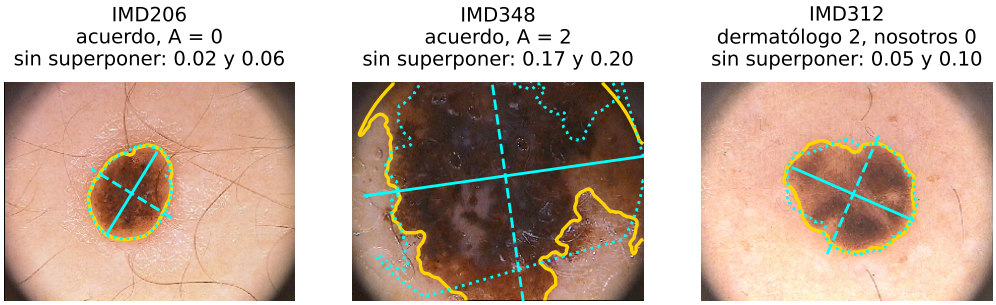


Figura 4: Ejes de simetría y reflejo de la máscara sobre el eje mayor en tres lesiones de entrenamiento. En IMD312 la forma es casi simétrica, pero el pigmento se concentra de un lado, y por eso el dermatólogo puso $A = 2$.

Color	Zonas	H	S	V
Blanco	2	0,630	0,152	0,541
Rojo	1	0,976	0,212	0,492
Marrón claro	12	0,083	0,249	0,452
Marrón oscuro	13	0,060	0,242	0,300
Azul grisáceo	6	0,965	0,069	0,285
Negro	3	0,038	0,065	0,254

Tabla 6: Referencias de color en HSV, con la imagen dividida por el color de la piel, que queda en gris medio ($V = 0{,}5$). Cada una es la mediana de las zonas de entrenamiento de ese color.

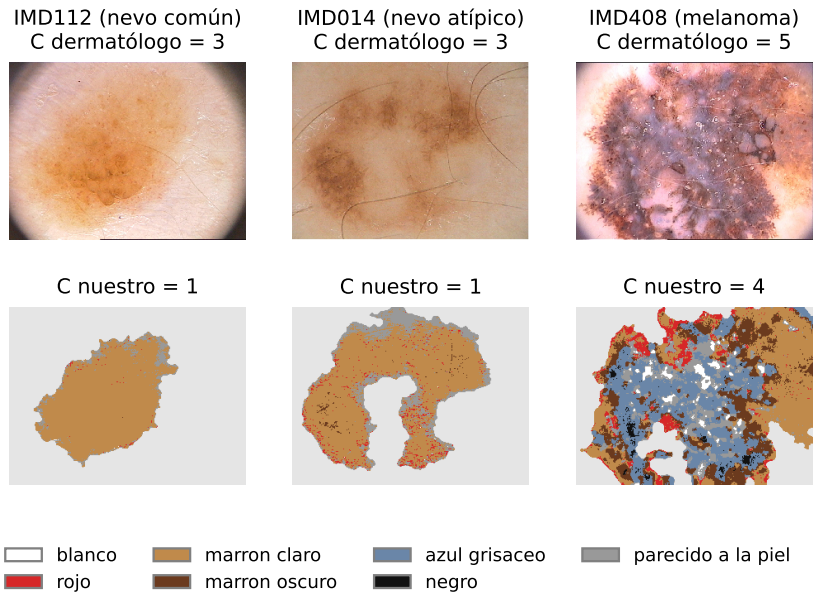


Figura 5: Mapa de colores de la lesión con más colores anotados de cada diagnóstico. En los dos nevos casi todo queda como marrón claro, y en el melanoma el blanco y el negro no llegan al 5 % de la lesión.

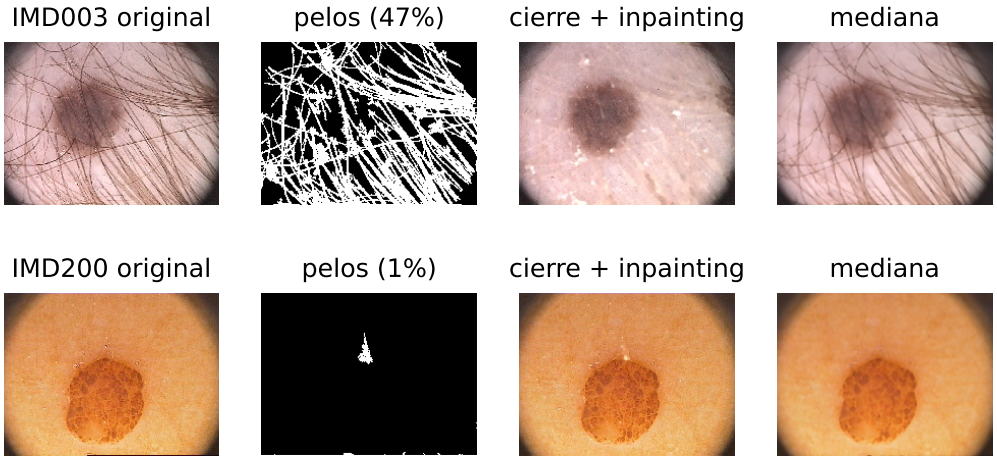


Figura 6: Remoción de pelos en una imagen con muchos pelos (IMD003) y en una sin pelos con red de pigmento (IMD200). Se muestran la original, los pelos detectados, el cierre con *inpainting* y el filtro de mediana.

Calidad	Tasa	PSNR (dB)	PSNR lesión (dB)	SSIM	ΔE lesión
95	8,2	41,1	40,7	0,97	1,9
75	23,7	35,9	34,9	0,89	2,7
50	39,7	34,5	33,4	0,85	3,2
25	67,7	32,8	31,7	0,80	3,9
10	121,8	29,6	28,7	0,70	5,8

Tabla 7: Compresión JPEG, con la mediana de cada métrica sobre las 140 imágenes de entrenamiento.



Figura 7: Detalle de la red de pigmento de IMD200 en la imagen original y comprimida a calidades 75, 25 y 10 (entre paréntesis, la tasa de compresión).

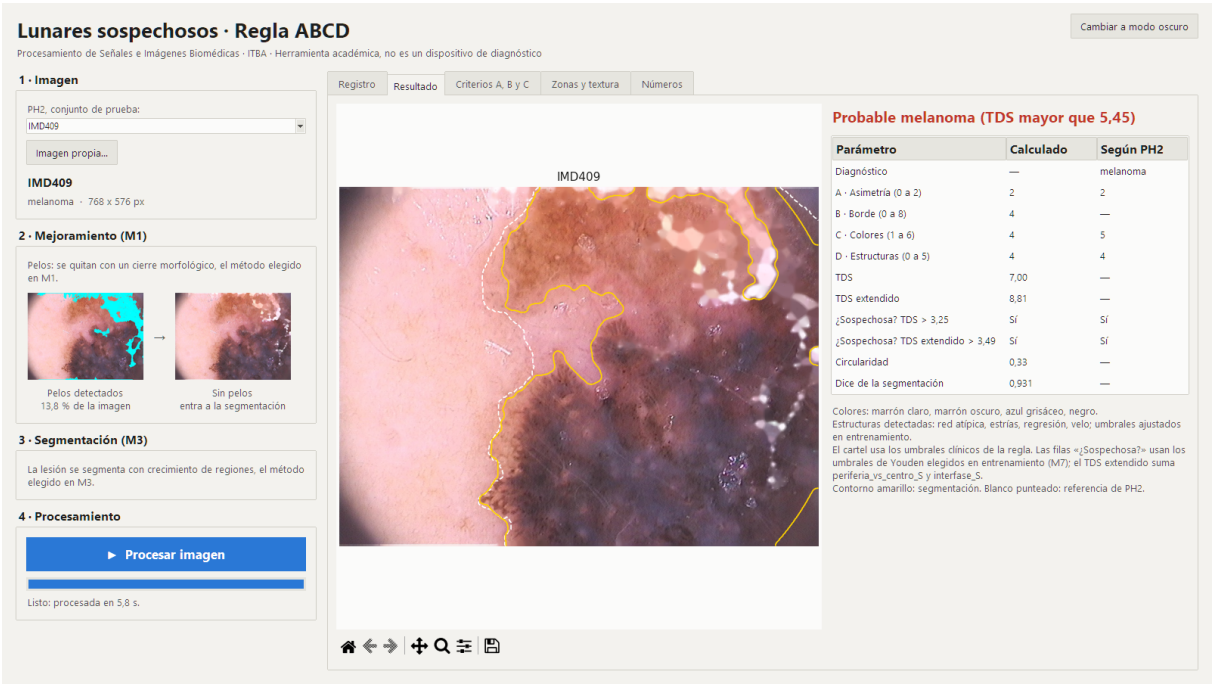


Figura 8: Interfaz gráfica con un melanoma de prueba (IMD409). A la izquierda, los pasos del algoritmo, y a la derecha, la segmentación y la tabla con los criterios calculados junto a los del dermatólogo.

Carpeta	Archivo	Contenido
raíz	`main.py`	Verifica módulos, procesa imágenes y genera resultados
M0	`carga_de_datos.py`	Lectura de PH2, alcance y partición
M1	`mejoramiento.py`	Viñeta y remoción de pelos
M2	`compresion.py`	JPEG, tasa de compresión, PSNR y SSIM
M3	`segmentacion.py`	Métodos de segmentación, posprocesamiento y Dice
M4	`criterios_abc.py`	Asimetría, borde, colores y circularidad
M5	`textura_criterio_d.py`	GLCM y detectores de las estructuras de D
M6	`zonas_y_mapas.py`	Zonas de la lesión y mapas de características
M7	`clasificacion_resultados.py`	TDS, umbrales, métricas y figuras finales
herramientas	`*.py`	Recorrido completo, verificación y gráficos
interfaz	`app.py`	Interfaz gráfica

Tabla 8: Archivos de Python del repositorio. Cada módulo Mn está en `modulos/mn_.../`.

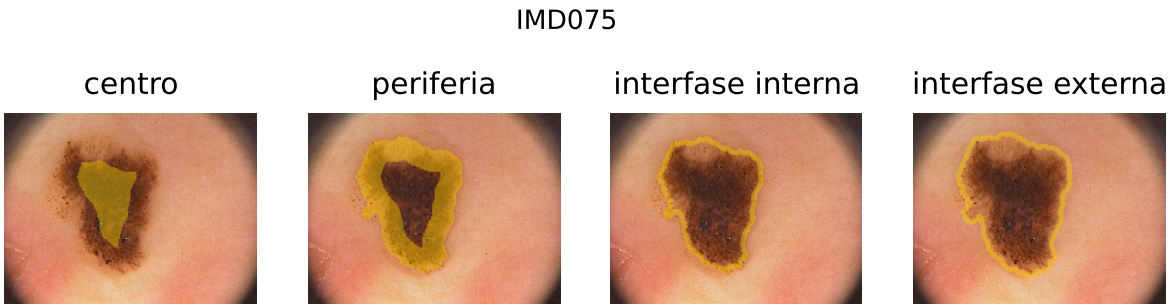


Figura 9: Las cuatro zonas sobre una lesión de tamaño típico de entrenamiento.

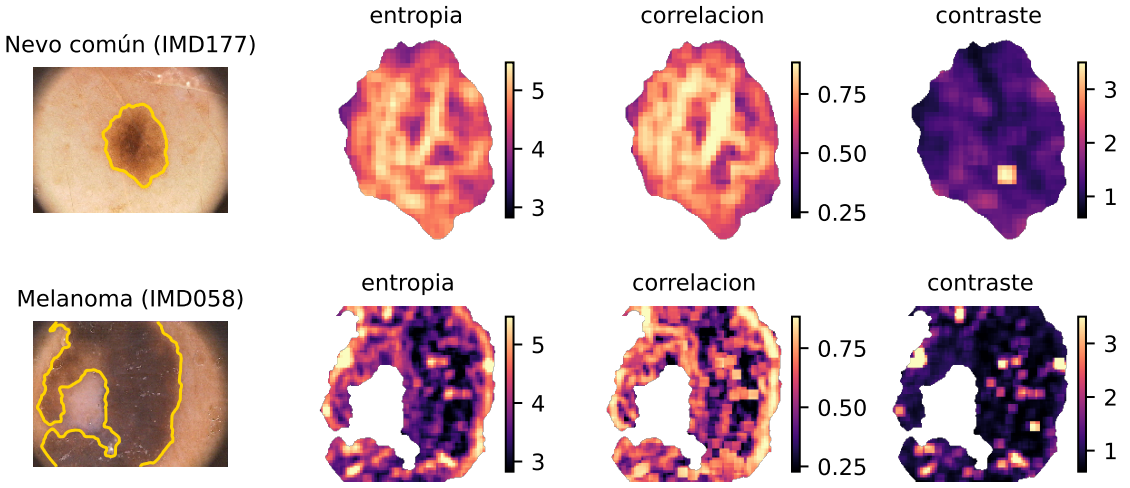


Figura 10: Mapas de entropía, correlación y contraste en un nevo común y un melanoma de entrenamiento. El hueco del mapa del melanoma es una zona central clara que la máscara automática dejó afuera.